

机器学习练习

1 机器学习基本概念

- (1) 请简述以下几种机器学习范式的区别,并各举一例:
监督学习(Supervised Learning)、无监督学习(Unsupervised Learning)、半监督学习(Semi-supervised Learning)、强化学习(Reinforcement Learning)
- (2) 在机器学习建模过程中,一般包括哪些主要步骤?

2 模型评估与选择

某二分类模型在测试集上的混淆矩阵如下:

	预测正类	预测负类
实际正类	45	5
实际负类	15	35

请计算以下指标(保留两位小数): 准确率(Accuracy)、精确率(Precision)、召回率(Recall)、F1 值(F1-score)

Acc:0.8;P:0.9;R:0.75;F1: $\frac{9}{11}$

3 交叉验证与模型选择

在一个回归问题上使用了两种模型: 线性回归(LR)与支持向量回归(SVR).

使用 5 折交叉验证得到平均 MSE 如下:

模型	Fold1	Fold2	Fold3	Fold4	Fold5	平均 MSE
LR	25	28	27	30	26	?
SVR	20	23	22	21	20	?

- (1) 计算两种模型的平均 MSE,并判断哪一个更优.
- (2) 简述交叉验证的主要作用.

LR:27.2;SVR:21.2;后者更优.

- 充分利用数据: 将数据集轮流作训练集和验证集,避免浪费样本
- 减少评估方差: 多折结果取均值,评估比单次更稳定可靠
- 防止过拟合: 比在训练集上直接评估更能反映泛化能力
- 用于模型选择与超参数调优: 选择在交叉验证上表现最好的模型/参数

4 线性回归参数求解(最小二乘法)

已知简单线性回归模型为: $y = w_0 + w_1x + \varepsilon$,其中, ε 为误差项.现有一组样本数据如下:

x(自变量)	1	2	3	4	5
y(因变量)	2	4	5	4	5

请使用最小二乘法求解模型参数 w_0 (截距)和 w_1 (斜率),并写出关键计算步骤.

$$w = (X^T X)^{-1} X^T y$$

$$X = \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \\ 5 & 1 \end{pmatrix}, y = \begin{pmatrix} 2 \\ 4 \\ 5 \\ 4 \\ 5 \end{pmatrix} \text{ 考虑使用增广矩阵求逆矩阵(以防你忘了, } [A|I] \rightarrow [I|A^{-1}]). \text{ 带入得到}$$

$$w = 2.2, w_0 = 0.6$$

5 岭回归正则化效果分析

已知某多元线性回归问题中,特征矩阵 X 存在多重共线性(如两个特征高度相关),分别使用普通线性回归和岭回归(Ridge Regression)建模,回答以下问题:

- (1) 多重共线性会对普通线性回归的参数估计产生什么影响? (从参数稳定性、方差角度说明)
- (2) 岭回归通过引入正则化项 $\lambda \sum_{j=1}^p w_j^2$ ($\lambda \geq 0$, p 为特征数) 解决该问题,简述正则化项的作用.
- (3) 当正则化参数 λ 分别取以下值时,分析对岭回归模型参数 w_j 和模型泛化能力的影响: $\lambda = 0$; λ 趋近于正无穷.

- (1) $(X^T X)^{-1}$ 虽然满 rank 但是接近奇异,数值不稳定,元素会很大,数据的微小扰动会导致

$$w = (X^T X)^{-1} X^T y$$

的 w 变化很大,并且,参数估计方差矩阵 $\text{VAR} \triangleq \sigma^2 [X^T X]^{-1}$,爆炸,模型不可信.

- (2) 岭回归通过引入正则化项 $\lambda \sum_{j=1}^p w_j^2$ ($\lambda \geq 0$, p 为特征数) 解决该问题,简述正则化项的作用.

$$w^* = (X^T X + \lambda I)^{-1} X^T y$$

,保证前者可逆,以引入少量偏差为代价,大幅降低参数估计方差(偏差-方差权衡)

- (3) 当正则化参数 λ 分别取以下值时,分析对岭回归模型参数 w_j 和模型泛化能力的影响: $\lambda = 0$; λ 趋近于正无穷.

前者退化为普通线性回归,多重共线性下参数方差极大训练集拟合好但泛化差,易过拟合;后者正则项主导,所有 $w_j \rightarrow 0$,模型趋于常数预测欠拟合,偏差极大,泛化能力也差

6 贝叶斯分类器计算

假设一个二分类问题(类别 C_1 与 C_2),观测特征为 x .已知如下信息

项目	C_1	C_2
先验概率 $P(C_i)$	0.6	0.4
条件概率 $P(x C_i)$	0.5	0.2

请根据贝叶斯定理计算后验概率 $P(C_1|x)$ 和 $P(C_2|x)$,并判断样本属于哪一类.

$\frac{30}{38}; \frac{8}{38}$ 属于 C_1 .

7 朴素贝叶斯分类器原理分析

- (1) 简述朴素贝叶斯(Naïve Bayes)分类器的基本假设;
- (2) 说明这一假设的优缺点;
- (3) 其常见变体有哪些?

(1) 简述朴素贝叶斯(Naïve Bayes)分类器的基本假设;

假设特征之间相对独立,也就是

$$\mathbb{P}(X|Y = c_k) = \prod_{i=1}^n \mathbb{P}(X^{(i)}|Y = c_k)$$

(2) 说明这一假设的优缺点;

参数数量从 $S^d - 1$ 降到了 $d(S - 1)$, 达到了线形降维, 使得训练方便、快速、可实现, 适合高维数据;

所需训练样本少, 小样本下表现稳定; 易于处理多分类问题

不能捕捉特征之间的相关关系

(3) 其常见变体有哪些?

- 半朴素贝叶斯分类器: 适当考虑一部分属性间的相互依赖信息, 避免完全联合概率计算的高复杂性, 同时不彻底忽略较强的属性依赖关系..
- SPODE, TAN, AODE

8 AdaBoost 权重更新与样本分布变化

给定一个二分类数据集:

样本	x_i	标签 y_i
1	A	+1
2	B	+1
3	C	-1
4	D	-1

第一个弱分类器 $h_1(x)$ 的预测如下:

样本	$h_1(x_i)$
A	+1
B	+1
C	-1
D	+1

(1) 计算弱分类器权重: $\alpha_1 = \frac{1}{2} \ln \frac{1 - \epsilon_1}{\epsilon_1}$

(2) 计算新的样本分布 $D_2(i)$

(3) 请分析哪些样本的权重会上升？这意味着 AdaBoost 下一轮学习时会偏向哪些样本？解释其原因。

(1)

计算弱分类器权重： $\alpha_1 = \frac{1}{2} \ln \frac{1 - \epsilon_1}{\epsilon_1}$

$$\epsilon_1 = \frac{1}{4}, \alpha_1 = \frac{\ln 3}{2}$$

(2) 计算新的样本分布 $D_2(i)$.

$$D_2 = \left[\frac{3}{4\sqrt{e}}, \frac{3}{4\sqrt{e}}, \frac{3}{4\sqrt{e}}, \frac{3\sqrt{e}}{4} \right]$$

$$\text{归一化后是 } D_2 = \left[\frac{1}{3+e}, \frac{1}{3+e}, \frac{1}{3+e}, \frac{e}{3+e} \right].$$

(3) 请分析哪些样本的权重会上升？这意味着 AdaBoost 下一轮学习时会偏向哪些样本？解释其原因。

样本 D 的权重从 0.25 上升到 0.5, 因为它是唯一被 h_1 错误分类的样本. AdaBoost 的核心机制是：下一轮弱分类器将重点关注当前轮分类错误的样本, 通过提高其权重, 迫使下一个弱学习器将注意力集中于难分样本, 最终多个弱分类器互补形成强分类器.

9 Bagging 模型方差与集成优点

某回归问题中, 单个基学习器的输出方差为 $Var(T_i) = 1.2$, 不同学习器之间的预测相关系数为 $\rho = 0.2$. 共有 $N = 50$ 个学习器.

(1) 计算集成预测输出的 总体方差： $Var(\bar{T}) = \rho Var(T_i) + \frac{1-\rho}{N} Var(T_i)$

(2) 若改为 $N = 200$ 个学习器, 新的方差是多少？

(3) 结合计算结果, Bagging 模型减少方差的机制是什么？为何当学习器越多、相关性越低时效果越好？

参考 6.4.2 这个笔记

(1) 计算集成预测输出的总体方差： $Var(\bar{T}) = \rho Var(T_i) + \frac{1-\rho}{N} Var(T_i)$

直接代入, 答案是 0.2592

(2) 若改为 $N = 200$ 个学习器, 新的方差是多少？

0.2448

(1) 结合计算结果, Bagging 模型减少方差的机制是什么？为何当学习器越多、相关性越低时效果越好？

N 大, 第二项越小, 集成方差越低

ρ 小, 第一项小, 第二项 $(1 - \rho)$ 可消除的更多

10 PCA 主成分方向与投影

给定数据集如下, 每一行是一条样本:

$$X = \begin{bmatrix} 2 & 0 & 1 \\ 3 & 1 & 2 \\ 4 & 0 & 3 \\ 5 & 2 & 4 \\ 6 & 3 & 5 \end{bmatrix}$$

- (1) 求特征值与特征向量,并将特征向量进行单位化.
- (2) 指出主成分方向,并计算方差贡献率.
- (3) 对样本 $x = [4, 0, 3]^T$, 计算其在第一主成分上的投影.
- (4) 如果仅保留第一主成分,原始三维信息会损失多少? 此损失代表什么含义?

(1) 求特征值与特征向量,并将特征向量进行单位化.

$$\bar{X} = \begin{pmatrix} -2 & -1.2 & 2 \\ -1 & -0.2 & 1 \\ 0 & 1.2 & 0 \\ 1 & 0.8 & 1 \\ 2 & 1.8 & 2 \end{pmatrix}$$

协方差矩阵 $C = \frac{1}{n-1} \bar{X}^T \bar{X}$, n 样本数量; 记住 X 是 $n \times d$ 的矩阵.

$$\bar{X}^T \bar{X} = \begin{pmatrix} 10 & 7 & 10 \\ 7 & \frac{34}{5} & 7 \\ 10 & 7 & 10 \end{pmatrix}$$

$$C = \begin{pmatrix} \frac{5}{2} & \frac{7}{4} & \frac{5}{2} \\ \frac{7}{4} & \frac{17}{10} & \frac{7}{4} \\ \frac{5}{2} & \frac{7}{4} & \frac{5}{2} \end{pmatrix}$$

$$\det(C - \lambda I) = 0$$

$$\Leftrightarrow \lambda^3 - \frac{67}{10} \lambda^2 + \frac{19}{8} = 0$$

$$\Leftrightarrow \lambda = 0, \frac{67 \pm \sqrt{3539}}{20}$$

向量是 $\left(1, \frac{67 \pm \sqrt{3539}}{20}, 1\right), (-1, 0, 1)$. 我不想归一化.

(2) 指出主成分方向,并计算方差贡献率.

不想手算. 计算器告诉我分别是 0.9439, 0.0560, 0.

(3) 对样本 $x = [4, 0, 3]^T$, 计算其在第一主成分上的投影.

$\bar{x} = [0, -1.2, 0]^T$. 直接乘特征向量, 答案是 0.566.

(4) 如果仅保留第一主成分,原始三维信息会损失多少? 此损失代表什么含义?

损失 5.6%. 对应第二主成分方向上的信息.

11 K-Means 聚类迭代与收敛分析

一维数据集:

$$x = \{1, 2, 3, 10, 11, 12\}$$

初始中心为:

$$\mu_1 = 2, \mu_2 = 10$$

- (1) 执行两次完整的 K-Means 迭代,每次写出簇分配与新的中心.
- (2) 说明两步后算法是否收敛.
- (3) 若初始中心改为 $\mu_1 = 3, \mu_2 = 12$,结果会怎样变化? 为什么 K-Means 对初始化敏感?

(1) 执行两次完整的 K-Means 迭代,每次写出簇分配与新的中心.

第一次:计算中心,距离分别为

$$\begin{pmatrix} 1 & 0 & 1 & 8 & 9 & 10 \\ 9 & 8 & 7 & 0 & 1 & 2 \end{pmatrix}$$

$$C_1 = \{1, 2, 3\}, C_2 = \{10, 11, 12\}$$

$$\mu_1 = 2, \mu_2 = 11$$

第二次不赘述,完全相同.

(2) 说明两步后算法是否收敛.

收敛.因为完全相同了

(3) 若初始中心改为 $\mu_1 = 3, \mu_2 = 12$,结果会怎样变化? 为什么 K-Means 对初始化敏感?

结果相同.初始化敏感是因为,K-Means 只保证收敛到局部最优,如果初始化很不好,算法会收敛到分割质量很差的局部最优解,例如,在簇间距小或分布复杂时,且初始化的两个中心都落在同一簇内.

12 高斯混合模型 (GMM)

有两个一维高斯成分:

成分	权重 π_k	均值 μ_k	方差 σ_k^2
1	0.4	0	1
2	0.6	3	1

给定样本 $x = 1$.

(1) 写出每个成分的后验概率(职责): $\gamma_{k(x)} = \frac{\pi_k \mathcal{N}(x|\mu_k, \sigma_k^2)}{\sum_{j=1}^2 \pi_j \mathcal{N}(x|\mu_j, \sigma_j^2)}$,并代入数值计算.

(2) 求两成分的责任度比值 $\frac{\gamma_1(x)}{\gamma_2(x)}$

(3) 分析哪个成分对该样本的解释更大? 如果两个高斯方差变大,职责会发生什么变化? 这说明了 GMM 的哪种鲁棒性问题?

(1)

考察 $\mathcal{N}(x|\mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$, 带入数值得到两个分量分别是 $\frac{0.4}{\sqrt{2\pi e}}, \frac{0.6}{\sqrt{2\pi e^2}}$. 那么后验概率分别是 0.749, 0.251.

(2) 2.98

(3) 分析哪个成分对该样本的解释更大? 如果两个高斯方差变大, 职责会发生什么变化? 这说明了 GMM 的哪种鲁棒性问题?

成分 1 解释更大, 因为 $x = 1$ 距离 $\mu_1 = 0$ 更近. 两个高斯分布都变得更宽、更平坦, 各成分的密度差异减小, 责任度将趋向由先验权重 π_k 主导, 成分 1 的优势降低.

这说明当方差过大时, GMM 对样本的“软分配”几乎退化为纯先验, 失去了用数据更新责任度的意义, 模型对数据的拟合能力下降(欠拟合). 反之方差过小则过拟合. 这反映了 GMM 参数(尤其方差)对 EM 迭代结果的敏感性问题.

13 硬间隔 SVM 的最优超平面计算

给定二维样本集:

样本	特征 (x_1, x_2)	标签 y
A	(0, 0)	+1
B	(1, 1)	-1
C	(2, 0)	-1

- 写出线性可分 SVM 的优化目标函数(原始形式).
- 画出这些点在平面上的分布, 并给出直观的分界线方向.
- 将该问题化为拉格朗日对偶问题, 求出支持向量与对偶变量 α_i 的非零条件.
- 求出最优分离超平面方程 $w^T x + b = 0$.
- 计算分类间隔的宽度.

(1) 写出线性可分 SVM 的优化目标函数(原始形式).

$$\min_{w, b} \frac{1}{2} \|w\|^2, \text{ s.t. } y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N$$

(1) 画出这些点在平面上的分布, 并给出直观的分界线方向.

(3) 将该问题化为拉格朗日对偶问题, 求出支持向量与对偶变量 α_i 的非零条件.

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, N \end{aligned}$$

考虑笔记的 4.1.1.4 小节. 我是 sb 吗, 为什么漏掉平方项?

(4) 求出最优分离超平面方程 $w^T x + b = 0$.

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

带入有 $\alpha_1 - \alpha_2 - \alpha_3 = 0, \min_{\alpha} (\alpha_2^2 + 2\alpha_2\alpha_3 + 2\alpha_3^2) - \alpha_1 - \alpha_2 - \alpha_3 \Rightarrow \alpha = [1, 1, 0]^T$ (求偏导)

$$\Rightarrow w^* = [-1, -1]^T, b^* = 1$$

(5) 计算分类间隔的宽度.

$$d = \frac{2}{\|w\|} = \sqrt{2}.$$

14 核函数与软间隔 SVM

已知 SVM 的对偶形式为:

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

约束: $\sum_i \alpha_i y_i = 0, 0 \leq \alpha_i \leq C$

- (1) 若使用高斯核 $K(x_i, x_j) = e^{-\|x_i - x_j\|^2}$, 说明此核在特征空间的非线性映射性质.
- (2) 分析参数 C 过大或过小时对应“欠惩罚”和“过惩罚”的几何解释.
- (3) 给出硬间隔与软间隔 SVM 的几何差别示意(可用文字或符号说明支持向量位置变化).
- (4) 说明核函数必须满足的两个基本条件.

(1) 若使用高斯核 $K(x_i, x_j) = e^{-\|x_i - x_j\|^2}$, 说明此核在特征空间的非线性映射性质.

对应无穷维的隐式特征空间映射 φ . 等价于在无穷维特征空间中做内积, 使原本线性不可分的样本在高维空间中变得线性可分, 而计算时只需原始空间的距离, 无需显式构造高维向量.

(2) 分析参数 C 过大或过小时对应“欠惩罚”和“过惩罚”的几何解释; C 小: 误分类惩罚低, 允许更多样本落入间隔内甚至越界, 决策边界间隔宽, 但训练误差大, 模型偏向欠拟合; C 过大: 不允许任何误分类, 决策边界尽量将所有点正确分开, 间隔窄, 边界紧贴数据, 易过拟合, 对噪声敏感

(3)

- 正定的, 也就是 Gram 矩阵半正定;
- 对称性: $K(x_i, x_j) = K(x_j, x_i)$

15 决策树构建与剪枝分析

给定以下训练数据集(二维离散特征):

样本	天气	湿度	是否打球(标签)
A	晴	高	否
B	晴	正常	是
C	阴	高	是
D	阴	正常	是
E	雨	高	否
F	雨	正常	是

- (1) 计算在主节点上按“天气”划分时的信息增益,并判断是否是最优划分特征.
- (2) 画出对应的决策树结构(可用文字层次描述代替图形).
- (3) 若使用“基尼指数”作为划分标准,比较与信息增益的划分结果是否一致.
- (4) 简述决策树容易过拟合的原因,并说明两种剪枝方法(预剪枝 / 后剪枝)的思路.

(1) 计算在主节点上按“天气”划分时的信息增益,并判断是否是最优划分特征.

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

$$= - \frac{4}{6} \left(\log_2 \frac{4}{6} \right) - \frac{2}{6} \log_2 \frac{2}{6} = \log_2 3 - \frac{2}{3}$$

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \sum_{k=1}^K \frac{|D_{ik}|}{|D_i|} \log_2 \frac{|D_{ik}|}{|D_i|}$$

$$= - \frac{1}{3} \left(\frac{1}{2} \log_2 \times 2 \frac{1}{2} + 0 + \frac{1}{2} \log_2 \frac{1}{2} \times 2 \right) = \frac{2}{3}$$

$$G(A) = H(D) - H(D|A) = \log_2 3 - \frac{4}{3}. \text{同理, } G(B) = \frac{1}{2} \log_2 3 - \frac{1}{3}$$

偷偷按计算器发现 $G(B)$ 更大,也就是湿度最优,天气不是最优的.

- (2) 画出对应的决策树结构(可用文字层次描述代替图形).

```

根节点：湿度
├── 湿度=高(3样本：C是2否)
│   └── 继续划分(天气)
│       ├── 天气=阴 → 是
│       └── 天气=晴/雨 → 否
└── 湿度=正常(3样本：全是)
    └── 叶节点：是
    
```

- (3) 若使用“基尼指数”作为划分标准,比较与信息增益的划分结果是否一致.

$$\text{Gini}(A) = \frac{1}{3} \left(\left(1 - \left(\frac{1}{2} \right)^2 - \left(\frac{1}{2} \right)^2 \right) \times 2 \right) = \frac{1}{3}$$

$$\text{Gini}(B) = \frac{1}{2} \left(\left(1 - \left(\frac{1}{3} \right)^2 - \left(\frac{2}{3} \right)^2 \right) \right) = \frac{2}{9}$$

所以先用 B 也就是湿度划分,结果一致.

(4) 简述决策树容易过拟合的原因,并说明两种剪枝方法(预剪枝 / 后剪枝)的思路.

决策树若不加约束会一直分裂直到叶节点纯净,记住了训练集中的所有噪声和细节,导致树深、叶多,对新样本泛化差.

预剪枝(Pre-pruning): 在树生长过程中提前停止,当节点划分带来的验证集精度提升不足某阈值,或样本数少于阈值时,停止分裂,直接设为叶节点.优点是训练快,缺点可能因贪心过早停止而欠拟合.

后剪枝(Post-pruning): 先将树完全生长,再自底向上将子树替换为叶节点(如 CCP、REP 等),若替换后验证集误差不增加则保留剪枝.保留了更多信息,通常效果优于预剪枝,但计算开销更大.

16 强化学习：价值迭代与策略改进

给定两个状态的 MDP:

状态	动作	奖励	下一状态
s_1	a_1	4	s_2
s_2	a_1	1	s_1

折扣因子 $\gamma = 0.5$, 初始 $V_0(s_1) = V_0(s_2) = 0$.

- 写出价值迭代更新公式;
- 分别计算 V_1, V_2, V_3 ;
- 判断策略是否随迭代发生变化;
- 解释价值迭代与策略迭代的关系与收敛特征.

(1) 写出价值迭代更新公式;

$$V_{k+1}(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} \mathbb{P}(s'|s, a) V_k(s') \right]$$

$$V_{k+1}(s_1) = 4 + 0.5 \cdot V_k(s_2)$$

$$V_{k+1}(s_2) = 1 + 0.5 \cdot V_k(s_1)$$

(2) 分别计算 V_1, V_2, V_3 ;

$$V_1(s_1) = 4, V_1(s_2) = 1; V_2(s_1) = 4.5, V_2(s_2) = 3; V_3(s_1) = 5.5, V_3(s_2) = 3.25$$

(3) 判断策略是否随迭代发生变化;

不随.

价值迭代：直接对贝尔曼最优方程迭代，每步更新值函数，收敛后隐含最优策略。简单但每次迭代后不显式提取策略。

策略迭代：交替执行"策略评估"（给定策略求精确值函数）和"策略改进"（贪心更新策略），每轮策略改进保证单调不降，通常在更少迭代轮次内收敛，但每轮策略评估计算量更大。

两者均收敛到最优策略 π^* 和最优值函数 V^* ，价值迭代可视为策略迭代中策略评估只进行一次的特例。

bro wtf is this

17 单隐藏层网络的反向传播计算

一个简单神经网络结构如下：输入层(2 维)→ 隐藏层(2 个神经元,Sigmoid 激活)→ 输出层(1 个神经元,线性输出)

设定参数如下：

参数	值
输入 x	$[1, 0]^T$
期望输出 y	0.8
W^1	$\begin{pmatrix} 0.1 & 0.4 \\ 0.2 & 0.3 \end{pmatrix}$
b^1	$[0, 0]^T$
W^2	$[0.7, 0.5]^T$
b^2	0.1
学习率 η	0.1

- (1) 写出前向传播过程,计算各层输出；
- (2) 以平方误差 $L = \frac{1}{2}(y_{\text{pred}} - y)^2$ 为损失,推导对所有参数的梯度；
- (3) 若将激活函数改为 ReLU,说明梯度表达式怎样简化,且在何种输入下可能出现神经元失活(dead neuron).

(1) 前向传播

隐藏层输入：

$$z_1 = W_1 x + b_1 = \begin{pmatrix} 0.1 & 0.4 \\ 0.2 & 0.3 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.1 \\ 0.2 \end{pmatrix}$$

隐藏层输出(Sigmoid): $h = [0.5250, 0.5498]^T$

输出层：

$$y_{\text{pred}} = W_2^T h + b_2 = 0.7424$$

(2) 反向传播梯度推导

损失:

$$L = \frac{1}{2}(0.7424 - 0.8)^2 \approx 0.00166$$

输出层误差:

$$\delta_{\text{out}} = \frac{\partial L}{\partial y_{\text{pred}}} = y_{\text{pred}} - y = -0.0576$$

W_2, b_2 的梯度:

$$\frac{\partial L}{\partial W_2} = \delta_{\text{out}} \cdot h = -0.0576 \times \begin{pmatrix} 0.5250 \\ 0.5498 \end{pmatrix} \approx \begin{pmatrix} -0.03024 \\ -0.03167 \end{pmatrix}$$

$$\frac{\partial L}{\partial b_2} = \delta_{\text{out}} = -0.0576$$

传回隐藏层:

$$\delta_h = \delta_{\text{out}} \cdot W_2 = -0.0576 \times \begin{pmatrix} 0.7 \\ 0.5 \end{pmatrix} = \begin{pmatrix} -0.04032 \\ -0.02880 \end{pmatrix}$$

经过 Sigmoid 导数($\sigma'(z) = \sigma(z)(1 - \sigma(z))$):

$$\sigma'(0.1) = 0.5250 \times 0.4750 \approx 0.2494, \quad \sigma'(0.2) = 0.5498 \times 0.4502 \approx 0.2475$$

$$\delta_h^{\text{in}} = \begin{pmatrix} -0.04032 \times 0.2494 \\ -0.02880 \times 0.2475 \end{pmatrix} = \begin{pmatrix} -0.01005 \\ -0.00713 \end{pmatrix}$$

W_1, b_1 的梯度:

$$\frac{\partial L}{\partial W_1} = \delta_h^{\text{in}} \cdot x^T = \begin{pmatrix} -0.01005 \\ -0.00713 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} -0.01005 & 0 \\ -0.00713 & 0 \end{pmatrix}$$

$$\frac{\partial L}{\partial b_1} = \begin{pmatrix} -0.01005 \\ -0.00713 \end{pmatrix}$$

(3) 改为 ReLU 的梯度简化与死亡神经元

ReLU:

$$\text{ReLU}(z) = \max(0, z)$$

,导数

$$\text{ReLU}'(z) = \begin{cases} 1 & \text{如果 } z > 0 \\ 0 & \text{如果 } z \leq 0 \end{cases}$$

梯度简化为:

$$\delta_h^{\text{in}} = \delta_h \cdot 1[z > 0]$$

,不再需要计算 Sigmoid 的非线性导数,梯度只有 0 或 1 两种情况,计算更高效,且不存在 Sigmoid 的梯度饱和问题。

死亡神经元(Dead Neuron): 当某神经元的输入 $z \leq 0$ 时,ReLU 输出为 0,梯度为 0,该神经元对反向传播无贡献,参数永远不更新.若学习率过大导致权重更新后 z 持续为负,该神经元将永久失活.常见触发条件: 初始化不当、学习率过大、偏置为大负数时。

18 写出 Logistic 模型学习的梯度下降算法.

笔记 2.3

$$J(w) = -L(w) = -\sum_{i=1}^N y_i(w \cdot x_i + b) - \log \left[1 + \exp(w \cdot x_i + b) + \frac{\lambda}{2} \sum_{j=1}^d w_j^2 \right]$$

(后者可选的正则化) 所以有:

$$\nabla J(w) = \frac{\partial J(w)}{\partial w} = \sum_{i=1}^N x_i(\pi(x_i) - y_i)$$

$\pi(x_i) = \frac{1}{1 + \exp(-w \cdot x_i + b)}$ 是 logistic 函数,表示样本 x_i 属于正类的概率。

梯度下降法具体的更新公式为:

$$\begin{aligned} w^{(k+1)} &= w^{(k)} - \alpha \nabla J(w^{(k)}) = w^{(k)} - \alpha \sum_{i=1}^N x_i(\pi(x_i) - y_i) \\ b^{(k+1)} &= b^{(k)} - \alpha \sum_{i=1}^N (\pi(x_i) - y_i) \end{aligned}$$

19 试从极大似然的角度阐释线性回归;在什么情况下,岭回归等价于最大后验概率估计? 请给出理论解释.

有关 MAP,请参考西瓜书 P296

线性回归的极大似然角度

假设误差项 $\varepsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$, 则:

$$y_i | x_i, w \sim \mathcal{N}(w^\top x_i, \sigma^2)$$

对数似然:

$$\ell(w) = \log \prod_i P(y_i | x_i, w) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_i (y_i - w^\top x_i)^2$$

最大化对数似然等价于最小化残差平方和, 即普通最小二乘法 (OLS)。因此, 在误差服从独立同分布高斯分布的假设下, 线性回归的最小二乘解就是极大似然估计。

岭回归等价于最大后验估计 (MAP)

在贝叶斯框架下, 对参数 w 施加高斯先验:

$$w \sim \mathcal{N}(0, \tau^2 I)$$

MAP 估计最大化后验概率:

$$\begin{aligned} w_{MAP} &= \arg \max_w [\log P(w) + \log P(D|w)] \\ &= \arg \min_w \left[\sum_i (y_i - w^\top x_i)^2 + \frac{\sigma^2}{\tau^2} \|w\|^2 \right] \end{aligned}$$

令 $\lambda = \frac{\sigma^2}{\tau^2}$, 这正好是岭回归的目标函数。

结论: 当参数先验为零均值高斯分布时 ($w \sim \mathcal{N}(0, \tau^2 I)$), 岭回归等价于 MAP 估计, 正则化参数 $\lambda = \sigma^2 / \tau^2$ (噪声方差与先验方差之比)。

20 机器学习综合题

某银行希望利用机器学习模型自动评估客户的信用风险.每位客户的特征如下:

特征	类型	说明
收入水平	高 / 中 / 低	分类特征
年龄	连续型	(单位: 岁)
是否有房	是 / 否	分类特征
历史违约次数	连续型	(次)
信用风险标签	0 = 低风险, 1 = 高风险	模型预测目标

银行提供了如下 6 组训练样本(简化数据):

编号	收入水平	年龄	是否有房	违约次数	信用风险
1	高	45	是	0	0
2	低	23	否	2	1
3	中	32	否	1	1
4	高	36	是	0	0
5	中	40	否	0	0
6	低	29	否	1	1

- 请给出：将“收入水平”(高/中/低)和“是否有房”(是/否)转换为数值的合理编码方式(例如 0/1 或 One-Hot 等形式);编码后第 2 条样本的特征向量应为何? (按顺序: 收入、年龄、是否有房、违约次数).
- 若模型首先考虑以“收入水平”作为划分属性(高、中、低),求此划分的信息增益.请写出计算过程,并说明最终是否选择“收入水平”作为首个划分节点(可定性判断).
- 假设二分类问题中,采用支持向量方法,当惩罚系数 C 较大时,会对模型的间隔与误分类率产生怎样的影响? 简要说明.
- 考虑一个简化的两层前馈神经网络:

输入层节点: 2(收入编码与违约次数)

隐藏层节点: 2,使用 Sigmoid 激活函数

输出层节点: 1,使用 Sigmoid 输出(表示高风险概率)

已知: $x = [1, 2]^T, W_1 = \begin{pmatrix} 0.5 & -0.4 \\ 0.3 & 0.1 \end{pmatrix}, b_1 = [0, 0]^T, W_2 = [0.6, -0.2]^T, b_2 = 0$

请计算: 隐藏层输出 $h = \sigma(W_1 x + b_1)$; 最终输出 $\hat{y} = \sigma(W_2^T h + b_2)$.

其中 $\sigma(a) = \frac{1}{1 + e^{-a}}$,保留两位小数即可

- 结合本任务特征特点与数据量(仅约 100 条样本),分析: 若仅能选择决策树 / SVM / 神经网络三种之一,你会选择哪种? 请从数据规模、特征类型、模型可解释性等方面说明理由.

(1)收入水平用顺序编码,高中低分别编码成 2,1,0.是否有房编码成 onehot. 第二条样本: $x_2 = [0, 23, 0, 2, 1]^T$.

$$(2) D(A) = -\sum_{i=1}^n p_i \log p_i = -\left(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}\right) = 1$$

$$H(A) = -\sum_{i=1}^n p_i \log p_i = -\frac{1}{3} \left(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}\right) = \frac{1}{3} \text{ 则 } G(A) = \frac{2}{3} \text{ 定性分析:可以.信息增益 } 0.667 \text{ 较高,收入水平能有效区分高/低风险,选择收入水平作为首个划分节点是合理的.}$$

定量分析:算一下是否有房和违约次数的信息增量.

(3) C 较大意味着对误分类施以重惩罚,SVM 的决策边界会尽量将所有训练样本正确分类:

- 间隔变窄: 为了不允许误分类,边界紧贴支持向量,分类间隔(margin)减小
- 过拟合风险上升: 模型对噪声和异常点敏感,泛化能力可能下降

(4)直接代入 $h = \sigma(W_1 x + b_1) = \sigma([-0.3, 0.5]^T) = [0.43, 0.62]^T$

$$\hat{y} = \sigma(W_2^T h + b_2) = \sigma(0.134) = 0.53$$

(5)决策树.理由:

- 数据规模:100 条样本量偏小,神经网络有过拟合风险不适合使用,决策树和 SVM 适合;
- 特征类型:收入水平和是否有房、年龄等需要编码处理,SVM 和神经网络需要挑选合适的编码方式;而决策树不需要,原生支持离散、连续的输入.
- 可解释性:决策树可解释性高,可可视化,可解释性高.SVM 和神经网络可解释性差.

21 杂项

21.1 数据质量问题

问题: 缺失值、噪声、异常值、标注错误.“垃圾进,垃圾出”,再好的模型也救不了烂数据.

解法:

- 缺失值: 均值/中位数填充、KNN 插补、或直接建模预测缺失值
- 异常值: IQR 法、Z-score 检测后剔除或修正
- 标注质量: 交叉标注、置信学习(Confident Learning)自动找出标注错误样本

21.2 特征问题

问题: 特征冗余(多重共线性)、无关特征引入噪声、特征量纲不统一干扰距离类模型.

- VIF (方差膨胀因子): VIF > 10 说明存在严重共线性

解法:

- 特征选择: 过滤法(相关系数)、包裹法(RFE)、嵌入法(Lasso 正则化自动压缩无关特征权重)
- 降维: PCA 去除冗余,t-SNE/UMAP 用于可视化
- 归一化/标准化: Min-Max、Z-score,尤其对 SVM、KNN、神经网络必要

21.3 分布偏移(Distribution Shift)

问题: 训练数据和真实部署数据的分布不一致,导致线上效果远差于离线评估.医院模型在 A 医院训练,部署到 B 医院就崩了,就是典型案例.

分为两类:

- 协变量偏移: 输入 X 的分布变了,但 $P(Y|X)$ 不变
- 概念漂移: X 和 Y 的关系本身变了(如疾病谱随时间变化)

解法:

- 持续监控线上数据分布,检测漂移(KL 散度、PSI 指标)
- 定期用新数据重新训练或微调模型
- 领域自适应(Domain Adaptation)技术

21.4 一、欠拟合 (Underfitting)

定义: 模型过于简单,未能学习到数据中的真实结构,导致难以做出有效可用的预测。示例: 用线性模型来表达“生活满意度与人均 GDP 的关系”属于拟合不足,因为现实情况远比简单线性模型复杂,导致对训练样本的预测也多有不准。解决方法:

- (1) 选择带有更多参数、更强大的模型 (复杂化模型)。
- (2) 通过特征变换, 为学习算法提供更好的特征集 (特征工程)。
- (3) 放松对模型的约束 (降低复杂度正则项的惩罚因子值)。

21.5 二、过拟合 (Overfitting)

定义: 模型完美适应于训练集数据,从而牺牲了对新数据点的预测能力 (泛化能力差)。当模型相对于训练数据过于复杂时, 容易发生过拟合。缓解方案:

- (1) 减少模型参数（人工手动）。
- (2) 优化模型特征（特征工程）。
- (3) 约束模型参数（对复杂性进行惩罚的正则化）。
- (4) 增加训练数据（降低过拟合可能性）。
- (5) 改善数据质量（修复数据错误，填补数据缺失，清除异常数据）。

21.6 三、训练数据集的挑战：数据量与代表性

不具代表性的训练集：拟合出的模型难以做出准确预测。样本集太小：容易出现采样噪声（即非代表性数据被选中），从而导致模型过拟合。大样本量但采样欠妥：同样可能导致非代表性数据集，这被称为采样偏差问题。

21.7 四、训练数据集的挑战：数据质量（Garbage in, garbage out）

如果训练集充满了错误、异常值和噪声（如差质量的测量数据），系统将很难检测到底层模式。

数据异常：如果某些实例明显是异常情况，应选择直接丢弃或尝试手动修复错误。数据缺失：如果部分实例缺少特征（如 5% 的顾客未指定年龄），可选择：整体忽略这些特征；忽略这部分有缺失的实例；将缺失的值补充完整（如填写年龄值的中位数）。

21.8 五、核心应对手段：特征工程 (Feature Engineering)

一个机器学习项目成功的关键是提取出一组好的特征子集用于训练模型。特征工程主要包括以下几点：

特征理解与选择：从现有特征中选择出最有效的特征。注：系统需要较多“与目标变量有关”的特征，较少“与目标变量无关”的特征，才能有效学习。

特征清洗与增强：删除和填充含缺失值的数据，最大化数据价值。特征提取与转化：将现有特征进行整合，产生更为有效的特征。注：各特征之间要尽可能减少互相关（Correlation）。多重共线性是互相关关系的极端情况（某些特征可表达为其他特征的线性组合），会导致算法极不稳定。

特征构建与学习：通过新数据创造新特征，或学习出新特征。