

4567 因为解答过程较长放在后面

一、

请简要解释监督学习、无监督学习及强化学习之间的区别,并分别举一个应用实例.

- ① 监督学习处理的对象是所谓的有标签训练数据,它利用有标签的训练数据来学习一个模型,它的目标是用学到的模型给无标签的测试数据打上标签.(决策树和随机森林)
- ② 无监督学习的训练数据没有标签,它自动从训练数据中学习知识,建立模型. -> K-均值聚类 (K-means)
- ③ 强化学习是通过与环境的交互来学习策略,以最大化累积奖励.模型(或称为代理)通过试错过程,从环境中获取反馈来调整其行为策略.如标准的马尔可夫决策过程.

二、

逻辑回归模型主要用于分类还是回归? 是线性模型还是非线性模型? 是生成式模型还是判别式模型? 请给出逻辑回归的数学公式,并简要回答上述问题.

- 逻辑回归主要用于分类任务.
- 逻辑回归模型本质上是一个线性模型,但由于其输入经过 sigmoid 函数进行变换,整体表现出非线性模型.
- 判别性模型.
- 公式:
 1. 线性部分: $z = W^T x + b$
 2.
$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

三、

随机森林是一种常用的集成学习算法.请回答以下问题:

(1) 简要说明随机森林的工作原理.

① **工作原理** 从训练数据集中有放回地随机抽取多个子集样本,形成多个不同的训练集.对每个训练集训练一个决策树.在训练决策树时,还在每个结点进行特征选择时,随机选择一部分特征,即特征子集选择.最后用所有训练好的决策树共同构成随机森林.对于分类任务,随机森林通过对每棵树的预测结果进行投票并决定最终结果.

(2) 随机森林在特征选择方面有什么优势?

② **特征选择方面的优势**

1. **减少过拟合.** 由于每棵树在训练时只使用了部分特征(通过特征子集选择),随机森林能够减少模型对特定特征的依赖,从而降低过拟合的风险.
2. **能处理大量数据.** 随机森林能处理大量特征,并且在特征子集选择过程中,不显著增加计算复杂度.

四、

对一维模式的两分类问题,设两类模式均为正态分布,其均值和方差分别为

$$\mu_1 = 0, \sigma_1^2 = 4; \quad \mu_2 = 2, \sigma_2^2 = 4$$

采用(0-1)损失函数,且 $P(\omega_1) = eP(\omega_2)$,这里 e 是自然对数的底数.

(1) 试大致绘出两类模式的密度函数曲线.

(2) 试写出基于自然对数的对数似然比的最小风险贝叶斯决策规则,计算基于 x 的判决阈值与规则.

(3) 判断两个样本: $x_1 = 2, x_2 = 4$, 分别属于哪一类.

五、

已知两类训练样本为

$$\omega_1: X_1 = [0, 0]^T, X_2 = [0, 1]^T; \quad \omega_2: X_3 = [1, 0]^T, X_4 = [1, 1]^T$$

设增广权矢量初值为 $W(1) = [0, 1, 1]^T$, 用感知器算法求解判别函数, 并绘出判别界面.

六、

有四个二维模式向量构成的样本集:

$$X_1 = [1, -1]^T, X_2 = [3, 3]^T, X_3 = [-1, 1]^T, X_4 = [-3, -3]^T$$

(1) 求该样本集的均值向量和协方差矩阵.

(2) 求出协方差矩阵的全部特征值及对应的特征向量, 并在图中标示出第一主元方向.

七、

设有 9 个一维模式样本: $X_1 = 0, X_2 = 1, X_3 = 2, X_4 = 6, X_5 = 7, X_6 = 8, X_7 = 10, X_8 = 11, X_9 = 12$, 分别在下面两种参数条件下, 用最大最小距离法对这些样本进行聚类分析.

(1) $Z_1 = X_1, \theta = 0.4$

(2) $Z_1 = X_3, \theta = 0.6$

八、

假设你正在为一家金融公司开发一个客户分类系统, 以预测客户是否会违约. 数据集包含以下字段:

- customer_id: 客户 ID
- age: 客户年龄
- income: 年收入
- loan_amount: 贷款金额
- loan_term: 贷款期限 (年)
- credit_score: 信用评分
- default: 是否违约 (0: 否, 1: 是)

公司希望你开发一个机器学习模型, 根据客户的这些特征来预测客户是否会违约. 试回答一下问题:

a. 根据上述数据, 你需要对数据进行哪些预处理步骤? 列出至少三个步骤并简述其原因.

1. 数据清理:

1. **缺失值处理:** 检查数据集中是否有缺失值, 并处理; 使用均值、中位数或其他方法填补缺失值.
2. **异常值处理:** 检测并处理异常值, 对于一些明显错误的值需要处理.

2. **数据标准化/归一化:** 将收入、贷款金额、贷款期限和信用评分等数值特征标准化或归一化到同一尺度, 以确保不同特征在模型训练过程中具有相似的影响范围.

3. 特征工程:

1. **特征选择:** 根据数据的相关性和特征重要性, 选择对违约预测最有帮助的特征.
2. **特征转换:** 将特征转换为分类变量, 或创建新的特征.

b. 针对分类问题,常见的机器学习模型有哪些? 请列出两种,并简述它们的基本原理.

- **逻辑回归**: 通过学习输入特征线性组合,使用逻辑函数将线性组合的结果映射到 0 和 1 之间的概率值,用于预测某个样本属于某类的概率.
- **随机森林**: 构建多个决策树,在预测时综合这些树的结果来提高模型的准确性和稳定性.每棵树都是在随机子集上训练的,并且每次分裂时只考虑随机一部分特征,从而减少过拟合的风险.

c. 你会选择哪些评估指标来评估分类模型的效果? 列出两种并解释其含义.

- **准确率**: 正确预测样本占样本总量比例. $Acc = \frac{TP + TN}{TP + TN + FP + FN}$

解答四

已知条件:

- 类 ω_1 : $\mu_1 = 0, \sigma_1^2 = 4$ (即 $\sigma_1 = 2$)
- 类 ω_2 : $\mu_2 = 2, \sigma_2^2 = 4$ (即 $\sigma_2 = 2$)
- 先验概率关系: $P(\omega_1) = eP(\omega_2)$
- 损失函数: (0-1) 损失

(1) 试大致绘出两类模式的密度函数曲线

正态分布的概率密度函数通式为:

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{(x-\mu_i)^2}{2\sigma_i^2}\right)$$

代入题目参数:

- 对于 ω_1 :

$$p(x|\omega_1) = \frac{1}{\sqrt{8\pi}} \exp\left(-\frac{x^2}{8}\right)$$

这是一个中心在 $x = 0$, 峰值高度为 $\frac{1}{\sqrt{8\pi}}$ 的钟形曲线.

- 对于 ω_2 :

$$p(x|\omega_2) = \frac{1}{\sqrt{8\pi}} \exp\left(-\frac{(x-2)^2}{8}\right)$$

这是一个中心在 $x = 2$, 峰值高度同为 $\frac{1}{\sqrt{8\pi}}$ 的钟形曲线.

绘图说明: 两条曲线形状完全相同 (因为方差相等), 只是位置发生了平移.

- $p(x|\omega_1)$ 的对称轴是 $x = 0$.
- $p(x|\omega_2)$ 的对称轴是 $x = 2$.

(2) 试写出基于自然对数的对数似然比的最小风险贝叶斯决策规则, 计算基于 x 的判决阈值与规则

1. 贝叶斯决策规则 在 (0-1) 损失函数下, 最小风险贝叶斯决策等价于最大后验概率决策. 决策规则为: 若 $P(\omega_1 | x) > P(\omega_2 | x)$, 则判为 ω_1 类; 否则判为 ω_2 类.

根据贝叶斯公式, 上述规则等价于比较似然与先验的乘积: 若 $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$, 则判为 ω_1 .

2. 引入对数似然比 将不等式变形为似然比的形式：

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$$

两边取自然对数：

$$\ln\left(\frac{p(x|\omega_1)}{p(x|\omega_2)}\right) > \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

3. 代入数值计算

• 右边（阈值项）：已知 $P(\omega_1) = eP(\omega_2)$, 即 $\frac{P(\omega_2)}{P(\omega_1)} = \frac{1}{e}$. 所以, $\ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right) = \ln(e^{-1}) = -1$.

• 左边（对数似然比）：

$$\ln\left(\frac{p(x|\omega_1)}{p(x|\omega_2)}\right) = \ln(p(x|\omega_1)) - \ln(p(x|\omega_2))$$

代入密度函数公式（注意系数 $\frac{1}{\sqrt{8\pi}}$ 相同, 相除为 1, 取对数为 0）：

$$\begin{aligned} &= \left(-\frac{x^2}{8}\right) - \left(-\frac{(x-2)^2}{8}\right) \\ &= \frac{(x-2)^2 - x^2}{8} \\ &= \frac{(x^2 - 4x + 4) - x^2}{8} \\ &= \frac{-4x + 4}{8} \\ &= \frac{1 - x}{2} \end{aligned}$$

4. 综合不等式 将左右两边代回决策不等式：

$$\frac{1-x}{2} > -1$$

$$1-x > -2$$

$$-x > -3$$

$$x < 3$$

结论：

• 判决阈值： $x_0 = 3$

• 决策规则：

- 若 $x < 3$, 则判为 ω_1 类；
- 若 $x > 3$, 则判为 ω_2 类。

(3) 判断两个样本： $x_1 = 2, x_2 = 4$, 分别属于哪一类

根据第 (2) 问得出的决策规则（ $x < 3$ 为 ω_1 , $x > 3$ 为 ω_2 ）：

1. 对于样本 $x_1 = 2$: 因为 $2 < 3$, 满足 ω_1 的条件. 所以 x_1 属于 ω_1 类.
2. 对于样本 $x_2 = 4$: 因为 $4 > 3$, 满足 ω_2 的条件. 所以 x_2 属于 ω_2 类.

解答五

已知两类训练样本为:

$$\omega_1 : X_1 = [0, 0]^T, \quad X_2 = [0, 1]^T$$

$$\omega_2 : X_3 = [1, 0]^T, \quad X_4 = [1, 1]^T$$

设增广权矢量初值为 $W(1) = [0, 1, 1]^T$, 用感知器算法求解判别函数, 并绘出判别界面.

1. 样本增广与规范化

首先将样本向量增广 (末尾加 1), 并将属于 ω_2 类的样本乘以 -1 进行规范化, 使得所有样本期望满足 $W^T X > 0$.

- ω_1 类样本 (保持不变):
 - $X_1 = [0, 0, 1]^T$
 - $X_2 = [0, 1, 1]^T$
- ω_2 类样本 (乘以 -1):
 - $X_{3'} = -[1, 0, 1]^T = [-1, 0, -1]^T$
 - $X_{4'} = -[1, 1, 1]^T = [-1, -1, -1]^T$

2. 感知器算法迭代过程

设定初始权向量 $W(1) = [0, 1, 1]^T$, 学习率 $\rho = 1$.

第 1 轮迭代:

- $W(1)^T X_1 = 1 > 0$ (正确) $\rightarrow W(2) = W(1)$
- $W(2)^T X_2 = 2 > 0$ (正确) $\rightarrow W(3) = W(2)$
- $W(3)^T X_{3'} = -1 \leq 0$ (错误) $\rightarrow W(4) = W(3) + X_{3'} = [-1, 1, 0]^T$
- $W(4)^T X_{4'} = 0 \leq 0$ (错误) $\rightarrow W(5) = W(4) + X_{4'} = [-2, 0, -1]^T$

第 2 轮迭代:

- $W(5)^T X_1 = -1 \leq 0$ (错误) $\rightarrow W(6) = W(5) + X_1 = [-2, 0, 0]^T$
- $W(6)^T X_2 = 0 \leq 0$ (错误) $\rightarrow W(7) = W(6) + X_2 = [-2, 1, 1]^T$
- $W(7)^T X_{3'} = 1 > 0$ (正确) $\rightarrow W(8) = W(7)$
- $W(8)^T X_{4'} = 0 \leq 0$ (错误) $\rightarrow W(9) = W(8) + X_{4'} = [-3, 0, 0]^T$

第 3 轮迭代:

- $W(9)^T X_1 = 0 \leq 0$ (错误) $\rightarrow W(10) = W(9) + X_1 = [-3, 0, 1]^T$
- $W(10)^T X_2 = 1 > 0$ (正确) $\rightarrow W(11) = W(10)$
- $W(11)^T X_{3'} = 2 > 0$ (正确) $\rightarrow W(12) = W(11)$
- $W(12)^T X_{4'} = 2 > 0$ (正确) $\rightarrow W(13) = W(12)$

第 4 轮迭代:

- $W(13)^T X_1 = 1 > 0$ (正确)
- $W(13)^T X_2 = 1 > 0$ (正确)
- $W(13)^T X_{3'} = 2 > 0$ (正确)
- $W(13)^T X_{4'} = 2 > 0$ (正确)

所有样本分类正确, 算法收敛.

3. 最终结果

最终权向量: $W = [-3, 0, 1]^T$

判别函数: 设原始输入向量为 $x = [x_1, x_2]^T$, 增广后为 $X = [x_1, x_2, 1]^T$. $d(x) = W^T X = [-3, 0, 1] [x_1, x_2, 1]^T = -3x_1 + 1$

判别界面: 令 $d(x) = 0$, 即: $-3x_1 + 1 = 0$ implies $x_1 = 1/3$

判别界面图示说明: 判别界面是一条垂直于 x_1 轴 (横轴) 的直线, 位置在 $x_1 = \frac{1}{3}$ 处.

- 当 $x_1 < \frac{1}{3}$ 时 (如 $x_1 = 0$), $d(x) > 0$, 判为 ω_1 类.
- 当 $x_1 > \frac{1}{3}$ 时 (如 $x_1 = 1$), $d(x) < 0$, 判为 ω_2 类.

解答六、主成分分析计算

已知四个二维模式向量构成的样本集:

$$X_1 = [1, -1]^T, \quad X_2 = [3, 3]^T, \quad X_3 = [-1, 1]^T, \quad X_4 = [-3, -3]^T$$

(1) 求该样本集的均值向量和协方差矩阵

1. 均值向量 M

样本集包含 4 个向量, 均值向量 M 为所有样本向量的平均值:

$$M = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{4} (X_1 + X_2 + X_3 + X_4)$$

$$M = \frac{1}{4} \begin{pmatrix} 1+3-1-3 \\ -1+3+1-3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

均值向量 $M = [0, 0]^T$.

2. 协方差矩阵 Σ

根据样本协方差矩阵公式 (分母为 $n-1$):

$$\Sigma = \frac{1}{n-1} \sum_{i=1}^n (X_i - M)(X_i - M)^T$$

这里 $n = 4$, 所以分母为 3. 由于 $M = [0, 0]^T$, 则 $X_i - M = X_i$.

分别计算每一项 $(X_i - M)(X_i - M)^T$:

- $i = 1$:

$$[1, -1]^T [1, -1] = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

- $i = 2$:

$$[3, 3]^T [3, 3] = \begin{pmatrix} 9 & 9 \\ 9 & 9 \end{pmatrix}$$

- $i = 3$:

$$[-1, 1]^T [-1, 1] = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

- $i = 4$:

$$[-3, -3]^T [-3, -3] = \begin{pmatrix} 9 & 9 \\ 9 & 9 \end{pmatrix}$$

求和：

$$\Sigma = \begin{pmatrix} 1+9+1+9 & -1+9-1+9 \\ -1+9-1+9 & 1+9+1+9 \end{pmatrix} = \begin{pmatrix} 20 & 16 \\ 16 & 20 \end{pmatrix}$$

计算协方差矩阵：

$$\Sigma = \frac{1}{3} \begin{pmatrix} 20 & 16 \\ 16 & 20 \end{pmatrix} = \begin{pmatrix} \frac{20}{3} & \frac{16}{3} \\ \frac{16}{3} & \frac{20}{3} \end{pmatrix} \approx \begin{pmatrix} 6.67 & 5.33 \\ 5.33 & 6.67 \end{pmatrix}$$

(2) 求出协方差矩阵的全部特征值及对应的特征向量,并在图中标示出第一主元方向

1. 求特征值

设协方差矩阵为 $A = \begin{pmatrix} \frac{20}{3} & \frac{16}{3} \\ \frac{16}{3} & \frac{20}{3} \end{pmatrix}$.

特征方程为 $\det(\lambda E - A) = 0$:

$$\det \left(\begin{pmatrix} \lambda - \frac{20}{3} & -\frac{16}{3} \\ -\frac{16}{3} & \lambda - \frac{20}{3} \end{pmatrix} \right) = 0$$

$$\left(\lambda - \frac{20}{3} \right)^2 - \left(-\frac{16}{3} \right)^2 = 0$$

$$\left(\lambda - \frac{20}{3} \right)^2 = \left(\frac{16}{3} \right)^2$$

$$\lambda - \frac{20}{3} = \pm \frac{16}{3}$$

解得两个特征值：

- $\lambda_1 = \frac{20}{3} + \frac{16}{3} = \frac{36}{3} = 12$
- $\lambda_2 = \frac{20}{3} - \frac{16}{3} = \frac{4}{3}$

2. 求特征向量

对于特征值 $\lambda_1 = 12$:

代入 $(A - \lambda_1 E)v = 0$:

$$\begin{pmatrix} \frac{20}{3} - 12 & \frac{16}{3} \\ \frac{16}{3} & \frac{20}{3} - 12 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} -\frac{16}{3} & \frac{16}{3} \\ \frac{16}{3} & -\frac{16}{3} \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

化简得 $-v_1 + v_2 = 0 \rightarrow v_1 = v_2$.

取特征向量 $V_1 = [1, 1]^T$.

对于特征值 $\lambda_2 = \frac{4}{3}$:

代入 $(A - \lambda_2 E)v = 0$:

$$\begin{pmatrix} \frac{20}{3} - \frac{4}{3} & \frac{16}{3} \\ \frac{16}{3} & \frac{20}{3} - \frac{4}{3} \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} \frac{16}{3} & \frac{16}{3} \\ \frac{16}{3} & \frac{16}{3} \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

化简得 $v_1 + v_2 = 0 \rightarrow v_1 = -v_2$.

取特征向量 $V_2 = [1, -1]^T$ (或 $[-1, 1]^T$).

3. 第一主元方向

第一主元方向对应于**最大特征值**的特征向量.

最大特征值为 $\lambda_1 = 12$, 对应的特征向量为 $V_1 = [1, 1]^T$.

七、

设有 9 个一维模式样本: $X_1 = 0, X_2 = 1, X_3 = 2, X_4 = 6, X_5 = 7, X_6 = 8, X_7 = 10, X_8 = 11, X_9 = 12$, 分别在下面两种参数条件下, 用最大最小距离法对这些样本进行聚类分析.

(1) $Z_1 = X_1, \theta = 0.4$

$$Z_1 = X_1 \quad \theta = 0.4 \quad Z_2 = X_9 \quad \theta = 0.4 \quad d(Z_1, Z_2) = 12 \quad \theta * d(Z_1, Z_2) = 12 * 0.4 = 4.8$$

$$d_{21} = 1 \quad d_{22} = 11 \quad d_2 = \min(1, 11) = 1$$

$$d_{31} = 2 \quad d_{32} = 10 \quad d_3 = \min(2, 10) = 2$$

$$d_{41} = 6 \quad d_{42} = 6 \quad d_4 = \min(6, 6) = 6 > 4.8$$

$$d_{51} = 7 \quad d_{52} = 5 \quad d_5 = \min(7, 5) = 5 > 4.8$$

$$d_{61} = 8 \quad d_{62} = 4 \quad d_6 = \min(8, 4) = 4$$

则建立第 3 个聚类中心 $Z_3 = X_4 = 6$.

$$d_{21} = 1 \quad d_{22} = 11 \quad d_{23} = 5 \quad d_2 = \min = 1$$

$$d_{31} = 2 \quad d_{32} = 10 \quad d_{33} = 4 \quad d_3 = \min = 2$$

$$d_{51} = 7 \quad d_{52} = 5 \quad d_{53} = 1 \quad d_5 = \min = 1$$

$$d_{61} = 8 \quad d_{62} = 4 \quad d_{63} = 2 \quad d_6 = \min = 2$$

$$d_{71} = 10 \quad d_{72} = 2 \quad d_{73} = 4 \quad d_7 = \min = 2$$

$$d_{81} = 11 \quad d_{82} = 1 \quad d_{83} = 5 \quad d_8 = \min = 1$$

属于 X_1 类 X_1, X_2, X_3, Z_1

属于 X_4 类 X_4, X_5, X_6, Z_3

属于 X_9 类 X_7, X_8, X_9, Z_2

(2) $Z_1 = X_3, Z_2 = X_9$

				$d_{11} = 2$	$d_{12} = 12$	$d_1 = \min = 2$
				$d_{21} = 1$	$d_{22} = 10$	$d_2 = \min = 1$
$Z_1 = X_3$	$Z_2 = X_9$	$d(Z_1, Z_2) = 10$	$\theta * d = 6$	$d_{41} = 4$	$d_{42} = 6$	$d_4 = \min = 4$
				$d_{51} = 5$	$d_{52} = 5$	$d_5 = \min = 5$
				$d_{61} = 6$	$d_{62} = 4$	$d_6 = \min = 4$

因此分为 2 类.

1, 2, 3, 4, 5 一类

6, 7, 8, 9 二类