



武汉大学
WUHAN UNIVERSITY

第1讲 概论

2025~2026学年第2学期

《机器学习》



- 了解机器学习的**基本原理**;
- 掌握典型监督、无监督、半监督机器学习**方法**, 了解并会用常见的机器视觉、Transformer和生成式AI模型;
- 掌握Python语言以及机器学习相关的**软件工具**, 熟悉PyTorch环境, 结合示例代码, 能用Scikit-learn等实现机器学习核心算法, 了解其中主要函数的使用方式和参数含义。



[01] 周志华，机器学习，清华版 俗称西瓜书，概念讲解清晰，有配套公式推导南瓜书

[02] 张学工、汪小我，模式识别与机器学习，清华大学出版社

[03] 李航，机器学习方法，清华版 经典教材《统计学习方法》升级版，推导较完整

[04] 邱锡鹏，神经网络与深度学习，机械工业出版社

[05] 伊藤真，用Python动手学机器学习，人民邮电出版社

[06] Raschka, Python机器学习(第2版)，机械工业出版社

含Python语言与ML工具包，课程组推荐使用的实验参考书

[07] 陈雷，深度学习与MindSpore实践，清华出版社

武大-华为合作推荐使用的实验参考书





数智教育实践创新平台

<https://aipractice.whu.edu.cn/>

武汉大学 数智教育实践创新平台

人工智能与机器学习B

全校《人工智能与机器学习》课程总体介绍

课程介绍

- 全校《人工智能与机器学习》... PDF | 5.37 MB
- 武汉大学课程教学大纲_人工智... PDF | 321.22 KB
- 人工智能与机器学习-课程宣传片 视频 | 00:08:13
- 2022级导航...
- 第一章 概论
 - 机器学习第一章 概论 (2024号... PDF | 8.63 MB
 - 代码练习: 张量的数据结构 Notebook
 - 代码练习: 张量的结构操作 Notebook
 - 代码练习: 张量的数学运算 Notebook
 - 代码练习: Dataset和DataLoader Notebook
 - 代码练习: 张量的计算 (KN... Notebook
 - 课程回放1: 机器学习用来干什么 视频 | 00:24:15

人工智能与机器学习

ARTIFICIAL INTELLIGENCE AND MACHINE LEARNING

跨学院公共基础必修课

指导教师: 郭 迟 教授 时间: 2024年6月

1010101 数智教育

武汉大学



B站

1. 李宏毅/机器学习+深度学习 （课程内容较新）

https://www.bilibili.com/video/BV1Wv411h7kN?from=search&seid=7997099282085963555&spm_id_from=333.337.0.0

https://www.bilibili.com/video/BV1JE411g7XF?from=search&seid=7997099282085963555&spm_id_from=333.337.0.0

2. 吴恩达/机器学习 （经典课程）

https://www.bilibili.com/video/BV164411b7dx?from=search&seid=7997099282085963555&spm_id_from=333.337.0.0

3. 邱锡鹏/机器学习与神经网络 （内容全面，有配套的教材）

https://www.bilibili.com/video/BV1P3411u7c1/?spm_id_from=333.337.search-card.all.click



慕课网

1. 机器学习 浙江大学 胡浩基（慕课中较高点击量）

<https://www.icourse163.org/course/ZJU-1206573810?from=searchPage>

2. Python机器学习应用 北理工 礼欣（用Python实现简单的机器学习算法）

<https://www.icourse163.org/course/BIT-1001872001?from=searchPage>

开源资源

1. 如何学习机器学习的完整指南（英文资源）

<https://github.com/louisfb01/start-machine-learning>

2. 机器学习资源中文版

<https://github.com/jobbole/awesome-machine-learning-cn>

3. 西瓜书学习笔记

<https://github.com/Vay-keen/Machine-learning-learning-notes>

4. 用Python实现机器学习算法

https://github.com/lawlite19/MachineLearning_Python




项目	次数	比例
考勤+平时作业	3	10%
实验（希冀平台）	4	40%
期末考试（开卷）	1	50%

希冀平台: <https://cslabcg.whu.edu.cn/>



2026上机器学习弘毅班



扫一扫二维码，加入群聊





武汉大学
WUHAN UNIVERSITY

01 机器学习用来干什么

02 机器学习的基本概念

03 机器学习技术与系统的种类

04 机器学习的发展和趋势



武汉大学
WUHAN UNIVERSITY

01机器学习用来干什么

What is machine learning used for

1 模式识别 (Pattern Recognition, PR)


非洲产、黑白纹、似雁叫、食青草。（打一动物）

产地

外形

声音

饮食喜好






➤ 模式识别（再认识）是指从**样本**数据中提取特定模式（模板或原型）（pattern），根据样本特征进行分类、回归、聚类和预测的过程。这里的“模式”可以理解为数据中的某种规律性结构或特征（feature），是对某类事物的抽象。

模式识别的一般步骤：


1. 特征提取：将数据转换为数值特征，用以描述数据的基本属性。例如，在图像识别中提取图像的颜色、亮度、纹理等特征；
2. 模型构建：根据特征选择合适的方法，对数据进行分类、聚类、预测；
3. 模型评估：对模型的准确性、鲁棒性、泛化性等进行评估，并反馈到模型构建中进行调整和优化。

分类问题 (Classification)





回归问题 (Regression)

Global Ionosphere Map 2019-11-29 00:00:00



聚类问题 (Clustering)





遥感影像聚类

2 特征提取 (Feature extraction)

- 在 d 维样本中提取 k 个维的新集合，这 k 个维是原来 d 个维的组合，用以表征原来 d 维样本。
一般 $d \gg k$ ，这一过程也称为维度归约或降维

维度归约问题 (Dimensionality Reduction)




3 数据生成 (Data generation)

- 对于由 m 个样本 $\{x_1, x_2, \dots, x_m\}$ 构成的集合（如 m 个人脸图像），假设它们是彼此独立且都源于某个未知的概率分布 $q(X)$ (**i.i.d**)，如何在不知道 $q(X)$ 的情况下构建模型使其也能产生和 $\{x_1, x_2, \dots, x_m\}$ 相似的样本

生成模型 (Generative model)

- 常见的生成模型有：生成对抗网络 (GAN)、变分自编码器 (VAE)、玻尔兹曼机 (Boltzman Machine) 和Diffusion扩散模型等
- 常见的生成模型具有**编码器** (Encoder) - **解码器** (Decoder) 结构



3 数据生成 (Data generation)

- 对于由 m 个样本 $\{x_1, x_2, \dots, x_m\}$ 构成的集合（如 m 个人脸图像），假设它们是彼此独立且都源于某个未知的概率分布 $q(X)$ ，如何在不知道 $q(X)$ 的情况下构建模型使其也能产生和 $\{x_1, x_2, \dots, x_m\}$ 相似的样本

生成模型 (Generative model)



3 数据生成 (Data generation)

- 对于由 m 个样本 $\{x_1, x_2, \dots, x_m\}$ 构成的集合（如 m 个人脸图像），假设它们是彼此独立且都源于某个未知的概率分布 $q(X)$ ，如何在不知道 $q(X)$ 的情况下构建模型使其也能产生和 $\{x_1, x_2, \dots, x_m\}$ 相似的样本

生成模型 (Generative model)



3 数据生成 (Data generation)

- 对于由 m 个样本 $\{x_1, x_2, \dots, x_m\}$ 构成的集合（如 m 个人脸图像），假设它们是彼此独立且都源于某个未知的概率分布 $q(X)$ ，如何在不知道 $q(X)$ 的情况下构建模型使其也能产生和 $\{x_1, x_2, \dots, x_m\}$ 相似的样本

生成模型 (Generative model)



扩散模型 (Diffusion models)



SORA@2024

扩散模型 (Diffusion models)



4 机器学习 (Machine Learning, ML)

- 模式识别发展到深度学习：传统模式识别是通过给定的各种特征来训练机器，从而让机器对未见过的样本进行识别预测；深度学习更强调将某一事物的海量样本输入机器，让机器通过样本来自己发现特征，预测未知的事物以及生成新的样本

机器学习的定义：

"the field of study that gives computers the ability to learn without being explicitly programmed."

(使计算机能够在没有明确编程情况下具有学习能力的领域)



机器学习先驱

Arthur Samuel (1901-1990)



"A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E ."

(一个计算机程序，从经验 E 中学习关于某一类任务 T 和性能度量 P 的知识，如果它在 T 中的性能如 P 所度量那样，随着经验 E 的提高而提高)



卡耐基梅隆大学教授

Tom M. Mitchell




南京大学教授

周志华

“机器学习是一门学科，致力于研究如何通过计算的手段，利用经验来改善系统自身的性能。在计算机系统中，“经验”通常以“数据”形式存在，机器学习研究的主要内容是在计算机上**从数据中产生“模型 (model)”**”

5 人工智能 (Artificial Intelligence, AI)

- 人工智能是用于模拟、延伸和扩展人的智能的理论、方法、技术及应用的一门新的技术科学





武汉大学
WUHAN UNIVERSITY

02 机器学习的基本概念

Basic concepts of machine learning



- **机器学习**是关于让机器更好地处理某些以前需要人工才能完成的任务的技术与理论，它主要**从数据中学习**，侧重**建立基于相关关系或协变关系的预测模型**，不寻求建立关于物理机制或因果关系的解释模型。
- 机器学习算法具有一定的**自我更新和环境适应性**，其中的模型参数和判断规则，可以根据确定的最优性目标进行调整。
- 机器学习主要为其他数据应用系统提供**能力部件**，不仅能提升原有数据的应用效能，还有可能发现数据中以前没有观察到的**新结构或新模式**。




机器学习学什么？


**学习 代表性数据 中的 感兴趣量与可观测量
之间有意义的结构和关系，以便用于预测**

- 如果我下载一份维基百科的全部内容副本到我的电脑上，我的电脑能学到什么？ 会变得更聪明吗？
- 在开始探索机器学习新大陆之前，先来看看地图，了解一下主要地区和显著地标：
 - **有监督学习与无监督学习**
 - **在线学习与批量学习**
 - **基于实例的学习与基于模型的学习**
- 机器学习与传统编程技术有什么不同？

- 使用**传统编程技术**编制垃圾邮件过滤软件
 - 先看看垃圾邮件通常长什么样。可能会注意到某些单词或用语（比如“信用卡”“免费”等字眼）在这类邮件中出现频率非常高
 - 为发现的每个模式编写检测算法，如果检测到一定数量的模式，程序会将其标记为垃圾邮件
 - 测试这个程序，不断重复前两个步骤，直到它变得足够好





- 基于机器学习技术的邮件过滤器能自动地注意到“免费”“For U”等单词，在用户标记的垃圾邮件中出现得异常频繁，无需人工干预，软件会自动标记这些特征词汇




机器学习技术编制的垃圾邮件过滤器能自动识别频繁出现的单词，自动升级特征数据和判断规则，提升算法的识别能力

- 机器学习还可以**帮助人类学习**：例如，一旦垃圾邮件过滤器经过了足够多的训练，就可以查看软件认定的、可以作为垃圾邮件**最佳预测因子**的单词及其组合。有时，这可能会揭示出一些人们以前未曾意识到的**关联性**或**新趋势**，从而帮助我们**更好地理解问题**





- **学习**：机器学习算法拟合训练数据，得到预测模型
- **预测**：根据预测模型，对新数据的响应变量做预测






- 对于那些现有解决方案需要大量手动调整或者是规则列表超长的
问题：通过机器学习算法可以**简化**代码，提升执行表现
- 对于传统技术手段无法解决的**复杂问题**：通过机器学习技术一般可以找到一个更好的解决方案（分类识别类，博弈类）
- 对于环境波动和迁移：机器学习技术可以**适应**新的数据
- 对于数据分析与挖掘：机器学习技术能从**海量数据**中获得新的洞见

1 样本空间与标记空间

- 一组描述客体性质的变量，称为**特征变量**（feature）。变量的个数 d 称为**特征维度**，特征变量组成的向量称为**特征向量**，变量张成的空间称为**特征空间**，变量的取值称为**属性值**





- 每个对象**实例**（**样本**）可由一个特征向量表征，记为 $\mathbf{x}_i$ 。**样本空间**是所有可能存在的、合理的样本的集合，记为 X 。每个 $\mathbf{x}_i$ 均定义在 d 维特征空间中，其每个维度对应于一种特征：

$$\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{id} \end{pmatrix} = (x_{i1}, \dots, x_{id})^T$$

- 与样本空间对应，样本的分类标签或预测取值的集合称为**标记空间**，记为 Y 。比如一个经典的二分类问题， $Y=\{-1, 1\}$ 或 $Y=\{0, 1\}$ 。在回归问题中，响应变量通常为实数值，则标记空间定义为响应变量的连续取值区间

注：多响应变量（多元输出回归）与多变量回归（多元回归）的区别

- 对于 $k(k \geq 2)$ 分类问题，也经常将标记值定义为一个 k 维向量，称为**独热编码 (one-hot Encoding)**，其中各分量下标与所在类别序号一致的置1，其余置0，如：

$$\mathbf{y}_i = \begin{pmatrix} y_{i1} \\ \vdots \\ y_{ik} \end{pmatrix} = (y_{i1}, \dots, y_{ik})^T$$



如一个识别手写0-9数字的分类任务，样本和其标记值举例如下：

x_i	y_i	x_i	y_i
0	$(1,0,0,0,0,0,0,0,0,0)^T$	5	$(0,0,0,0,0,1,0,0,0,0)^T$
1	$(0,1,0,0,0,0,0,0,0,0)^T$	6	$(0,0,0,0,0,0,1,0,0,0)^T$
2	$(0,0,1,0,0,0,0,0,0,0)^T$	7	$(0,0,0,0,0,0,0,1,0,0)^T$
3	$(0,0,0,1,0,0,0,0,0,0)^T$	8	$(0,0,0,0,0,0,0,0,1,0)^T$
4	$(0,0,0,0,1,0,0,0,0,0)^T$	9	$(0,0,0,0,0,0,0,0,0,1)^T$

2 数据集 (Data set)

- 一个拥有 m 个样本的训练集可以记为：

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$$

其中, $x_i \in X$, $y_i \in Y$

- 在机器学习中，数据集合一般被划分为训练集（Training Set）、验证集（Validation Set）和测试集（Test Set），各自扮演着不同的角色，以确保模型具有良好的泛化能力和性能

训练集	验证集	测试集
用于模型训练 降低经验误差	验证模型正确性调节 超参数	评估泛化性能

3 张量 (Tensor)

- 在计算机科学中，**张量**是一个非常重要的数据结构，用于存储和操作多维样本。一个实数可以被视为0阶张量，一个向量可以视为1阶张量，一个矩阵可以视为2阶张量...一个 $n+1$ 阶的张量可以通过对 n 阶张量增加1个索引来扩展得到




1阶张量¹

3元素1阶张量:

↗ $[f_1, f_2, f_3]$

3个元素

每个元素是1个0阶张量



2阶张量²

2×3的2阶张量:

↗ $[[f_{11}, f_{12}, f_{13}], [f_{21}, f_{22}, f_{23}]]$

2个元素

每个元素是1个1阶张量



3阶张量³

3×2×3的3阶张量:



↗ $[[[r_{11}, r_{12}, r_{13}], [r_{21}, r_{22}, r_{23}]],$

$[[g_{11}, g_{12}, g_{13}], [g_{21}, g_{22}, g_{23}]],$

$[[b_{11}, gb_{12}, gb_{13}], [b_{21}, b_{22}, b_{23}]]]$

3个元素

每个元素是1个2阶张量

4阶张量⁴5阶张量⁵6阶张量⁶

- 通过高效的**张量运算库**（如PyTorch、TensorFlow、NumPy等），我们可以快速地构建和训练复杂的机器学习模型



在pytorch里定义张量：

```
import torch
# 1阶张量（向量）
tensor_1d = torch.tensor([1, 2, 3, 4, 5])
print("1阶张量:")
print(tensor_1d, ", shape:", tensor_1d.shape)
```

```
shape: torch.Size([5])
```



2阶张量 (矩阵)

```
tensor_2d = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

```
print("\n2阶张量:")
```

```
print(tensor_2d, "shape:", tensor_2d.shape)
```

```
shape: torch.Size([3, 3])
```

3阶张量

```
tensor_3d = torch.tensor([[[1, 2, 3], [4, 5, 6], [7, 8, 9]],  
                           [[10, 11, 12], [13, 14, 15], [16, 17, 18]]])
```

```
print("\n3阶张量:")
```

```
print(tensor_3d, "shape:", tensor_3d.shape)
```

```
shape: torch.Size([2, 3, 3])
```

4阶张量

```
tensor_4d = torch.tensor([[[[1, 2], [3, 4]], [[5, 6], [7, 8]]],  
                           [[[9, 10], [11, 12]], [[13, 14], [15, 16]]]])
```

```
print("\n4阶张量:")
```

```
print(tensor_4d, "shape:", tensor_4d.shape)
```

```
shape: torch.Size([2, 2, 2, 2])
```


 在pytorch里翻转一个张量（3通道彩色图像）：

```
import torch
from torchvision import transforms
from PIL import Image
# 定义图像变换
transform = transforms.ToTensor() # 转换图像到 Tensor

# 读取图像
image_path = 'library.jpg' # 武汉大学老图书馆经典照片
image = Image.open(image_path).convert('RGB')

# 应用变换
image_tensor = transform(image)

# 打印图像张量的大小
print("原始图像张量大小:")
print(image_tensor.size()) # 图像张量大小[3, 224, 224]

# 水平翻转
flipped_horizontal = torch.flip(image_tensor, [2])

# 垂直翻转
flipped_vertical = torch.flip(image_tensor, [1])
```

将张量转换回 PIL 图像以便保存

```
to_pil_image = transforms.ToPILImage()
```

水平翻转图像

```
flipped_horizontal_image = to_pil_image(flipped_horizontal)
```

```
flipped_horizontal_image.save('f_horizontal_image.jpg')
```

垂直翻转图像

```
flipped_vertical_image = to_pil_image(flipped_vertical)
```

```
flipped_vertical_image.save('f_vertical_image.jpg')
```



library.jpg



f_horizontal_image.jpg




f_vertical_image.jpg

4 假设空间 (H) 与模型

- 机器学习通过数据集训练，构成一个典型的归纳推理过程。学习的结果是得到或逼近样本空间 X 到标记空间 Y 的映射 $f: X \rightarrow Y$ ，或条件概率分布 $P(Y|X)$ 。所有可能解的集合称为假设空间 H (hypothesis)。这些假设都会基于一个机器学习模型 (model) 来表示，所以一般也把假设=模型




i.e. 二维平面内的线性假设空间(即直线条数)为 ∞ 。我们在分类二维平面中的点时，选择线性假设，即认为可以在二维平面上画一条直线，将平面中的点分为正例与负例






自行阅读该例子：西瓜问题-假设色泽、根蒂和敲声完全决定西瓜的品质，用布尔表达式表达好瓜的概念，建立一个树状的假设空间



- A 表示学习器 (Learner), f 表示目标假设 (可以是一个函数, 也可以是一个分布), H 表示假设空间, g 表示我们学习到的用来预测的假设, g 是属于 H 的。机器学习的过程又可以理解为: 通过学习器 A , 在假设空间 H 中, 根据训练样例集合 D , 选择最好的假设 g 使 g 近似于 f







为什么要用学习的方式得到 g


1. $g(x) : y = kx$ 直线假设

2. $g(x) : y = ax^k + bx^p + \dots + cx^l$
多项式假设

3. $g(x) :$ 
分段 (树状) 假设

4. $g(x) :$  神经网络形态
的非线性假设

...




$f: X \rightarrow Y$ 不易被解析式表达

?

- 从样本数据中学习的 $g(x)$, $g(x)$ 的表现形式根据不同的假设表现为不同形式
- 确定模型后, $g(x)$ 将由一组参数 w 决定的, 学习 $g(x, w)$ 就是学习这组参数 w



不同学习器学习到的 g 各不相同（参数不同）



→第四讲 《线性模型》



5 选择模型的策略

➤ 策略 (strategy) 也称为学习准则

1. 经验风险最小化 (empirical risk minimization-ERM) 准则:

是机器学习里最常用的准则, 即在训练样本上取得最小的经验误差, 是模型有效的基础。
经验误差最小化的求解思路: 构造一个代价函数或损失函数 (Loss function) 来描述经验风险, 优化参数使该函数值最小

损失函数 $L(w)$:

给定独立同分布的学习样例集合 $(x, y) \in X \times Y$ 和模型 $\hat{y} = g(x, w)$, 损失函数度量的是模型输出预测值和训练样本标记值之间的差异

$$L(w) = \text{distance}(y, \hat{y}) \text{ or } = \text{distance}$$

数值差异 ↗

$$[p(y|x), q(\hat{y}|x)]$$

概率分布差异 ↗

(有监督学习)



➤ 以下是机器学习中常用的损失函数：

损失函数	表达式
L1损失 (L1 loss)	$ \hat{y}_i - y_i $
L2损失 (L2 loss) 最小二乘误差	$(\hat{y}_i - y_i)^2$
Huber损失 (Huber loss)	$\begin{cases} \frac{1}{2}(\hat{y}_i - y_i)^2 & , \hat{y}_i - y_i < \delta \\ \delta \hat{y}_i - y_i - \frac{1}{2}\delta^2 & , \hat{y}_i - y_i \geq \delta \end{cases}$
交叉熵损失 (cross-entropy loss)	$-y_i \cdot \ln \hat{y}_i - (1 - y_i) \cdot \ln(1 - \hat{y}_i)$ 二分类: $y_i \in \{1, 0\}$, $\hat{y}_i$ 是预测样本属于正类的概率
铰链损失 (hinge loss)	$\max(0, 1 - \hat{y}_i y_i)$ SVM: $y_i \in \{1, -1\}$
指数损失 (exponential loss)	$\exp(\hat{y}_i y_i)$

- 损失函数通常针对单个训练样本，用于度量模型在该样本上的预测错误程度。**代价函数** (Cost function) 通常针对整个训练集而言，是损失函数在所有训练样本上的平均值。用于度量模型在整个数据集上的平均误差，反映了模型对整体数据的适应能力



定义在 m 个训练样本上的最小二乘误差（平方误差），就是大家熟悉的均方误差 (Mean Squared Error, MSE)

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

注：如果不引起混淆，一般不刻意区分损失函数和代价函数，统称为 $Loss$



- 泛化能力 (generalization) 是指模型对新样本的适应能力，反映了一个模型在训练集数据之外的数据上的表现

2. 结构风险最小化 (structural risk minimization-SRM) 准则:

结构风险在经验风险的基础上增加对模型复杂度的正则化 (regularization) 约束，以降低模型复杂度，提升模型的泛化能力

选择假设 (模型) 的原则:

- 在选择机器学习方法的过程中对某种假设的偏好称为**归纳偏好** (inductive bias)。归纳偏好起到了“模型选择”的作用，使我们可以从假设空间中选择出更符合现实规则的模型
- 奥卡姆剃刀 (Occam's Razor): 若有多个假设与观察一致，选择最简单的那个模型

6 优化参数的算法

- **算法 (algorithm)** 特指最优化代价函数 (损失函数) 训练模型参数的方法, 即求解最优化问题的算法

凸优化 ((Quasi) convex optimization) :

也称为凸最优化或凸最小化, 主要研究定义于凸集中的凸函数的最小化问题。在机器学习中, 常把**优化目标函数或损失函数设计为凸函数**, 则很多优化问题都需要通过凸优化算法来求解。常用的优化算法包括:

- 对偶问题与Lagrange乘子法
- 梯度下降法 (Gradient descent)
- 牛顿法 (Newton Method)
- 内点法 (Interior Point Method)

模型、策略、算法构成机器学习的三要素


机器学习方法（学习器）=模型+策略+算法



AI大模型（Foundation Models / Large Models）是指具有巨大参数数量和复杂结构的机器学习（神经网络）模型。它们能够更好地理解和生成自然语言、处理复杂的图像和语音数据，生成更准确和高质量的预测结果

* GPT-3的参数数量约1750亿

* 完整版DeepSeek R1的参数数量约6710亿




David McCandless, Tom Evans, Paul Barton
Information is Beautiful // UPDATED 6th Dec 23

MADE WITH VIZsweat

7 机器学习的基本流程

机器学习的工作流程





武汉大学
WUHAN UNIVERSITY

03机器学习技术与系统的种类

Types of machine learning techniques and systems



- **机器学习技术分类(I)**: 样本是否带有分类标记
 - 有监督学习、无监督学习、半监督学习、自监督学习
- **机器学习技术分类(II)**: 能否从导入的数据进行动态持续学习
 - 批量学习、在线学习
- **机器学习技术分类(III)**: 是简单地将待分类数据点和已知数据点进行匹配, 还是通过训练样本建立一个预测模型
 - 基于实例的学习、基于模型的学习
- **机器学习技术分类(IV)**: 在样本空间 $\mathbf{x}_i \in X$ 和标记空间 $C_k \in Y$ 中, 对于样本 $\mathbf{x}_i$ 的分类是直接针对条件分布 $P(C_k | \mathbf{x}_i)$ 建模, 还是根据联合分布 $P(\mathbf{x}_i, C_k) = P(\mathbf{x}_i | C_k) \cdot P(C_k)$ 建模
 - 判别式模型、生成式模型

注: 以上各分类之间并不互斥, 只是分类角度不同





有监督学习	➤ 有标签数据 ➤ 直接反馈 ➤ 预测结果 / 未来
无监督学习	➤ 无标签 / 目标 ➤ 无反馈 ➤ 寻找数据中隐藏的结构
强化学习	➤ 决策过程 ➤ 奖励机制 ➤ 学习一系列的行动





1 有监督学习 (Supervised learning)

- 也称为有导师的学习，常见的**分类**和**回归**问题都属于监督学习
- 有监督学习的训练样本既有特征又有标签，模型从训练样本中学习从样本空间到标记空间的映射，在面对只有特征没有标签的数据时，可以预测出其标签
- 在有监督学习中，通常都需要足够有标记的样本。如果已标记样本过少、标记不均衡或者标记不准确，都会影响模型性能

分类任务



回归任务（曲线拟合）






➤ 常见的有监督学习方法:

- k -近邻算法 (k -Nearest Neighbors)
- 线性回归 (Linear Regression) (第3讲)
- 逻辑回归 (Logistic Regression) (第3讲)
- 支持向量机 (Support Vector Machines, SVM) (第4讲)
- 决策树和随机森林 (Decision Trees & Random Forests) (第6讲)
- 神经网络 (Neural Networks) (第10、11讲)



2 无监督学习 (Unsupervised learning)


- 也称为无导师的学习，常见的**聚类**问题、大部分**降维**问题都属于无监督学习。无监督学习目标是发现输入数据潜藏的结构或者规律。大数据**可视化**也可以看作是一种无监督学习

大数据可视化 (Data Visualization)




聚类分析






PCA是迄今为止最流行的降维算法
先找出第1主轴，投影数据的方差最大
再找出第2主轴：投影数据的方差次之
(第2主轴应该与第1主轴“正交”)



局部线性嵌入：一种流形学习技术

对高维空间的流形，先计算每个点与其邻域点的距离信息，在向低维空间投影时，最大程度地保持这种局部距离信息。


LLE能有效实现，前提是高维空间的数据是本质低维的



一个可视化示例，突显了各种语义簇



异常检测





➤ 常见的无监督学习方法：

- **聚类算法**

- k -均值聚类(k -Means)
- 层次聚类分析(Hierarchical Cluster Analysis)
- 概率聚类分析(Probabilistic Cluster Analysis)

- **降维算法**

- 主成分分析(PCA)
- 多维标定降维 (MDS)

- **关联规则学习算法**

- Apriori


3 基于实例的学习

➤ 学习器先完全记住学习样例 (example), 然后通过某种相似度量方式, 将其泛化到新的实例 (instance), 而不使用模型

k 近邻分类算法 (懒惰学习)

(k -Nearest Neighbor, k NN):

经典的监督学习和基于样例的学习方法: 给定某个测试样本, 基于某种距离度量在训练集中找出与其最近的 k 个带有真实标记的训练样本, 然后由这 k 个邻居的标记来进行预测




- 投票法: 选择 k 个样本中出现最多的类别标记作为预测结果
- 平均法: 将这 k 个样本的实值输出标记的平均值作为预测结果

4 生成模型与判别模型


- **判别式 (Discriminative) 模型**: **寻找决策边界**, 通过该边界将样本划分到对应类别。
反映异类数据之间的差异, 直接面对预测而设计, 学习准确度高



生成式模型和判别式模型示意图



判别式模型




生成式模型




- **生成式 (Generative) 模型**：学习每个类别的边界，基于贝叶斯公式计算样本属于每个类的后验概率，一般由**最大后验概率**确定样本分类。模型能够反映同类数据本身的相似度，包含信息更为丰富，可以用来生成样本
- 常见的生成式模型：
 - 朴素贝叶斯 (Naive Bayes)
 - 高斯混合模型 (Gaussian Mixture Model, GMM)
 - 隐马尔可夫模型 (Hidden Markov Model, HMM)
 - 变分自编码器 (Variational Autoencoder, VAE)
 - 生成对抗网络 (Generative Adversarial Networks, GANs)
 - Transformer网络

- 从样例中构建出：或者 能生成这些样例数据的模型（**生成式模型**），或者 能基本反映这些样例中存在的某些数量关系（特征与标签之间）的模型（**判别式模型**），然后使用这些模型进行预测（回归和分类）



基于模型的学习


➤ 基于模型的回归问题：金钱能否使人感到快乐？



部分国家国民生活满意度与人均GDP的散点图



➤ 简单线性回归模型：金钱似乎能使人感到快乐！



国民生活满意度与人均GDP的“关系”

5 强化学习 (Reinforcement Learning)

- 又称再励学习、评价学习或增强学习，是机器学习的范式和方法论之一，用于在智能体 (agent) 与环境的交互过程中，学习最优策略以达成回报最大化或实现特定目标



强化学习是人工智能中非常关键的方法





➤ 由于构建机器学习技术的主要任务是选择一种学习算法，并对某些数据掘进行训练，所以可能出现的问题不外乎是“**坏算法**”和“**坏数据**”。让我们先从坏数据开始

➤ 训练数据的数量不足


要教一个咿呀学语的小朋友什么是苹果，你只需要指着苹果说“苹果”（重复这个过程几次）就行了，然后孩子就能够识别各种颜色和形状的苹果了，样例教学的典型。简直是天才！

机器学习还没达到这一步，大部分机器学习算法需要大量的数据才能正常工作。即使是最简单的问题，可能也需要成千上万个样例，而对于诸如图像识别或语音识别等复杂问题，机器可能需要上千万个样例（除非你可以重用现有模型的某些部分）



➤ 训练数据不具代表性

- 为了很好地实现向新数据的推广与泛化，重要的是，对于将要泛化的新实例来说，建模用的训练数据一定要非常有代表性。不论你使用的是基于样例的学习还是基于模型的学习，都是如此
- 例如，前面我们用来训练线性模型的国家数据集并不具备完全的代表性，有部分国家的数据缺失，下页图中显示了补充缺失国家 / 地区信息之后的数据表现
- 如果用这个新的数据集训练线性模型，将会得到图中的实线，而虚线表示旧模型。这里，添加部分缺失数据不仅显著地改变了模型，也清楚地说明，这种线性模型可能永远不会那么准确
- 看起来，某些非常富裕的国家并不比中等富裕国家幸福（事实上，看起来甚至是不幸福）。反之，一些贫穷的国家也似乎比许多富裕国家更加快乐



使用更具代表性数据后的线性回归模型

- 使用不具代表性的训练集拟合出的模型难以做出准确预测
- 使用具有代表性的训练集，说起来容易做起来难：
 - 如果**样本集太小**，将会出现采样噪声（非代表性数据被选中），容易导致**模型过拟合**
 - 即便是有大样本量数据，如果采样方式欠妥，同样可能导致非代表性数据集，这就是所谓的**采样偏差问题**



- 如果训练集充满了**错误、异常值和噪声**（例如，差质量的测量产生的数据），系统将更难检测到底层模式，更不太可能表现良好。所以花时间来清理训练数据是非常值得的投入
- 事实上，大多数数据科学家都会花费很大一部分时间来做这项工作。如果样本集太小，将会出现采样噪声（非代表性数据被选中）
 - **数据异常**：如果某些实例明显是异常情况，要么直接将其丢弃，要么尝试手动修复错误
 - **数据缺失**：如果某些实例缺少部分特征（例如，5% 的顾客没有指定年龄），你必须决定是整体忽略这些特征，还是忽略这部分有缺失的实例，又或者是将缺失的值补充完整（例如，填写年龄值的中位数）




Garbage in, garbage out

- 当训练数据中包含较多**与目标变量有关的** (Relevant)特征，以及较少的**与目标变量无关的** (Irrelevant) 特征，系统才能够有效学习。同时，**各特征之间要尽可能减少互相关**(Correlation)
- **互相关特征**：是指样本中的某些特征可以由其他特征，或者部分地，或者完全地表达出来
- **特征的多重共线性**：是互相关特征的极端情况，指某些特征可表达为其他特征的线性组合，导致算法极不稳定
- 一个机器学习项目成功的关键是：提取出一组好的特征子集，用于训练模型，这个工作叫**特征工程**，主要有以下几点：
 - 特征理解与选择：从现有特征中选择出最有效的特征
 - 特征清洗与增强：删除和填充含缺失值的数据，最大化数据价值
 - 特征提取与转化：将现有特征进行整合，产生更为有效的特征
 - 特征构建与学习：通过新数据创造新特征，或学习出新特征




- 假设你正在国外旅游，被出租车司机狠宰了一刀，你很可能会说，那个国家的所有出租车司机都是强盗。**过度概括**是我们人类常犯的错误。
- 下图是对前面的的生活满意度数据，用**高阶多项式**进行的模型拟合，这是一个明显的**与训练数据过拟合的**模型。虽然它在训练数据上的表现比简单的线性模型要好得多，但是**你真的相信它的预测是合理的吗？**



模型过拟合



- **蓝色虚线**：代表一开始的原始模型，也就是缺失部分国家的数据时拟合的模型
- **红色虚线**：代表用所有国家数据拟合出的第二个模型：
- **蓝色实线**：代表的模型与第一个模型使用的训练数据相同，但是应用了**模型正则化**。可以看出通过正则化使得模型具有较小的斜率，虽然这略微降低了模型与训练数据的匹配程度，但是能更好地泛化到新的实例





- **过拟合** 是指在建模过程中，模型完美适应于训练集数据，从而牺牲对新数据点的预测能力的一种倾向
- 当模型相对于训练数据过于复杂时，容易发生过拟合
- 过拟合问题可能的**缓解方案**有
 - 减少模型参数（人工手动）
 - 优化模型特征（特征工程）
 - 约束模型参数（对复杂性进行惩罚的正则化）
 - 增加训练数据（降低过拟合可能性）
 - 改善数据质量（修复数据错误，填补数据缺失，清除异常数据）



- **欠拟合** 与过拟合相反：模型太过简单，没有学习到数据中的真实结构，难以做出有效可用的预测
- 例：用线性模型来表达生活满意度与人均GDP的关系，属于拟合不足；现实情况远比这个简单模型要复杂得多。所以，即便对于用来训练模型的样例，该模型产生的预测都会有很多是不准确的
- 解决欠拟合问题主要有以下一些方式：
 - 选择一个带有更多参数、更强大的模型（复杂化模型）
 - 通过特征变换，为学习算法提供更好的特征集（特征工程）
 - 放松对模型的约束（降低复杂度正则项的惩罚因子值）




武汉大学
WUHAN UNIVERSITY

04机器学习的发展和趋势

The development and trends of machine learning


- 20 世纪40、50年代至今，机器学习已经成为一个独立的学科领域并快速发展，给各行各业带来了颠覆性变革
- 请大家自行了解下述人物、事件和成果



2018图灵奖颁发给了深度学习三位大师



- Geoffrey Hinton: 1947年生, 谷歌的副总裁和工程师, 多伦多大学的名誉教授
 - 反向传播 (Backpropagation) • 玻尔兹曼机 (Boltzmann Machines)
- Yann LeCun: 1960年生, Facebook首席AI科学家
 - 卷积神经网络 (Convolutional Neural Networks, CNN)
- Yoshua Bengio: 1964年生, 蒙特利尔大学教授
 - 序列的概率模型 • 高维词汇嵌入和注意机制
 - 生成对抗网络 (Generative Adversarial Networks, GAN)



2024诺贝尔物理奖、化学奖均颁给了AI领域的科学家

- John Hopfield、Geoffrey Hinton：在人工神经网络机器学习方面的基础性发现和发明
- Demis Hassabis、John Jumper：利用人工神经网络开展蛋白质结构预测（AlphaFold 新版不开源）



“机器学习是一门数学课”

- 微积分：方向导数与偏导数、梯度、凸函数、函数极值、最小二乘法、Lagrange乘子法、多项式拟合、Jacobian矩阵和Hessian矩阵
- 线性代数：向量组的线性相关性、向量内积与正交、方阵的特征值与特征向量、对称矩阵对角化、基变化与坐标变换、矩阵投影、张量
- 概率论与数理统计：条件概率、全概率、贝叶斯公式、概率分布、期望、方差、协方差、相关系数、假设检验、似然函数、参数估计
- 最优估计：最小二乘估计、极大似然估计、极大验后估计、贝叶斯估计
- 随机过程：Markov chain
- 最优化
-



机器学习是实现第四范式的重要技术

- 图灵奖获得者吉姆·格雷（Jim Gray）提出：科学研究需要第四范式（the fourth paradigm），从计算密集型科研发展到以大数据为基础的数据密集型科研
- **当物理过程复杂、难以被模型归纳时，机器学习可以发挥其长处**



- **多模态 (Multimodal) 大模型**：视、听觉与语言多模态对齐的智能
- **世界模型 (空间智能)**：人类观察世界并进一步预测世界的智能（相对于语言）
- **具身智能 (Embodied intelligence)**：指具有身体并支持与物理世界进行交互的智能体，如机器人、无人车等。通过多模态传感数据处理，由大模型生成运动指令对智能体进行驱动，替代传统基于规则或者数学公式的驱动方式，实现虚拟和现实的深度融合
- **AI4R (AI for Research)**：成为科学发现与技术发明的主要范式



中国工程院孙凝晖院士给国家领导人讲课：《人工智能与智能计算的发展》



- 我国在人工智能发展方面制定了多层次、多维度的系统性规划，旨在推动人工智能技术的创新、应用和产业发展。其国务院《**新一代人工智能发展规划**》提出，到2025年，人工智能基础理论实现重大突破，部分技术与应用达到世界领先水平。到2030年，人工智能理论、技术与应用总体达到世界领先水平，我国将成为世界主要人工智能创新中心。

[1]. 孙凝晖.十四届全国人大常委会专题讲座第十讲讲稿：人工智能与智能计算的发展[EB/OL][2024-04-30]. http://www.npc.gov.cn/c2/c30834/202404/t20240430_436915.html

请课后自学西瓜书第一章



武汉大学
WUHAN UNIVERSITY

End of This Part
