



武汉大学
WUHAN UNIVERSITY

第2讲 模型选择与评估

《机器学习》



武汉大学
WUHAN UNIVERSITY

01 监督学习的计算理论

02 误差构成与过拟合

03 模型验证与测试

04 模型的性能度量

05 模型的比较检验 *



武汉大学
WUHAN UNIVERSITY

01 监督学习的计算理论

Computational theory of supervised learning


《机器学习》



从机器学习的过程看，机器学习方法（或者机器学习模型）可分为：

- 有监督学习 (Supervised Learning)
 - 无监督学习 (Unsupervised Learning)
 - 半监督学习 (Semi-Supervised Learning)
 - 自监督学习 (Self-Supervised Learning)
- 机器学习以**数据**为对象，它通过提取数据特征，发现数据中的知识并抽象出数据**模型**，作出对新数据的**预测**。

- $\mathcal{A}$ 表示学习器 (Learner), f 表示学习的目标假设 (可以是一个函数, 也可以是一个分布), H 表示假设空间, g 表示我们求解的用来预测的假设, g 属于 H 。机器学习的过程又可以理解为: 通过学习器 $\mathcal{A}$, 在假设空间 H 中, 根据训练样例集合 D , 选择最好的假设 g 使 g 近似于 f





- **经验误差** $E_{\text{in}}(g)$: 学到的模型 g 在训练样本 (in-of-sample) 上的**损失**。训练 (training) 的目标就是使得经验误差 $E_{\text{in}}(g)$ 尽可能小
- **泛化误差** $E_{\text{out}}(g)$: 模型 g 在除了训练样本外的其他所有样本 (out-of-sample) 上的**损失**。测试 (test) 过程即希望 $E_{\text{out}}(g)$ 接近 $E_{\text{in}}(g)$

► 本节核心问题

● 问题一：模型选择

给定一类假设，是否可以通过学习实现 $E_{\text{out}}(g) \approx E_{\text{in}}(g)$ (是否可学习?)

● 问题二：模型评估

f 作为目标假设 $E_{\text{out}}(f) = 0$ 。使 g 近似于 f 即需要 $E_{\text{out}}(g) \approx E_{\text{in}}(g) \approx E_{\text{out}}(f) = 0$ 。如果没有训练样本外的其他样本，那么如何**评估** $E_{\text{out}}(g)$ 呢?






1 有效假设









- **假设 (hypothesis)** 可以看作是对于真实模型的一种**近似或猜测**。比如“线性回归模型”即等同于这样一个假设：解释变量与响应变量之间的关系可以用一条直线（或超平面）来描述
- **有效假设**是指在给定数据集中，能够产生**不同**二分结果（又称**对分**，dichotomies）的假设。这些假设对于数据的描述或预测是有意义的。即使假设空间包含无限多个假设，但其中许多假设在给定数据集上产生的结果是相同的，则可视为同一种



二维空间的所有线性假设（即直线条数）有无穷多个。如只存在1个数据点，则可以将这些假设分为两类，一类是把 x_1 判断为正例，另一类是把 x_1 判断为负例




提问：如果有2个数据点、3个数据点呢？



提问：如果有4个数据点呢？

注意到，最后红色的情况：无法通过一条直线将正例、负例分开

2 x



注：红实点与黑空点一为正例，则另一为负例。反之亦然。故一共16种分布情况，但对分只有14种

- VC维 (Vapnik-Chervonenkis Dimension) 是前苏联数学家弗拉基米尔·瓦普尼克 (Vladimir Vapnik) 和亚历山大·切沃年科 (Alexey Chervonenkis) 在1968年共同提出的, 是衡量模型复杂度的关键指标



Vapnik



Chervonenkis

2 VC维

- 增长函数 $\Pi_H(m)$: 假设空间 H 对 m 个样本所能赋予二分类标记的**最大的可能数**, 其上界为 2^m 。这里每种标记称为一个**对分**

- **H 散列 (shatter)** : H 作用于大小为 m 的样本集 D 时, 产生的对分数量等于 2^m , 即 $\Pi_H(m) = 2^m$ 时, 则称 D 被 H 散列 (**打散**) 了





存在二维平面的3个数据可以被直线假设散列: $\Pi_H(3) = 2^3 = 8$, 但是任意4个数据不能被直线假设散列: $\Pi_H(4) = 14 < 2^4 = 16$

提问: 那么4个数据可以被什么样的假设散列呢?



i.e. 轴平行的矩形假设能够散列二维空间的4个点





- **中断点 (break point)** : 对于假设空间 H 的增长函数 $\Pi_H(m)$, 当 $m=1$ 逐渐增大到 k 过程中, (**第一次**) 出现 $\Pi_H(k) < 2^k$ 时, 则称 k 是该假设空间的中断点。任何数目大于等于 k 的数据集, H 都没有办法打散它。
- **VC维**: 可以被 H 散列的点的最大数据集大小称为 H 的VC维。 **$VC(H)=k-1$** , 其中 k 是 H 的中断点。 VC维的大小与具体的学习策略和优化算法无关, 与数据集分布无关, **只与假设空间有关**

提问:

- (1) H 表示实数域的闭区间记作 $\{h_{[a,b]}\}$, 如果 $x \in [a,b]$ 则为正类, 否则为负类。问 H 的VC维是多少?
- (2) H 表示二维平面的三角形假设类, 问 H 的VC维是多少?
- (3) H 表示 R^d 空间的线性超平面, 试着证明其VC维为 $d+1$

3 可学习条件

➤ 引入VC维后，可推导得知对于 $\forall g \in H$

$$\mathbb{P}[|E_{\text{out}}(g) - E_{\text{in}}(g)| > \varepsilon] \leq 4 (2m)^{\text{VC}(H)} \exp\left(-\frac{1}{8} \varepsilon^2 m\right) \quad \begin{array}{l} m \geq 2, k \geq 2 \\ \text{VC}(H) = k-1 \end{array}$$



[推导过程](#)


可学习条件

- 学习器A 能够从 H 选出假设 g ，通过训练使得 $E_{\text{in}}(g) \approx 0$
- 假设空间 H 中**VC(H)是有限的，且训练样本 m 足够大**，则经验误差与泛化误差之差大于 ε 的概率趋于0，即学习器A 从 H 选出的假设 g 都满足 $E_{\text{out}}(g) \approx E_{\text{in}}(g) \approx 0$



4 VC维的意义


- VC维用来度量假设 H 的复杂度和学习能力。当固定样本数 m 时，随着VC维的上升， $E_{in}(g)$ 会不断降低，同时模型复杂度 Ω 会不断上升。因此**机器学习的模型选择要寻找一个合适的VC维使 $E_{out}(g)$ 最小**





- 当模型复杂时需要更多的训练数据，约为 $10000 \cdot VC(H)$ 这个量级。而在实际工程中， m 取 **$10 \cdot VC(H)$** 就能取得比较好效果。另外为了避免过拟合，一般都会加正则化项，从而控制其 VC 维
- 对于决策树模型来说，由于其可以任意深、任意宽，其 VC 维可以非常大，甚至是无穷大。
在实际应用中，我们通常通过限制决策树的**深度**、叶子节点对应的最小**样本个数**、最多**属性划分数**等方式来控制其复杂度，从而控制其 VC 维
- 对于深度学习（神经网络），其 VC 维与神经元连接数有关。一个输入层1000、隐藏层1000，输出层为1的神经网络，VC 维大约 $O(1000 \times 1000 \times 1)$ 。可见神经网络的 VC 维很高，因而它的**表达能力非常强**，可以用来处理复杂的分类问题。

提问：直线假设 H 的VC维仅为3，为什么我们还要使用线性分类模型？



线性模型易于建模、可解释性、可扩展性



武汉大学
WUHAN UNIVERSITY

02 误差构成与过拟合

Error composition and overfitting



1 偏差-方差分解

- 在机器学习中，误差泛指模型预测值与真实值之间的差异，是评估模型性能的重要依据，也是不可避免的。误差进一步可以分解为**偏差**、**方差**和**噪声**的组合

偏差
Bias

又称为表观误差，通常指的是模型预测的平均值（期望）与真实值之间的差异，反映模型**精度**

方差
Variance


指模型在不同训练集上学习到的结果之间的差异，反映模型的**稳定性**

噪声
Noise


通常指数据集中无法解释的人为疏忽、标记错误或随机变异的部分，是不可避免的

- **偏差**：表示估计量或预测量的**平均值**相对于估计对象或预测对象的**真值** 之间的**差异**。衡量的是估计值或预测值**与未知真值间的偏离程度**。
- **方差**：表示估计量或预测量**对样本数据的敏感程度**，衡量的是估计值或预测值**围绕自己的平均值**的变动程度、发散程度。


方差：跟自己比



偏差：跟目标比




谁的枪法好?
谁的枪法差?




低偏差、高方差



高偏差、低方差




高偏差、高方差



低偏差、低方差



e.g 对测试样本 x , 令 y_{Di} 为 x 在数据集 D_i 中的标记, y 为 x 在物理世界的真实标记, $\hat{y}_{Di}$ 为在训练集 D_i 上学习到的模型在 x 上的预测值。以回归任务为例, 使用样本数量相同的不同训练集训练学习器





- 各学习器在 x 上的预测输出的数学期望记为: $\mathbb{E}_D[\hat{y}_D]$
- 各学习器预测输出的方差为: $\mathbb{E}_D[(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])^2]$
- 训练数据存在噪声, 即标记 y_D 与真值 y 有差异, 则噪声 ε 有:

$$\varepsilon^2 = \mathbb{E}_D[(y_D - y)^2]$$

- 模型预测值的期望与真实值的差别为偏差, 有:

$$bias^2 = (\mathbb{E}_D[\hat{y}_D] - y)^2$$

➤ 那么这些学习器可观测到的平均误差（期望）：

$$\begin{aligned}\mathbb{E}_D[(\hat{y}_D - y_D)^2] &= \mathbb{E}_D[(\hat{y}_D - \mathbb{E}_D[\hat{y}_D] + \mathbb{E}_D[\hat{y}_D] - y_D)^2] \\ &= \mathbb{E}_D[(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])^2] + \mathbb{E}_D[(\mathbb{E}_D[\hat{y}_D] - y_D)^2] \\ &\quad + \mathbb{E}_D[2(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])(\mathbb{E}_D[\hat{y}_D] - y_D)]\end{aligned}$$

其中 $\mathbb{E}_D[\hat{y}_D] = c$ 是数学期望设为常数 c

$$\begin{aligned}&\mathbb{E}_D[2(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])(\mathbb{E}_D[\hat{y}_D] - y_D)] \\ &= 2\mathbb{E}_D[\hat{y}_D \cdot c - c \cdot c - \hat{y}_D \cdot y_D + c \cdot y_D] \\ &= 2c \cdot \mathbb{E}_D[\hat{y}_D] - 2c^2 - (2\mathbb{E}_D[\hat{y}_D \cdot y_D] - 2c\mathbb{E}_D[y_D]) \\ &= 2c^2 - 2c^2 - (2\mathbb{E}_D[\hat{y}_D] \cdot \mathbb{E}_D[y_D]) - 2c\mathbb{E}_D[y_D] \\ &= -(2c\mathbb{E}_D[y_D] - 2c\mathbb{E}_D[y_D]) = 0\end{aligned}$$

Tips

数学期望的性质： $\mathbb{E}_D[aX + b] = a\mathbb{E}_D[X] + b$ ， $\mathbb{E}_D[XY] = \mathbb{E}_D[X] \cdot \mathbb{E}_D[Y]$

➤ 则学习器可观测到的平均误差（期望）：

$$\begin{aligned}\mathbb{E}_D[(\hat{y}_D - y_D)^2] &= \mathbb{E}_D[(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])^2] + \mathbb{E}_D[(\mathbb{E}_D[\hat{y}_D] - y_D)^2] \\ &= \mathbb{E}_D[(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])^2] + \mathbb{E}_D[(\mathbb{E}_D[\hat{y}_D] - y + y - y_D)^2]\end{aligned}$$

其中 y 是物理真值也视为常数，则可观测误差期望：

$$\mathbb{E}_D[(\hat{y}_D - y_D)^2]$$

$$= \mathbb{E}_D[(\hat{y}_D - \mathbb{E}_D[\hat{y}_D])^2] + \mathbb{E}_D[(\mathbb{E}_D[\hat{y}_D] - y)^2] + \mathbb{E}_D[(y - y_D)^2] + 2(c - y)\mathbb{E}_D[y - y_D]$$

=0

方差

($\hat{y}_D$ 与 $\mathbb{E}_D[\hat{y}_D]$ 的关系)

偏差

($\mathbb{E}_D[\hat{y}_D]$ 与 y 的关系)

噪声

(y_D 与 y 的关系)

偏差-方差分解、偏差-方差权衡、偏差-方差困境，说的都是一个意思：

在随机世界里，鱼和熊掌不可兼得（“平衡的观点”）

设 θ 是某参数真值（未知，非随机），通过样本进行估计的估计量记为 $\hat{\theta}$ ，该估计量关于未知真值 θ 的偏差记为： $B(\hat{\theta}) \triangleq E(\hat{\theta}) - \theta$ ，

方差记为： $V(\hat{\theta}) \triangleq E[(\hat{\theta} - E(\hat{\theta}))^2]$ ，

估计量偏离目标（此处为真值 θ ）的“质量”用均方差表示：

$$MSE(\hat{\theta}) \triangleq E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2] = V(\hat{\theta}) + [B(\hat{\theta})]^2$$

这就是所谓的参数估计量均方误差的偏差-方差分解（两项）：

$$MSE(\hat{\theta}) = [B(\hat{\theta})]^2 + V(\hat{\theta})$$

$$MSE = B^2 + V$$

设 y 是某变量真值（未知，非随机）， $\tilde{y}$ 是其观测值，观测误差记为 e ，观测方程： $\tilde{y}=y+e$ 故 $\tilde{y}$ 是随机变量。

这里， $e \sim N(0, \sigma_e^2)$ 。于是有： $\tilde{y} \sim N(y, \sigma_e^2)$ ，也即： $E(\tilde{y}) = y, V(\tilde{y}) = \sigma_e^2$ 。

又设 $\hat{y}$ 是某预测模型根据观测值 $\tilde{y}$ 对 y 做出的预测值，也是随机变量，且与观测噪声 e 无关，因此也就与观测值 $\tilde{y}$ 线性无关： $E(\hat{y} \cdot \tilde{y}) = E(\hat{y}) \cdot E(\tilde{y})$ ，预测方程： $\hat{y} = f(\tilde{y})$

该预测量关于未知真值 y 的偏差记为： $B(\hat{y}) = E(\hat{y}) - y$ ，方差记为： $V(\hat{y}) = E[(\hat{y} - E(\hat{y}))^2]$ ，

预测量 $\hat{y}$ 偏离目标（此处为观测值 $\tilde{y}$ ）的“质量”用均方误差表示：

$$\begin{aligned} MSE(\hat{y}) &= E[(\hat{y} - \tilde{y})^2] = E[\hat{y}^2 - 2\hat{y} \cdot \tilde{y} + \tilde{y}^2] = E(\hat{y}^2) - 2E[\hat{y} \cdot \tilde{y}] + E(\tilde{y}^2) \\ &= V(\hat{y}) + [E(\hat{y})]^2 - 2E(\hat{y}) \cdot E(\tilde{y}) + V(\tilde{y}) + [E(\tilde{y})]^2 \\ &= V(\hat{y}) + V(\tilde{y}) + [E(\hat{y}) - E(\tilde{y})]^2 = [E(\hat{y}) - y]^2 + V(\hat{y}) + V(\tilde{y}) \\ &= B(\hat{y})^2 + V(\hat{y}) + \sigma_e^2 \end{aligned}$$

这就是所谓的变量预测量均方误差的偏差-方差分解（三项）：

$$MSE(\hat{y}) = B(\hat{y})^2 + V(\hat{y}) + \sigma_e^2$$

$$MSE = B^2 + V + \sigma_e^2$$





➤ 小k值时——模型变得复杂：**低偏差、高方差**


➤ 测试点的分类预测值，只与最近邻的类别有关，与其他点无关。在训练集因不同抽样而变动时，测试点的预测类别紧跟最近邻，变动频繁，但是平均而言，应该还是在其真值附近（如果训练集真实反映实际情况的话），因此**属于小偏差**

➤ 因为最近邻缘故，当训练集因抽样而变化时，同样的测试点，由于训练点的类别变化频繁，导致预测值变动频繁，因此**具有大方差**


➤ 大k值时——模型变得简单：**高偏差、低方差**








1-NN, 模型紧跟训练数据分布, 决策边界变动频繁, 模型最复杂, 方差最高, 但基本无错分



3-NN, 模型平均因素增加, 决策边界开始平滑, 复杂度有所降低, 方差也会降低, 但错分增加




9-NN, 模型更加平均, 决策边界更加平滑, 复杂度下降较多, 方差很小, 但是错分增加很多




2 欠拟合与过拟合

- **欠拟合 (Underfitting)** : 是指模型在训练集、验证集和测试集上均表现不佳的情况。情况通常发生于模型 (假设) 过于**简单**, 没有足够的能力去提取数据的复杂关系或特征
- **过拟合 (Overfitting)** : 是指模型在训练集上表现很好, 而在验证和测试阶段误差很大, 即模型的泛化能力很差。通常是因为模型没有学习到数据的普遍规律, 而学习到了训练数据的噪声或**个性特征**


回归：



欠拟合






好拟合



过拟合

分类：





- 复杂的模型，信息吸收能力强，数据拟合能力强，不仅能学到训练数据中存在的真实模式与相关关系，也能学到数据中随机噪声呈现的虚假模式与关系
 - 复杂模型主要体现在参数过多，能记忆更多的数据细节，相对弱化了预测中真正需要的固定模式与相关关系
 - 用过拟合的复杂模型去做预测，容易受新样本中随机噪声的影响。在考察大量新样本的预测结果时，错分率较大，呈现出偏差不低、方差很高的特征——模型泛化能力差的典型特征
 - 使用少量数据进行训练的复杂模型，容易产生对过拟合
 - 过拟合模型，就像一个读死书的书呆子：记得很多，但不能活用
 - **过拟合-泛化能力的关系**，是**偏差-方差权衡**的一个具体实例

If you torture the data long enough, it will confess.

Ronald Coase, 1991 Nobel Laureate economist



➤ 如何发现过拟合现象？

➤ 利用交叉验证

- 如果训练精度、测试精度都低——欠拟合
- 如果训练精度高、测试精度低——过拟合

➤ 观察学习曲线和验证曲线

➤ 如何缓解过拟合问题？——降低模型复杂度

➤ 减少模型参数（人工手动）

➤ 优化模型特征（特征工程）

➤ 约束模型参数（对复杂性进行惩罚的正则化）

➤ 增加训练数据（增加过拟合的难度）

➤ 改善数据质量（修复数据错误，填补数据缺失，清除异常数据）



```
from sklearn.datasets import load_breast_cancer


cancer = load_breast_cancer()
X_train, X_test, y_train, y_test = train_test_split(
    cancer.data, cancer.target, stratify=cancer.target, random_state=66)

training_accuracy = []
test_accuracy = []
# try n_neighbors from 1 to 10
neighbors_settings = range(1, 11)


for n_neighbors in neighbors_settings:
    # build the model
    clf = KNeighborsClassifier(n_neighbors=n_neighbors)
    clf.fit(X_train, y_train)
    # record training set accuracy
    training_accuracy.append(clf.score(X_train, y_train))
    # record generalization accuracy
    test_accuracy.append(clf.score(X_test, y_test))

plt.plot(neighbors_settings, training_accuracy, label="training accuracy")
plt.plot(neighbors_settings, test_accuracy, label="test accuracy")
plt.ylabel("Accuracy")
plt.xlabel("n_neighbors")
plt.legend()
```

02 拟合深度与泛化能力——以K-NN为例



- 1-NN时，模型最复杂：
 - 训练集预测结果十分完美
 - 测试精度比k-NN时要低
- K-NN时，模型变简单：
 - 训练集精度也随之下下降
 - 测试性能上升，但在 $k=10$ 又变差



- 单变量的300阶多项式拟合，严重过拟合，有明显**翘尾效应**
- 另一种判断拟合情况的方法：**观察学习曲线**



学习曲线


模型在训练集和验证集上，关于训练集规模的性能函数

```
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split

def plot_learning_curves(model, X, y):
    X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2)
    train_errors, val_errors = [], []
    for m in range(1, len(X_train)):
        model.fit(X_train[:m], y_train[:m])
        y_train_predict = model.predict(X_train[:m])
        y_val_predict = model.predict(X_val)
        train_errors.append(mean_squared_error(y_train_predict, y_train[:m]))
        val_errors.append(mean_squared_error(y_val_predict, y_val))
    plt.plot(np.sqrt(train_errors), "r-+", linewidth=2, label="train")
    plt.plot(np.sqrt(val_errors), "b-", linewidth=3, label="val")
```


训练误差一直低于
验证误差，过拟合

10阶多项式拟合的学习曲线



训练误差与验证误差
都较高，欠拟合

线性回归拟合的学习曲线



```
from sklearn.pipeline import Pipeline

polynomial_regression = Pipeline((
    ("poly_features", PolynomialFeatures(degree=10, include_bias=False)),
    ("sgd_reg", LinearRegression()),
))

plot_learning_curves(polynomial_regression, X, y)
```

```
lin_reg = LinearRegression()
plot_learning_curves(lin_reg, X, y)
```

3 三元权衡

- 机器学习中的三元权衡 (Triple Trade-off) 是指在训练过程中, 需要平衡模型**复杂度**、训练**数据规模和质量**、在新样本上的**泛化误差**这三个关键因素。在实际应用中, 需要根据具体问题和数据集特点来灵活调整这三个因素, 以达到最佳的学习效果

▸ 模型假设

- 模型VC维低则容易偏差大, 造成欠拟合; 模型VC维高则容易对数据的变化敏感, 受到训练数据中噪声的影响, 造成过拟合


▸ 泛化误差

- 训练不足时, 模型拟合能力不强, 泛化误差由**偏差主导**。随着训练程度加深, 模型拟合能力增强, 泛化误差由**方差主导**



▸ 数据样本

- 机器学习算法一般需要**大规模且有代表性**的训练数据。如果训练集充满了错误、异常值和噪声，需要提前**清洗数据**。同时，样本各特征之间要尽可能减少互相关（Correlation）。当样本中包含多数与响应变量有关的特征，以及少数与响应变量无关的特征时，学习效果最好



泛化误差与偏差、方差的关系示意图

- 训练不足时，分类器拟合能力不足，偏差较大
- 随着训练数据量增加，分类器拟合能力逐渐增加，故偏差下降，但方差也逐渐增加
- 训练充足后，分类器拟合充分，模型复杂，拟合能力强，此时偏差最小，但方差最大



➤ 奥卡姆剃刀原则

Entities should not be multiplied beyond necessity.

(如无必要，勿增实体)

William of Occam, c. 1280–1349

➤ 奥卡姆剃刀原则的机器学习版本

**给定两个具有同样泛化误差的模型，
较简单的模型相对于较复杂的模型更可取**

➤ 爱因斯坦

Everything should be made as simple as possible, but not simpler.

(凡事应尽可能简单，但不能过于简单)

- “欠拟合”、“过拟合”是机器学习最需要关注的问题之一。可以从模型选择、数据样本和训练各个方面入手解决

模型	样本	训练
- 正则化 - Dropout - Stacking集成 - Bagging集成 - Boosting集成  奥卡姆剃刀原理 (Ockham's Razor) 不要忘记	- 清洗样本,减少/添加噪声 - 数据增强 (旋转、平移、翻转、Mixup) - 分层采样 - 交叉验证 - 多项式特征	Early Stopping



武汉大学
WUHAN UNIVERSITY

03 模型验证与测试

Model validation and testing



► 模型评估的基本问题

- 如何获得测试样本? → 验证测试
- 如何评估性能优劣? → 性能度量
- 如何比较学习器性能? → 比较检验

1 训练集、验证集和测试集

- 模型选择与评估：对候选模型的泛化误差进行评估，然后**选择泛化误差最小的模型**。但是泛化误差是定义在样本集之外的，无法直接获得。现实中的模型到底**如何评估**与选择呢？

关键：怎么获得“验证集” (validation set) 和“测试集” (test set) ？

训练集	验证集	测试集
降低经验误差	验证模型正确性调 节超参数	A榜 B榜


测试集、验证集应该与训练集“互斥”



- 机器学习中的 “参数 (parameters) ” :
 - **算法参数** (超参数, Hyperparameters) : 数目 10^1 级, 由人工依据经验设定, 调整的过程即俗称的 “调参” ;
 - **模型参数**: 目前已到 10^{12} 级 (e.g. GPT-3 1750亿) , 通过学习算法优化确定。

2 留出法

- 假设包含 m 个样例的数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，从 D 中选择一部分作为训练集 S ，留出 (hold out) 一部分作为测试集 T ：



- 一般测试集不能太大也不能太小（例如：**70%**的数据用于训练，**30%**的数据用于测试）
- 单次划分可能导致结果不稳定。通常需要**多次重复划分**（例如：100次随机划分），取平均值作为留出法的评估结果




- **分层采样 (Stratified Sampling)** 是一种在数据集中进行采样的方法。它根据数据集的某些特征或类别将数据划分为多个**子集** (即 “**层**”) , 然后在每个层中进行采样, 以确保每个子集中都有足够的样本被选中, 保持样本的多样性和代表性 (**一致性**)
- 在留出法划分训练集和测试集时, 通常结合分层采样来实施。这是因为如果简单随机划分, 可能会导致某些类别的样本在训练集 S 和测试集 T 中分布不均, 从而影响模型的训练和评估。通过分层采样, 可以**确保每个类别的样本在训练集和测试集中比例一致, 从而减小模型偏差**



3 k折交叉验证法

- 将数据集 D 划分为 k 个大小相同的互斥子集，满足 $D=D_1 \cup D_2 \cup \dots \cup D_k$, $D_i \cap D_j = \emptyset$ ($i \neq j$)。采用**分层采样**的方法使得这些子集的数据分布一致。每次用 $k-1$ 个子集的并集构成训练集，余下的那个子集作为测试集。共有 k 种训练集/测试集划分的情况，从而可进行 k 次交叉验证 (k -fold Cross-Validation)，最终返回 k 次评估结果的均值、标准差
- 如果模型性能在不同折之间存在较大差异，可能意味着数据集存在某种不平衡或模型对特定的样本过于敏感，则需要进一步的**数据清洗或模型调整**



10折交叉验证示意图

提问: k 折交叉验证会得到 k 个参数不同的模型, 那么最终使用哪一个呢?



- k 折交叉验证是一个用于评估模型性能的技术，而不是一个用于直接选择最终模型的技术。

交叉验证的一般步骤

- **评估所有折的性能**：计算每一折上的性能指标（如准确率、召回率、F1分数等），并计算 k 折的平均值和标准差；
- **选择最佳假设和模型超参**：基于平均结果，确定哪种模型配置（如不同的超参数、特征选择方法、假设类型等）的性能最好；
- **使用全部数据训练最终模型**：确定最佳模型配置后，使用全部可用的数据（即原始的训练集，有时也包括验证集，但不包括测试集）来训练一个最终的模型；
- **评估最终模型**：使用独立的测试集来评估最终模型的泛化性能



- 假定数据集 D 中包含 m 个样本，若令 $k=m$ ，则得到了交叉验证法的一个特例：**留一法 (Leave-One-Out, LOO)**
 - 优点：留一法不受随机样本划分的方式影响，因为 m 个样本只有唯一的方式划分为 m 折；留一法使用的训练集与初始数据集相比只少了一个样本，这就使得在绝大多数情况下，留一法中**被实际评估的模型与最终模型很相似**。
 - 缺点：在数据集较大时，训练 m 个模型的**计算开销**大。



在pytorch里调用sklearn库划分5折样本：

```
import torch
from sklearn.model_selection import KFold

# 设置随机种子
seed = 3407
torch.manual_seed(seed)


# 示例数据集（假设有100个样本，每个样本有10个特征）
data = torch.randn(100, 10) # 100个样本，每个样本有10个特征

# 创建 KFold 对象，n_splits=5 表示将数据集划分为 5 份
kf = KFold(n_splits=5, shuffle=True, random_state=seed)


# 遍历每个折
for fold, (train_index, test_index) in enumerate(kf.split(data)):
    train_data, test_data = data[train_index], data[test_index]
    print(f'Fold {fold + 1}')
    print(f'Train indices: {train_index}')
    print(f'Test indices: {test_index}')
    print(f'Train data: {train_data}')
    print(f'Test data: {test_data}')
```

4 自助采样法

- 自助采样 (bootstrap sampling) 又称 “**有放回采样**”：给定包含 m 个样本的数据集 D ，每次随机从 D 中挑选一个样本，将其副本放入 D' （该样本自身仍在数据集 D 中，使得下次采样时仍有可能被选中）。重复执行 m 次，就得到了包含 m 个样本的数据集 D'



训练集与原样本集同规模



数据分布有所改变

*在 m 次采样中，某样本始终不被选中的概率极限

$$\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368$$



- 以 D' 作为训练集, $D \setminus D'$ 用作测试集。这样的测试结果, 被称为“**包外估计**” (out-of-bag estimate)
- 优点: 对于**数据集较小**、难以有效划分训练/测试集时很有效。此外, 自助法能从初始数据集中产生多个**不同的训练集**, 有利于**集成学习**方法
- 缺点: 自助法**改变了初始数据集的分布**, 会引入估计偏差



武汉大学
WUHAN UNIVERSITY

04 模型的性能度量

Model performance metrics


1 分类任务的性能度量指标

- 二分类任务存在正例和反例。基于真实情况和预测结果，可得到以下**混淆矩阵**（Confusion Matrix）：分为真正例（True Positive, TP）、假正例（False Positive, FP）、真反例（True Negative, TN）、假反例（False Negative, FN）四类结果

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

二分类的混淆矩阵

多分类的混淆矩阵



常见的二分类性能度量指标

正确率Accuracy

分类正确的样本数占样本总数的比例 $(TP+TN) / (P+N)$

错误率Error

分类错误的样本数占样本总数的比例 $(FP+FN) / (P+N)$

$$\text{Accuracy} = 1 - \text{error}$$



精度/查准率Precision

分类为正例的样本中实际为正例的比例 $TP/(TP+FP)$

召回率/查全率Recall

正例中被分类为正例的比例 $TP/(TP+FN)$

灵敏度Sensitive

正例中被分类为正例的比例 $TP/(TP+FN)$ 对正例的
识别能力

特异性Specificity

反例中被分类为反例的比例 $TN/(FP+TN)$ 对反例的
识别能力

Fb-score

查准率和召回率的调和平均: $[(1+b) \cdot P \cdot R]/(b \cdot P + R)$ 精确率和召回率是相互影响的, F1分数是二者平衡点的指标, $b=1$



在pytorch里绘制混淆矩阵:

```
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
from sklearn.metrics import confusion_matrix
```

生成示例数据

```
np.random.seed(3407)
```

```
y_true = np.random.randint(0, 5, 100) # 真实标签
```

```
y_pred = np.random.randint(0, 5, 100) # 预测标签
```

计算混淆矩阵

```
cm = confusion_matrix(y_true, y_pred)
```

绘制混淆矩阵

```
plt.figure(figsize=(8, 6))
```


```
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
            xticklabels=range(5), yticklabels=range(5))
```

```
plt.xlabel('Predicted')
```

```
plt.ylabel('True')
```

```
plt.title('5x5 Confusion Matrix')
```


```
plt.show()
```





2 PR曲线和ROC曲线

- **P-R曲线**：精度（Precision）与召回率（Recall）的曲线。以召回率作为横坐标轴，精度作为纵坐标轴绘制而成
- 根据学习器输出的正例的预测概率将最可能是“正例”的样本排前，最不可能是“正例”的排后（每个样本的真实标签和预测概率已知）。逐次从大到小设置不同的概率阈值，按此顺序将概率大于阈值的样本预测为正例、小于阈值的样本为预测负例，并计算对应的精度P和召回率R，形成一个数据点。多个不同阈值对应的一组数据点构成P-R曲线。



- 若一个学习器C的P-R曲线被另一个学习器A的P-R曲线完全**包住**，则称：A的性能优于C。若A和B的曲线发生了交叉，则谁的曲线下的面积大，谁的性能更优。
- “**平衡点**” (Break-Event Point, 简称BEP)，即当 $P=R$ 时的取值，平衡点的取值越高，性能更优


- **ROC (Receiver Operating Characteristic) 曲线**：接受者操作特性曲线。与P-R曲线类似，逐次设置阈值把样本预测为“正例”和“反例”，计算当前的真正例率和假正例率。ROC曲线其与坐标轴围成的面积AUC越大性能越优

- 纵轴：是“真正例率” (True Positive Rate, 简称TPR) ；

$$TPR = \frac{TP}{TP + FN}, \quad (\text{灵敏度})$$

- 横轴为“假正例率” (False Positive Rate, 简称FPR) ；

$$FPR = \frac{FP}{TN + FP} \cdot (1 - \text{特异性})$$





e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m_+ = m_- = 4$ ）进行预测，假设预测结果为：

(s1, 0.77, +)、(s2, 0.65, -)、(s3, 0.56, +)、(s4, 0.56, -),
(s5, 0.50, +)、(s6, 0.30, +)、(s7, 0.20, -)、(s8, 0.15, -)


真实标签

预测概率

设将x轴（假正例率轴）的单位刻度定为 $1/m_-$ ，y轴（真正例率轴）的单位刻度定为 $1/m_+$ ，试绘制ROC曲线

阈值：0.77

真实情况	预测结果		
	+	-	
+	1 TP	3 FN	$=1/4$
-	0 FP	4 TN	$=0$






e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m^+ = m^- = 4$ ）进行预测，假设预测结果为：

(s1, 0.77, +)、(s2, 0.65, -)、(s3, 0.56, +)、(s4, 0.56, -),
(s5, 0.50, +)、(s6, 0.30, +)、(s7, 0.20, -)、(s8, 0.15, -)

设将x轴（假正例率轴）的单位刻度定为 $1/m^-$ ，y轴（真正例率轴）的单位刻度定为 $1/m^+$ ，试绘制ROC曲线

阈值：0.65

真实情况	预测结果		
	+	-	
+	1 TP	3 FN	$=1/4$
-	1 FP	3 TN	$=1/4$





e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m^+ = m^- = 4$ ）进行预测，假设预测结果为：


$(s_1, 0.77, +)$ 、 $(s_2, 0.65, -)$ 、 $(s_3, 0.56, +)$ 、 $(s_4, 0.56, -)$ ，

$(s_5, 0.50, +)$ 、 $(s_6, 0.30, +)$ 、 $(s_7, 0.20, -)$ 、 $(s_8, 0.15, -)$

设将x轴（假正例率轴）的单位刻度定为 $1/m^-$ ，y轴（真正例率轴）的单位刻度定为 $1/m^+$ ，试绘制ROC曲线

阈值：0.56

真实情况	预测结果			
	+		-	
+	2	TP	2	FN = 1/2
-	2	FP	2	TN = 1/2





e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m^+ = m^- = 4$ ）进行预测，假设预测结果为：


(s1, 0.77, +)、(s2, 0.65, -)、(s3, 0.56, +)、(s4, 0.56, -),

(s5, 0.50, +)、(s6, 0.30, +)、(s7, 0.20, -)、(s8, 0.15, -)

设将x轴（假正例率轴）的单位刻度定为 $1/m^-$ ，y轴（真正例率轴）的单位刻度定为 $1/m^+$ ，试绘制ROC曲线

阈值：0.50

真实情况	预测结果		
	+	-	
+	3 TP	1 FN	$=3/4$
-	2 FP	2 TN	$=1/2$





e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m^+ = m^- = 4$ ）进

行预测，假设预测结果为：


(s1, 0.77, +)、(s2, 0.65, -)、(s3, 0.56, +)、(s4, 0.56, -),

(s5, 0.50, +)、(s6, 0.30, +)、(s7, 0.20, -)、(s8, 0.15, -)

设将x轴（假正例率轴）的单位刻度定为 $1/m^-$ ，y轴（真正例率轴）的单位刻度定为 $1/m^+$ ，试绘制ROC曲线

阈值：0.30

真实情况	预测结果				
	+	-			
+	4 TP	0 FN	=1		
-	2 FP	2 TN	=1/2		





e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m^+ = m^- = 4$ ）进行预测，假设预测结果为：


$(s_1, 0.77, +)$ 、 $(s_2, 0.65, -)$ 、 $(s_3, 0.56, +)$ 、 $(s_4, 0.56, -)$ ，

$(s_5, 0.50, +)$ 、 $(s_6, 0.30, +)$ 、 $(s_7, 0.20, -)$ 、 $(s_8, 0.15, -)$

设将x轴（假正例率轴）的单位刻度定为 $1/m^-$ ，y轴（真正例率轴）的单位刻度定为 $1/m^+$ ，试绘制ROC曲线

阈值：0.20

真实情况	预测结果				
	+	-			
+	4 TP	0 FN	=1		
-	3 FP	1 TN	=3/4		





e.g 用已经训练好的学习器对8个测试样本（4个正例，4个反例，即 $m^+ = m^- = 4$ ）进行预测，假设预测结果为：


$(s1, 0.77, +)$ 、 $(s2, 0.65, -)$ 、 $(s3, 0.56, +)$ 、 $(s4, 0.56, -)$,

$(s5, 0.50, +)$ 、 $(s6, 0.30, +)$ 、 $(s7, 0.20, -)$ 、 $(s8, 0.15, -)$

设将x轴（假正例率轴）的单位刻度定为 $1/m^-$ ，y轴（真正例率轴）的单位刻度定为 $1/m^+$ ，试绘制ROC曲线

阈值：0.15

真实情况	预测结果				
	+	-			
+	4 TP	0 FN	=1		
-	4 FP	0 TN	=1		





在pytorch里绘制ROC曲线:

```
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve, auc

# 样本数据: 预测概率和真实标签
data = [(0.77, 1), (0.65, 0), (0.56, 1), (0.56, 0), (0.50, 1), (0.30,
1), (0.20, 0), (0.15, 0)]
y_scores = [x[0] for x in data]
y_true = [x[1] for x in data]


# 计算ROC曲线和AUC值
fpr, tpr, thresholds = roc_curve(y_true, y_scores)
roc_auc = auc(fpr, tpr)

# 绘制ROC曲线
plt.figure()
plt.plot(fpr, tpr, color='darkorange',
lw=2, label='ROC curve (area = %0.2f)' %
roc_auc)
plt.plot([0, 1], [0, 1], color='navy',
lw=2, linestyle='--')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
```



在pytorch里绘制ROC曲线:

```
plt.xlabel('False Positive Rate')  
plt.ylabel('True Positive Rate')  
plt.title('Receiver Operating Characteristic (ROC) Curve')  
plt.legend(loc="lower right")  
plt.show()
```



3 回归任务的性能度量指标

➤ 用以下指标度量 n 个预测值 $\hat{y}$ 与测试样本标记值 y 的差异

平均绝对误差
Mean Absolute Error,
MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

均方误差
Mean-Square Error,
MSE

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

均方根误差
Root MSE

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

提问1：用于损失（代价）函数的MAE、MSE与
用于回归性能度量的MAE、MSE有什么区别联系？

提问2：为什么用于**回归**的损失（代价）函数和性能度量函数形式一致，
而用于**分类**的损失函数和性能度量方法不一样？

损失函数	表达式
L2损失（L2 loss）均方误差	$Loss = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$
交叉熵损失（cross-entropy loss）	$Loss = \frac{1}{m} \sum_i (-y_i \cdot \ln \hat{y}_i - (1 - y_i) \cdot \ln(1 - \hat{y}_i))$

为什么加
系数2？

注：此处损失函数是定义在批量样本（ m 个）上的损失，又称为“代价函数”



残差平方和 SSE Sum of Squares due to Error	$SSE = \sum_{i=1}^n (\hat{y}_i - y_i)^2$
回归平方和 SSR Sum of Squares of Regression	$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
总离平方和 SST Total Sum of Squares	$SST = \sum_{i=1}^n (y_i - \bar{y})^2$
R-平方系数 (决定系数) R-square	$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$

SST是方差，可解释
SSE是残差，不可解释

分子是残差平方之和，分母是总方差， R^2 是（总方差 - 残差平方和）/ 总方差”，即能够描述的“变化程度”占真实数据“变化程度”的比例

- 数据的总方差 $SST = SSR + SSE$ 。 R^2 系数越接近1表明拟合优度越


证明:
$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$= \sum_{i=1}^n (y_i - \hat{y}_i + \hat{y}_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y})$$

$\swarrow$
SSE
 $\swarrow$
SSR
 $\rightarrow$ = 0 ?



e.g 2020年3月对美国新冠病毒感染数量变化进行的回归分析





武汉大学
WUHAN UNIVERSITY

05 模型的比较检验 *

Comparative testing of models *

1 比较检验的目的

- 统计假设检验 (hypothesis test) 为我们进行模型性能比较提供了重要依据。基于假设检验结果可推断出，若**在测试集上观察到模型A比B好，则A的泛化性能是否在统计意义上优于B，以及这个结论的把握有多大？**



阅读后两页PPT前，建议先复习《概率论》教材第8章内容，做一遍 P_{262} 例题8.2.2

2 单模型泛化错误率检验 t 检验

- 模型A通过多次留出法或是交叉验证法等进行多次测试，会得到 k 个测试错误率 $\hat{\epsilon}_1, \hat{\epsilon}_2, \dots, \hat{\epsilon}_k$ ，则平均测试错误率 μ 和方差 σ^2 为

$$\mu = \frac{1}{k} \sum_{i=1}^k \hat{\epsilon}_i, \quad \sigma^2 = \frac{1}{k-1} \sum_{i=1}^k (\hat{\epsilon}_i - \mu)^2$$


- 将这 k 个测试错误率看作泛化错误率 ϵ_0 的独立采样，用 “ t 检验” 检验模型的泛化错误率是否满足：

$$H_0: \mu = \epsilon_0 \leftrightarrow H_1: \mu \neq \epsilon_0 \quad \text{双边检验}$$

- 构造统计检验量 τ_t 服从自由度为 $k-1$ 的 t 分布，确定拒绝域

$$\tau_t = \frac{\sqrt{k}(\mu - \epsilon_0)}{\sigma} \sim t(k-1) \quad \text{拒绝域} \{ |\tau_t| > \tau_{t, \alpha/2}(k-1) \}$$

显著性水平



3 两模型边际同质性检验

McNemar检验



西瓜书P41

- 比较两个二元分类算法时，检验是这两个模型的**差别列联表**的行和列的边际频率是否相等（即是否存在“边际同质性”）

模型 B	模型 A	
	正确	错误
正确	e_{00}	e_{01}
错误	e_{10}	e_{11}

- **假设是两模型性能相同**则应有 $e_{01} = e_{10}$ ，那么变量 $|e_{01} - e_{10}|$ 应当服从**正态分布**，下面统计量服从自由度为1的卡方分布，且小于临界值时不能拒绝原假设

$$\tau_{\chi^2} = \frac{(|e_{01} - e_{10}| - 1)^2}{e_{01} + e_{10}} \sim \chi^2(1)$$

$$\tau_{\chi^2} \quad \chi^2_{\alpha}$$

显著性水平



- 欠拟合与过拟合的问题本质上反映了模型复杂度和数据复杂度之间的**平衡问题**，体现了唯物辩证法中的平衡与适度原则。
- 在机器学习中，通过不断**调整模型参数、增加数据量、使用正则化**等方法来处理模型泛化问题，体现了实践与探索的精神。同学们要勇于尝试、不断探索未知领域，并在实践中不断学习和成长。

[1]. TangShusen. 统计学习理论之VC维究竟是什么[EB/OL][2018-12-30].

<https://tangshusen.me/2018/12/09/vc-dimension/>

请课后阅读西瓜书第2、12章



武漢大學
WUHAN UNIVERSITY

End of This Part
