



第七章：贝叶斯分类器

—— 自强弘毅 求是拓新 ——

|| 目 录 ||

CONTENTS

- 1 贝叶斯决策论
- 2 极大似然估计
- 3 朴素贝叶斯分类器
- 4 半朴素贝叶斯分类器
- 5 贝叶斯网
- 6 EM算法



01

贝叶斯决策论



- 贝叶斯决策论 (Bayesian decision theory) 是在**概率框架下**实施决策的基本方法
 - 对于**分类**任务, 在所有相关概率都已知的理想情形下, 贝叶斯决策考虑如何基于这些**概率**和**误判损失**来选择**最优**的类别标记
- 假设有 N **种**可能的类别标记, 即 $\mathcal{Y} = \{c_1, c_2, \dots, c_N\}$, λ_{ij} 是将一个真实标记为 c_j 的样本误分类为 c_i 所产生的**损失**



- 基于后验概率 $P(c_i | \mathbf{x})$ 可获得将样本 $\mathbf{x}$ 分类为 c_i 所产生的期望损失 (expected loss), 即在样本 $\mathbf{x}$ 上的“条件风险” (conditional risk)

$$R(c_i | \mathbf{x}) = \sum_{j=1}^N \lambda_{ij} P(c_j | \mathbf{x}) \quad \text{公式 (7.1)}$$

- 我们的任务是寻找一个判定准则 $h: \mathcal{X} \mapsto \mathcal{Y}$ 以最小化总体风险

$$R(h) = \mathbb{E}_{\mathbf{x}} [R(h(\mathbf{x}) | \mathbf{x})]$$



- 显然，对每个样本 $\mathbf{x}$ ，若 h 能最小化条件风险 $R(h(\mathbf{x}) | \mathbf{x})$ ，则总体风险 $R(h)$ 也将被最小化
- 这就产生了贝叶斯判定准则 (Bayes decision rule)：为最小化总体风险，只需在每个样本上选择那个能使条件风险 $R(c | \mathbf{x})$ 最小的类别标记，即

$$h^*(\mathbf{x}) = \operatorname{argmin}_{c \in \mathcal{Y}} R(c | \mathbf{x})$$

- 此时， h^* 称为贝叶斯最优分类器 (Bayes optimal classifier)，与之对应的总体风险 $R(h^*)$ 称为贝叶斯风险 (Bayes risk)



- $1 - R(h^*)$ 反映了分类器所能达到的最好性能，即通过机器学习所能产生的模型精度的理论上限

具体来说，若目标是**最小化分类错误率**，则误判损失 λ_{ij} 可写为

$$\lambda_{ij} = \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise} \end{cases} \quad \text{公式 (7.4)}$$

- 此时条件风险（即**分类错误率**）

$$R(c | \mathbf{x}) = 1 - P(c | \mathbf{x})$$



- 公式 (7.5)

$$R(c|\mathbf{x}) = 1 - P(c|\mathbf{x})$$

推导：由公式 (7.1) 和公式 (7.4) 可得

$$\begin{aligned} R(c_i|\mathbf{x}) &= 1 \cdot P(c_1|\mathbf{x}) + \dots + 1 \cdot P(c_{i-1}|\mathbf{x}) \\ &\quad + 0 \cdot P(c_i|\mathbf{x}) + 1 \cdot P(c_{i+1}|\mathbf{x}) + \dots \\ &\quad + 1 \cdot P(c_N|\mathbf{x}) \end{aligned}$$

又 $\sum_{j=1}^N P(c_j|\mathbf{x}) = 1$, 则

$$R(c_i|\mathbf{x}) = 1 - P(c_i|\mathbf{x})$$



- 于是，**最小化分类错误率的贝叶斯最优分类器**为

$$h^*(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c | \mathbf{x}) \quad \text{公式 (7.6)}$$

即对每个样本 $\mathbf{x}$ ，选择能使后验概率 $P(c | \mathbf{x})$ 最大的类别标记

- 不难看出，使用贝叶斯判定准则来最小化决策风险，首先要获得**后验概率** $P(c | \mathbf{x})$

然而，在现实中通常难以直接获得后验概率，机器学习所要实现的是**基于有限的训练样本尽可能准确地估计出后验概率** $P(c | \mathbf{x})$



- 主要有两种策略：

- 判别式模型 (discriminative models)

给定 $\mathbf{x}$ ，通过直接建模 $P(c | \mathbf{x})$ ，来预测 c

决策树，BP神经网络，支持向量机

- 生成式模型 (generative models)

先对联合概率分布 $P(\mathbf{x}, c)$ 建模，再由此获得 $P(c | \mathbf{x})$

生成式模型考虑

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})}$$



- 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})}$$

基于贝叶斯定理, $P(c | \mathbf{x})$ 可写成
公式 (7.8)

类标记 c 相对于样本 $\mathbf{x}$ 的
“类条件概率” (class-
conditional probability),
或称 “似然”

$$P(c | \mathbf{x}) = \frac{P(c) P(\mathbf{x} | c)}{P(\mathbf{x})}$$

先验概率
样本空间中各类样本所占的
比例, 可通过各类样本出现
的频率估计 (大数定理)

“证据” (evidence)
因子, 与类标记无关



- 对类条件概率 $P(\boldsymbol{x} | c)$ 来说，由于它涉及关于 $\boldsymbol{x}$ 所有属性的联合概率，直接根据样本出现的频率来估计将会遇到严重的困难。例如，假设样本的 d 个属性都是二值的，则样本空间将有 2^d 种可能的取值
- 在现实应用中，这个值往往远大于训练样本数 m ，也就是说，很多样本取值在训练集中根本**没有出现**，直接使用频率来估计 $P(\boldsymbol{x} | c)$ 显然不可行，因为“**未被观测到**”与“**出现概率为零**”通常是不同的



02

极大似然估计



- 估计类条件概率的常用策略：先假定其具有某种确定的概率分布形式，再基于训练样本对概率分布参数估计
- 记关于类别 c 的类条件概率为 $P(\mathbf{x} | c)$ ，假设 $P(\mathbf{x} | c)$ 具有确定的形式并且被参数向量 θ_c 唯一确定，我们的任务就是利用训练集 D 估计参数 θ_c
- 为明确起见，我们将 $P(\mathbf{x} | c)$ 记为 $P(\mathbf{x} | \theta_c)$



- 概率模型的**训练**过程就是参数**估计**过程，统计学界的两个学派提供了不同的方案：
 - **频率主义学派** (frequentist) 认为参数虽然未知，但却存在客观值，因此可通过优化似然函数等准则来确定参数值
 - **贝叶斯学派** (Bayesian) 认为参数是未观察到的**随机变量**，其本身也可有分布，因此可假定参数服从一个先验分布，然后基于观测到的数据计算参数的后验分布
 - **极大似然估计**属于频率主义



- 令 D_c 表示训练集 D 中第 c 类样本的组成的集合，假设这些样本是**独立同分布**的，则参数 θ_c 对于数据集 D_c 的**似然是**

$$P(D_c | \theta_c) = \prod_{x \in D_c} P(x | \theta_c) \quad \text{公式 (7.9)}$$

- 对 θ_c 进行极大似然估计，寻找能最大化似然 $P(D_c | \theta_c)$ 的参数值 $\hat{\theta}_c$ 。直观上看，极大似然估计是试图在 θ_c 所有可能的取值中，**找到一个使数据出现的“可能性”最大的值**
- 式 (7.9) 的连乘操作易造成下溢，通常使用**对数似然** (log-likelihood)
$$\begin{aligned} LL(\theta_c) &= \log P(D_c | \theta_c) \\ &= \sum_{x \in D_c} \log P(x | \theta_c) \end{aligned}$$



- 此时参数 θ_c 的极大似然估计 $\hat{\theta}_c$ 为

$$\hat{\theta}_c = \underset{\theta_c}{\operatorname{argmax}} LL(\theta_c)$$

例如，在连续属性情形下，**假设**概率密度函数

$p(\mathbf{x} | c) \sim \mathcal{N}(\boldsymbol{\mu}_c, \boldsymbol{\sigma}_c^2)$ ，则参数 $\boldsymbol{\mu}_c$ 和 $\boldsymbol{\sigma}_c^2$ 的极大似然估计为

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{|D_c|} \sum_{\mathbf{x} \in D_c} \mathbf{x},$$

$$\hat{\boldsymbol{\sigma}}_c^2 = \frac{1}{|D_c|} \sum_{\mathbf{x} \in D_c} (\mathbf{x} - \hat{\boldsymbol{\mu}}_c) (\mathbf{x} - \hat{\boldsymbol{\mu}}_c)^T$$

通常采用梯度方法求解上述优化问题。



- 也就是说，通过极大似然法得到的正态分布均值就是样本均值，方差就是 $(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)^T$ 的均值，这显然是一个**符合直觉**的结果
- 需注意的是，这种参数化的方法虽能使类条件概率估计变得相对简单，但估计结果的准确性**严重依赖于所假设的概率分布形式是否符合潜在的真实数据分布**，一定程度上要应用与任务有关的经验知识



03

朴素贝叶斯分类器



- 估计后验概率 $P(c | \mathbf{x})$ 的主要困难：类条件概率 $P(\mathbf{x} | c)$ 是所有属性上的**联合概率**，难以从有限的训练样本估计而得
- 朴素贝叶斯分类器 (Naïve Bayes Classifier) 采用了“**属性条件独立性假设**”：每个属性独立地对分类结果发生影响
- 基于**属性条件独立性假设**，公式 (7.8) 可重写为

$$P(c | \mathbf{x}) = \frac{P(c) P(\mathbf{x} | c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i | c)$$

其中 d 为属性数目， x_i 为 $\mathbf{x}$ 在第 i 个属性上的取值



- 公式 (7.14)

$$P(c | \mathbf{x}) = \frac{P(c) P(\mathbf{x} | c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i | c)$$

- 由于对所有类别来说 $P(\mathbf{x})$ 相同, 因此基于 (7.6) 的贝叶斯判定准则有

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

这就是**朴素贝叶斯分类器**的表达式

- 朴素贝叶斯分类器的训练器的训练过程就是**基于**训练集估计**类先验概率** $P(c)$ 并为每个属性估计**类条件概率** $P(x_i | c)$



- 令 D_c 表示训练集 D 中第 c 类样本组成的集合，若有**充足的**独立同分布样本，则可容易地估计出**类先验概率**

$$P(c) = \frac{|D_c|}{|D|} \quad \text{公式 (7.16)}$$

- 对**离散属性**而言，令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样本组成的集合，则**类条件概率** $P(x_i | c)$ 可估计为

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|} \quad \text{公式 (7.17)}$$

- 对**连续属性**而言可考虑概率密度函数，**假定** $p(x_i | c) \sim \mathcal{N}(\mu_{c,i}, \sigma_{c,i}^2)$ ，其中 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 分别是第 c 类样本在第 i 个属性上取值的均值和方差，则有

$$p(x_i | c) = \frac{1}{\sqrt{2\pi} \sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$



朴素贝叶斯分类器



武汉大学

WUHAN UNIVERSITY

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	硬挺	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	蜷缩	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

- 例子：用西瓜数据集3.0 (p84) 训练一个朴素贝叶斯分类器，对测试例“测1” (p151) 进行分类。估计先验概率与条件概率，计算验概率，比较并判别



- 若某个属性值在训练集中没有与某个类同时出现过，则直接计算该属性的类条件概率会出现问题，比如“敲声=清脆”测试例，训练集中没有该样例，因此连乘式计算的概率值为0，哪怕其他属性上明显像好瓜，分类结果都是“好瓜=否”，这显然不合理
- 为了避免其他属性携带的信息被训练集中未出现的属性值“抹去”，在估计概率值时通常要进行“拉普拉斯修正”（Laplacian correction）。随着训练集变大，修正所引入的影响会逐渐变小、可忽略。



- 令 N 表示训练集 D 中可能的类别数, N_i 表示第 i 个属性可能的取值数, 则式 (7.16) 和 (7.17) 分别修正为

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}$$

$$\hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

- 拉普拉斯修正等价于类别先验概率为均匀分布的后验期望值估计
- 现实任务中朴素贝叶斯分类器的使用: 预测速度要求高, 先计算各概率, 再“查表”; 任务数据更替频繁, 收到预测请求再估计概率 (“懒惰学习”); 数据不断增加, 仅修正新样本属性值涉及的概率 (增量学习) 等等



04

半朴素贝叶斯分类器




- 为了降低贝叶斯公式中估计后验概率的困难，朴素贝叶斯分类器采用了属性条件独立性假设；对属性条件独立性假设进行一定程度的放松，适当考虑一部分属性间相互依赖信息，由此产生了一类称为“半朴素贝叶斯分类器”（semi-naïve Bayes classifiers）的方法
- 半朴素贝叶斯分类器最常用的一种策略：“独依赖估计”（One-Dependent Estimator--ODE），假设每个属性在类别之外最多仅依赖一个其他属性，即

$$P(c | \mathbf{x}) \propto P(c) \prod_{i=1}^d P(x_i | c, pa_i)$$


其中 pa_i 为属性 x_i 所依赖的属性，称为 x_i 的父属性




- 对每个属性 x_i ，若其父属性 pa_i 已知，则可估计概值 $P(x_i | c, pa_i)$ ，于是问题的关键转化为如何确定每个属性的父属性
- 最直接的做法是假设所有属性都依赖于同一属性，称为“超父”（super-parent），然后通过交叉验证等模型选择方法来确定超父属性，由此形成了 SPODE（Super-Parent ODE）方法。然后估计 $P(x_i | c, pa_i)$



(a) NB



(b) SPODE



(c) TAN

- TAN (Tree augmented Naïve Bayes) 是在**最大带权生成树算法**的基础上，通过以下步骤将属性间依赖关系**约简**为上页图 (c) 所示的树形结构

- 计算任意两个属性之间的条件互信息

$$I(x_i, x_j | y) = \sum_{x_i, x_j; c \in \mathcal{Y}} P(x_i, x_j | c) \log \frac{P(x_i, x_j | c)}{P(x_i | c) P(x_j | c)}$$

- 以属性为结点构建完全图，任意两个结点之间边的**权重**设为 $I(x_i, x_j | y)$
- 构建此完全图的最大带权生成树，挑选根变量，将边设为有向
- 加入类别节点 y ，增加从 y 到每个属性的有向边

TAN仅保留了强相关属性之间的依赖



- **AODE** (Averaged One-Dependent Estimator) 是一种基于集成学习机制、更为强大的分类器
 - 尝试将**每个属性**作为超父构建SPODE (**更合理!**)
 - 将具有**足够训练数据支撑**的SPODE集成起来作为最终结果

$$P(c | \mathbf{x}) \propto \sum_{|D_{x_i}| \geq m'}^d P(c, x_i) \prod_{j=1}^d P(x_j | c, x_i) \quad \text{公式 (7.23)}$$

其中, D_{x_i} 是在第 i 个属性上取值 x_i 的样本的集合, m' 为阈值常数

- 显然, AODE需估计 $P(c, x_i)$ 和 $P(x_j | c, x_i)$, 有

$$\hat{P}(c, x_i) = \frac{|D_{c, x_i}| + 1}{|D| + N_i}$$

$$\hat{P}(x_j | c, x_i) = \frac{|D_{c, x_i, x_j}| + 1}{|D_{c, x_i}| + N_j}$$

其中, N_i 是在第 i 个属性上取值数, D_{c, x_i} 是类别为 c 且在第 i 个属性上取值为 x_i 的样本集合, D_{c, x_i, x_j} 是类别为 c 且在第 i 和第 j 个属性上取值分别为 x_i 和 x_j 的样本集合



- 既然将属性条件独立性假设放松为独依赖假设可能获得泛化性能的提升，那么能否通过考虑属性间的高阶依赖来进一步提升泛化性能？也就是说将式 (7.21) 中的属性 pa_i 替换为包含 k 个属性的集合 $\mathbf{pa}_i$ ，从而将ODE拓展为 k DE
- 需注意的是，随着 k 的增加，准确估计概率 $P(x_i | y, \mathbf{pa}_i)$ 所需的训练样本数量将以指数级增加，因此若训练数据非常充分，泛化性能有可能提升；但在有限样本条件下，则又陷入估计高阶联合概率的泥沼。



05


贝叶斯网



- 贝叶斯网 (Bayesian network) 亦称“信念网”，它借助有向无环图来刻画属性间的依赖关系（概率依赖网络），并使用条件概率表来表述属性的联合概率分布
- 具体来说，一个贝叶斯网 B 由结构 G 和参数 Θ 两部分构成，即 $B = \langle G, \Theta \rangle$ ；网络结构 G 是一个有向无环图，其每个结点对应于一个属性，若两个属性有直接依赖关系，则它们由一条边连接起来；参数 Θ 定量描述这种依赖关系，假设属性 x_i 在 G 中的父结点集为 π_i ，则 Θ 包含了每个属性的条件概率表 $\theta_{x_i|\pi_i} = P_B(x_i | \pi_i)$



- **贝叶斯网** (Bayesian network) 亦称“信念网”，它借助有向无环图来刻画属性间的依赖关系，并使用条件概率表来表述属性的联合概率分布



西瓜问题的一种贝叶斯网结构以及属性“根蒂”的条件概率表

- 从网络图结构可以看出：“色泽”直接依赖于“好瓜”和“甜度”
- 从条件概率表可以得到：“根蒂”对“甜度”的**量化**依赖关系 $P(\text{根蒂} = \text{硬挺} | \text{甜度} = \text{高}) = 0.1$



- 贝叶斯网有效地表达了**属性间的条件独立性**。给定父结点集，贝叶斯网**假设每个属性与它的非后裔属性独立**
- $B = \langle G, \Theta \rangle$ 将属性 $x_1, x_2, \dots, x_d$ 的联合概率分布定义为

$$P_B(x_1, x_2, \dots, x_d) = \prod_{i=1}^d P_B(x_i | \pi_i) = \prod_{i=1}^d \theta_{x_i | \pi_i} \quad \text{公式 (7.26)}$$


上页图的联合概率分布定义为

$$P(x_1, x_2, x_3, x_4, x_5) = P(x_1)P(x_2)P(x_3 | x_1)P(x_4 | x_1, x_2)P(x_5 | x_2)$$


显然， x_3 和 x_4 在给定 x_1 取值时独立， x_4 和 x_5 在给定 x_2 的取值时独立，记为 $x_3 \perp x_4 | x_1$ 和 $x_4 \perp x_5 | x_2$




- 贝叶斯网中三个变量之间的典型依赖关系：



同父结构



V型结构



顺序结构

- 在“同父” (common parent) 结构中，给定父结点 x_1 的取值，则 x_3 与 x_4 条件独立；在“顺序”结构中，给定 x 的值，则 y 与 z 条件独立；V型结构亦称“冲撞”结构，给定子结点 x_4 的取值， x_1 与 x_2 必不独立；若 x_4 的取值完全未知，则V型结构下 x_1 与 x_2 是相互独立的



- 做一个简单的验证

$$\begin{aligned} P(x_1, x_2) &= \sum_{x_4} P(x_1, x_2, x_4) \\ &= \sum_{x_4} P(x_4 | x_1, x_2) P(x_1) P(x_2) \\ &= P(x_1) P(x_2) \end{aligned}$$

这样的独立性被称为 “**边际独立性**” (marginal independence) , 记为 $x_1 \perp\!\!\!\perp x_2$




贝叶斯网：结构




武汉大学
WUHAN UNIVERSITY


- 贝叶斯网中三个变量之间的典型依赖关系：



同父结构




V型结构



顺序结构

- 分析**有向图中变量间的条件独立性，可使用“有向分离” (D-separation)

- 所有V型结构父结点相连
- 有向边变成无向边



由此产生的图称为**道德图**，以此

39 找出所有的条件独立关系

自强弘毅 求是拓新



- 贝叶斯网络首要任务：根据训练集找出结构最“恰当”的贝叶斯网结构（**评分搜索**）
- 我们用**评分函数**评估贝叶斯网与训练数据的契合程度
 - “**最小描述长度**”（Minimal Description Length）
综合编码长度（包括描述网路、编码数据）最短
- 若**网络结构已知**，即属性间的依赖关系已知，则贝叶斯网的学习过程相对简单，只需通过对训练样本“**计数**”，估计出每个结点的**条件概率表**即可



- 常用评分函数通常基于**信息论准则**，此类准则将学习问题看作一个**数据压缩任务**，学习的目标是找到一个能以最短编码长度描述训练数据的模型，此时编码的长度包括了描述模型自身所需的编码位数和使用该模型描述数据所需的编码位数
- 对贝叶斯网学习而言，**模型就是一个贝叶斯网**，同时每个贝叶斯网描述了一个在训练数据上的概率分布，自有一套编码机制能使那些经常出现的样本有更短的编码
- 选择综合编码长度最短的贝叶斯网，亦即**MDL准则**



- 给定训练集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$, 贝叶斯网 $B = \langle G, \Theta \rangle$ 在 D 上的评分函数可写为

$$s(B | D) = f(\theta)|B| - LL(B | D) \quad \text{公式 (7.28)}$$

其中, $|B|$ 是贝叶斯网的参数个数; $f(\theta)$ 表示描述每个参数 θ 所需的编码位数

- 贝叶斯网的对数似然如下

$$LL(B | D) = \sum_{i=1}^m \log P_B(\mathbf{x}_i) \quad \text{公式 (7.29)}$$



- 显然，式 (7.28) 的第一项是计算编码贝叶斯网 B 所需的编码位数 (**结构风险**)，第二项是计算 B 所对应的概率分布 P_B 对 D 描述多好 (**经验风险**)，学习任务就转化为一个优化任务，即寻找一个贝叶斯网 B 使评分函数 $s(B | D)$ **最小**

- 若 $f(\theta) = 1$ ，即每个参数用 1 编码位描述，则得到 **AIC** (Akaike Information Criterion) **评分函数**

$$\text{AIC}(B | D) = |B| - LL(B | D)$$

- 若 $f(\theta) = \frac{1}{2} \log m$ ，即每个参数用 $\frac{1}{2} \log m$ 编码位描述，则得到 **BIC** (Bayesian Information Criterion) **评分函数**

$$\text{BIC}(B | D) = \frac{\log m}{2} |B| - LL(B | D)$$



- 不难发现，若贝叶斯网 $B = \langle G, \Theta \rangle$ 的**网络结构 G 固定**，则评分函数 $s(B | D)$ 的第一项为常数；此时最小化 $s(B | D)$ 等价于对参数 Θ 的**极大似然估计**，由式 (7.29) 和 (7.26) 可知，参数 $\theta_{x_i | \pi_i}$ **能直接在训练数据 D 上通过经验估计获得**，即

$$\theta_{x_i | \pi_i} = \hat{P}_D(x_i | \pi_i)$$

其中 $\hat{P}_D(\cdot)$ 是 D 上的**经验分布**，因此，为了最小化评分函数 $s(B | D)$ ，只需对**网络结构进行搜索**（**NP难问题**，**贪心法**、**约束法**），而候选结构的**最优参数**可直接在训练集上计算得到



- 训练好的贝叶斯网能用来回答查询。通过已知变量观测值来推测待查询变量的过程称为“**推断**” (inference)，已知变量观测值称为“**证据**” (evidence)
- 最理想的是根据贝叶斯网络定义的**联合概率分布**来精确计算后验概率 (NP难)，在现实应用中，贝叶斯网的**近似推断**常使用**吉布斯采样** (Gibbs sampling) 来完成
- 吉布斯采样随机产生一个与证据 $\mathbf{E} = \mathbf{e}$ **一致** 的样本 $\mathbf{q}^0$ 作为初始点，然后每步从当前样本出发产生下一个样本。假定经过 T 次采样的得到与 $\mathbf{q}$ 一致的样本共有 n_q 个，则可近似估算出后验概率



- 吉布斯采样算法估算出的后验概率为

$$P(\mathbf{Q} = \mathbf{q} \mid \mathbf{E} = \mathbf{e}) \simeq \frac{n_q}{T}$$

吉布斯采样是与证据一致的**子空间**的随机游走，每一步仅依赖于前一步的状态，这是一个“**马尔可夫链**”

- 在一定条件下，无论从什么初始状态开始，**马尔可夫链**第 t 步的状态分布在 $t \rightarrow \infty$ 时**必收敛于个平稳分布**；对于吉布斯采样来说，这个分布**恰好**是 $P(\mathbf{Q} \mid \mathbf{E} = \mathbf{e})$ ，因此在 T 很大时，吉布斯采样相当于根据 $P(\mathbf{Q} \mid \mathbf{E} = \mathbf{e})$ 采样，从而保证了上式收敛于 $P(\mathbf{Q} = \mathbf{q} \mid \mathbf{E} = \mathbf{e})$
- 吉布斯采样收敛速度较慢，并且若贝叶斯网络存在极端概率0或1时会给出错误估计



06

EM算法



- **“不完整”的样本**：西瓜已经脱落的根蒂，无法看出是“蜷缩”还是“坚挺”，则训练样本的“根蒂”属性变量值未知，如何计算？
- 未观测的变量称为 **“隐变量”** (latent variable) 令 $\mathbf{x}$ 表示已观测变量集， $\mathbf{z}$ 表示隐变量集，若欲对模型参数 Θ 做极大似然估计，则应最大化**对数似然函数**

$$LL(\Theta | \mathbf{X}, \mathbf{Z}) = \ln P(\mathbf{X}, \mathbf{Z} | \Theta)$$



- 由于 $\mathbf{z}$ 是隐变量，上式无法直接求解。此时我们可以通过对 $\mathbf{z}$ 计算期望，来最大化已观测数据的对数“**边际似然**” (marginal likelihood)

$$LL(\Theta | \mathbf{X}) = \ln P(\mathbf{X} | \Theta) = \ln \sum_{\mathbf{z}} P(\mathbf{X}, \mathbf{z} | \Theta) \quad \text{公式 (7.35)}$$

- **EM** (Expectation-Maximization) 是常用的估计参数隐变量的利器
 - 当参数 Θ 已知，则可根据训练数据推断出最优隐变量的值 (**E步**)
 - 当 $\mathbf{z}$ 已知，则可对 Θ 做极大似然估计 (**M步**)



- 于是，以初始值 Θ^0 为起点，对式子 (7.35)，可迭代执行以下步骤直至收敛
 - 基于 Θ^t 推断隐变量 $\mathbf{z}$ 的期望，记为 $\mathbf{z}^t$
 - 基于已观测到变量 $\mathbf{x}$ 和 $\mathbf{z}^t$ 对参数 Θ 做极大似然估计，记为 Θ^{t+1}

这就是EM算法的原型

- 进一步，若我们不是取 $\mathbf{z}$ 的期望，而是基于 Θ^t 计算隐变量的概率分布，又应该怎么做呢？



- 做法如下

- E步 (Expectation) : 以当前参数 Θ^t 推断隐变量分布 $P(\mathbf{Z} | \mathbf{X}, \Theta^t)$, 并计算**对数似然** $LL(\Theta | \mathbf{X}, \mathbf{Z})$ **关于 $\mathbf{Z}$ 的期望** $Q(\Theta | \Theta^t) = \mathbb{E}_{\mathbf{Z} | \mathbf{X}, \Theta^t} LL(\Theta | \mathbf{X}, \mathbf{Z})$

- M步 (Maximization) : 寻找参数**最大化期望似然**, 即 $\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta | \Theta^t)$

- EM算法使用两个步骤交替计算: **第一步计算期望**, 利用当前估计的参数值计算对数似然的期望值; **第二步最大化**, 寻找能使E步产生的似然期望最大化的参数值, 直至**收敛到全局最优解**

- 隐变量估计问题也可通过梯度下降等优化算法求解, 但隐变量数目增加会给梯度计算带来麻烦。EM算法可看作是非梯度优化算法



**课后阅读西瓜书第7章，并依托
某种概率结构，深入领悟EM算
法的迭代计算过程**

贝叶斯思维

高手必备技能



武汉大学
WUHAN UNIVERSITY

谢谢

自强弘毅 求是拓新