



武漢大學

WUHAN UNIVERSITY

# 第5讲 支持向量机

---





武汉大学  
WUHAN UNIVERSITY

01 间隔与支持向量

02 对偶问题

03 软间隔与正则化

04 核方法

05 非线性支持向量机示例





武汉大学  
WUHAN UNIVERSITY

# 01 间隔与支持向量

Margin and Support Vector

---





- 弗拉基米尔·万普尼克 (Vladimir Naumovich Vapnik) , 俄罗斯统计学家、数学家。他是统计学习理论 (Statistical Learning Theory) 的主要创建人之一。机器学习中的支持向量机方法、VC 维理论等都是由万普尼克提出的




万普尼克  
Vladimir Naumovich Vapnik

- 支持向量机 (Support Vector Machine, SVM) 是1964年被提出, 且在二十世纪90年代快速发展的一种统计机器学习方法。SVM在深度神经网络广泛应用前, 被认为是**最优秀**的模式识别方法之一。至今仍在很多工程应用上发挥作用, 是机器学习里最经典的方法之一



三个线性分类器，都能很好地将当前的样例分隔开



哪一个在**未来**样例上可能会获得更好表现？



“正中间” 分类器：对两类样本交汇区域的分类能力更强

稳健性更好，泛化能力更强






都是“正中间”分类器，但是左边的比右边的更好


与两类当前边界越远，对未来两类样本的越界点更少误判


如何寻找具有**最大间隔**（缓冲区宽度）的线性分类器？

- 假设一个二分类训练集**线性可分**，即一个**分类超平面**能将其线性分隔，则分别向两个方向**平移**分类超平面，在与两个类的数据点**首次接触**后即停止移动，形成了**两个平行超平面**
- 这两个平行超平面在两类数据之间就形成了一个无样例数据的**缓冲区**，这个缓冲区的宽度就是前述分类超平面的**间隔**，是衡量分类超平面的一个**重要指标**









点 $x$ 到超平面的代数距离

$$d_A(x, \pi) \equiv d(x, (w, b)) = \frac{w \cdot x + b}{\|w\|}$$



**定义 (数据集的线性可分性)** 给定一个数据集

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

其中,  $x_i \in X = R^n$ ,  $y_i \in Y = \{+1, -1\}$ ,  $i = 1, 2, \dots, N$  如果存在某个超平面  $S$

$$w \cdot x + b = 0$$

能够将数据集的正实例点和负实例点**完全正确地划分到超平面的两侧**, 即对所有  $y_i = +1$  的实例, 有  $w \cdot x_i + b > 0$ , 对所有  $y_i = -1$  的实例  $i$  有  $w \cdot x_i + b < 0$ , 则称数据集  $T$  为**线性可分数据集**(linearly separable data set); 否则, 称数据集  $T$  **线性不可分**。





一般来说，一个点距离分离超平面的远近可以表示分类预测的**确信程度**。在超平面  $w \cdot x + b = 0$  确定的情况下， $|w \cdot x + b|$  能够相对地表示点  $x$  距离超平面的远近。而  $w \cdot x + b$  的符号与类标记  $y$  的符号是否一致能够表示分类是否正确。所以可用量  $y(w \cdot x + b)$  来表示分类的**正确性及确信度**，这就是**函数间隔**(functional margin)的概念。


定义 (**函数间隔**) 对于给定的训练数据集  $T$  和超平面  $(w, b)$ ，超平面  $(w, b)$  **关于样本点**  $(x_i, y_i)$  的函数间隔为

$$\hat{\gamma}_i = y_i(w \cdot x_i + b)$$

定义超平面  $(w, b)$  **关于训练数据集  $T$  的函数间隔** 为超平面  $(w, b)$  关于  $T$  中所有样本点  $(x_i, y_i)$  的**函数间隔之最小值**，即

$$\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i$$

- 函数间隔可以表示**分类的正确性及其强度**，但如果成比例地改变 $w$ 和 $b$ ，分隔超平面方程并没有改变，但函数间隔也成比例地改变（**Why?**）
- 因此，需要对分离超平面的法向量 $w$ 进行尺度规范化 $\|w\| = 1$ （单位法向量），使得间隔是**确定**的。归一化后的函数间隔，称为**几何间隔（几何距离）**



几何间隔示意图

$$\gamma_i = y_i \left( \frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$



定义 (**几何间隔**) 对于给定的训练数据集 $T$ 和超平面 $(w, b)$ , 超平面 $(w, b)$  **关于样本点** $(x_i, y_i)$ 的几何间隔为

$$\gamma_i = y_i \left( \frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$

定义超平面 $(w, b)$  **关于训练数据集 $T$ 的几何间隔**为超平面 $(w, b)$ 关于 $T$ 中所有样本点 $(x_i, y_i)$ 的**几何间隔之最小值**, 即

$$\gamma = \min_{i=1, \dots, N} \gamma_i$$

$$\gamma_i = \frac{\hat{\gamma}_i}{\|w\|}, \quad \gamma = \frac{\hat{\gamma}}{\|w\|}$$

几何间隔和函数间隔的比例关系



武汉大学  
WUHAN UNIVERSITY

# 02对偶问题

---





- 支持向量机 (Support Vector Machine) 的基本分类思想是
  - 找到**能够正确划分**训练数据集、并且**支持面间隔最大的分离超平面**
- 对**线性可分**训练数据集
  - 线性可分分离超平面可以有无穷多，但是支持面间隔最大的分离超平面则是**唯一**的。这时的分离超平面称为**硬间隔最大分离超平面**
- 对**轻微的线性不可分**训练数据集
  - 存在唯一的间隔最大分离超平面，称为**软间隔最大分离超平面**
- **间隔最大化**的直观解释是：
  - 对训练数据集找到**几何间隔最大**的超平面，意味着：不仅能将正负样例点分开，而且对**最难分的样例点**（离超平面最近的点）也有**足够大的确信度**将它们分开（最近距离最大）
  - 对未来的两类接触区域的实例点，有更好的分类能力**盈余**



- 对给定样例数据拟合一个支持向量机分类器（SVM Classifier），就是**求解**支持面间隔最大的分离超平面问题，可表示为如下约束最优化问题（体现了“**最大最小**”）：

$$\begin{aligned} \max_{w,b} \quad & \gamma \\ \text{s.t.} \quad & y_i \left( \frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma, \quad i = 1, 2, \dots, N \end{aligned}$$

- 希望最大化 训练数据集关于超平面 $(w, b)$ 的几何间隔 $\gamma$ ，约束条件是：超平面 $(w, b)$ 关于每个训练样本点的几何间隔至少是 $\gamma$ 。
- 考虑到几何间隔与函数间隔的关系，上面的最优化问题可以**改写**为：

$$\begin{aligned} \max_{w,b} \quad & \frac{\hat{\gamma}}{\|w\|} \\ \text{s.t.} \quad & y_i(w \cdot x_i + b) \geq \hat{\gamma}, \quad i = 1, 2, \dots, N \end{aligned}$$

**函数间隔  $\hat{\gamma}$  的取值并不影响最优化问题的解。**事实上，假设将  $w$  和  $b$  按比例改变为  $\lambda_w$  和  $\lambda_b$ ，这时函数间隔成为  $\lambda\hat{\gamma}$ 。函数间隔的这一改变对上面最优化问题的不等式约束没有影响，对目标函数的优化也没有影响，也就是说，它产生一个**等价的最优化问题**。这样，就**可以取**  $\hat{\gamma} = 1$ 。将  $\hat{\gamma} = 1$  代入上面的最优化问题，注意到最大化  $\frac{1}{\|w\|}$  和最小化  $\frac{1}{2} \|w\|^2$  是等价的，于是就得到下面的线性可分支持向量机学习的最优化问题：

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

这是一个**凸二次规划**(convex quadratic programming)问题。

- **凸优化问题**：目标函数与不等式约束是连续可导凸函数，等式约束是仿射函数。优点：**局部极值点就是全局极值点**
- **凸二次规划问题**：当目标函数是二次函数，不等式约束函数是仿射函数时，凸优化问题成为凸二次规划问题



- 求出凸二次规划问题的解，就给出了**线性可分支持向量机分类器**的定义

定义 (**线性可分支持向量机**) 给定线性可分训练数据集，通过间隔最大化或等价地求解相应的凸二次规划问题学习得到的分离超平面为

$$w^* \cdot x + b^* = 0$$

以及相应的**分类决策函数**


$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

称为线性可分支持向量机。


- 最大间隔分类器的**稳健性** (Robustness)
  - 不仅能对线性可分的训练数据正确分类，而且对未来的相对于拟合出的支持面有一定越界的实例点，仍能保持较好的分类性能
  - 进一步，在求解最大间隔分类器( $w, b$ )的过程中，即使有一些数值扰动，得到的分类器仍能较好地进行分类



- 在线性可分情况下，样本点中**与分离超平面距离最近的样本点**的样例称为**支持向量**(support vector)。支持向量是使**约束条件式等号成立的点**，也就是**函数间隔等于1的样例点**
- 对 $y_i = +1$ 的正例点，支持向量在超平面  $H_1: w \cdot x + b = 1$  上，超平面  $H_1$ 称为**正支持面（间隔正边界）**
- 对 $y_i = -1$ 的负例点，支持向量在超平面  $H_2: w \cdot x + b = -1$  上，超平面  $H_2$ 称为**负支持面（间隔负边界）**



- 求取分离面时，**只有支持向量在起作用，其他样例点并不起作用**——Hence the name
- 支持向量个数一般**很少**，所以**SVM是由少量“重要的”训练样本确定的**



## 1 支持向量机的模型


- 对于线性分类器而言，其**判决函数**：
- $$f(x) = \begin{cases} \mathbf{w}^T \mathbf{x}_i + w_0 \geq 1, y_i = 1 & (\text{正类}) \\ \mathbf{w}^T \mathbf{x}_i + w_0 = 0 & (\text{决策界}) \\ \mathbf{w}^T \mathbf{x}_i + w_0 \leq -1, y_i = -1 & (\text{负类}) \end{cases}$$
- 类比LR里面的线性回归预测值 $z$

- 用  $y(\mathbf{w}^T \mathbf{x} + w_0)$  的正负性来判定或表示分类的正确性，定义分类的函数间隔 (Functional margin) 和几何间隔 (Geometrical margin)

Tips

- 点 $x$ 到平面的距离：
$$\frac{f(x)}{\|\mathbf{w}\|} = \frac{\mathbf{w}^T \mathbf{x} + w_0}{\|\mathbf{w}\|}$$

点与平面内任意一点的连线，在平面的法向量上的投影长




- 根据点到分类平面的几何间隔，定义**支持向量**（support vector）为：


$$f(x_i^s) = \begin{cases} \mathbf{w}^T \mathbf{x}_i^{s+} + w_0 = 1, & y_i = 1 \\ \mathbf{w}^T \mathbf{x}_i^{s-} + w_0 = -1, & y_i = -1 \end{cases}$$

- 正反两类的支持向量到分类平面的距离和为：

$$\gamma = \frac{y_i \cdot f(\mathbf{x}_i^{s+})}{\|\mathbf{w}\|} + \frac{y_i \cdot f(\mathbf{x}_i^{s-})}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$



- 称  $\gamma$  为支持向量机模型里的**间隔**（margin）。分类决策界是最适合分开两类数据的一条“直线”。
- “**最适合**”的优化标准就是让这条直线离两边支持向量的间隔最大



- 可将训练样本完全正确分开的最大间隔超平面**存在且唯一**



## 2 支持向量机的学习准则

- 最大化间隔的优化准则表示为：

$$(\mathbf{w}, w_0)^* = \underset{\mathbf{w}, w_0}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{w}\|^2, \quad \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + w_0) \geq 1 \quad i=1, 2, \dots, m$$

- 最大化间隔的过程也是一个**不断找寻支持向量**的过程



- 先考虑一个**等式约束下的最优化问题**

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0, i = 1, 2, \dots, m \end{aligned}$$

- 约束条件将解的范围限定在一个称为**可行域**的范围内，此时不一定能找到使得  $\nabla f(x) = 0$  的点。只能满足于：在可行域内找到**使得  $f(x)$  最小的可行解**。使用拉格朗日乘子法可简化求解。
- 首先引入 Lagrange Multiplier  $\alpha \in \mathbb{R}^m$ ，构建 **Lagrange 函数**如下：

$$L(x, \alpha) = f(x) + \sum_{i=1}^m \alpha_i h_i(x)$$


- 求解方法：首先对 Lagrange 函数关于  $\alpha$  与  $x$  求偏导，并令其为 0：

$$\begin{cases} \nabla_x L(x, \alpha) = 0 \\ \nabla_\alpha L(x, \alpha) = 0 \end{cases}$$

- 求得  $x$ 即为在约束条件  $h_i(x)$  下的可行解。

- 示例：对于二维情形，在参数面中画出目标函数  $f(x,y)$  的多个等高线  $f(x,y)=d$ （图中虚线），一个约束曲线  $h(x,y)=0$ （图中绿线）。目标函数等高线与约束曲线只有三种关系：**相交、相切或没有交集**。没交集肯定不是解。相交点肯定不是最优值，因为在交点的左右邻域，肯定还存在有更大值和更小值的等高线（关键是存在更小值）。
- 只有在等高线与约束曲线**相切**时，才可能取得最优值（可行解）。因为只有在这种情况下，在约束曲线上的切点的左右邻域内，目标函数的值都大于（如图示）切点处的函数值，因此这个切点就是一个可行解。
- 结论：等式约束下目标函数极值点的**必要条件**是：在该点处，目标函数的等高线与约束曲线相切，**此时两曲线在该点处的法向量是平行的**

$$\nabla_x f(x) - \alpha \nabla_x h(x) = 0$$




- 再考虑**不等式约束下的最优化问题**:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & g(x) \leq 0 \end{aligned}$$



- Lagrange 函数:

$$L(x, \lambda) = f(x) + \lambda g(x)$$

- 可行解**必须落在约束区域  $\{g(x) \leq 0\}$  之内。



- 当约束区域**内部** $\{g(x) < 0\}$ **包含**目标函数原有的最优解时，此时约束条件自动满足，对后续优化不起作用，直接极小化目标函数  $f(x)$  求得无约束最优解即可。
- 当约束区域内部**不包含**目标函数原有的最优解，此时约束最优解只能落在**边界** $\{g(x) = 0\}$ 上（Why?），这等价于等式约束优化问题。








- 综上两种情况：要么最优解落在约束区域的边界上，要么最优解落在约束区域的内部（此时约束不起作用，令  $\lambda=0$  消去约束）。**综合起来有：**


$$\lambda g(x) = 0$$

- **$\lambda$  的取值问题。**在等式约束优化中，约束函数与目标函数的梯度只要平行即可，而在不等式约束中则不然。**若  $\lambda \neq 0$ ，这便说明可行解  $x$  是落在约束区域的边界上的。**边界点很多，哪些或哪个边界点才是其中的极小值点呢？——直观看，极小值点应尽量靠近原问题的最优解，由前面等式约束优化的讨论知道，可能的极值点处，**至少目标函数的等高线与约束函数相切。**
- 但是，在一些具体情形中，可能有多个切点。就图中所示的2个切点情况而言，左图的切点1，离目标函数原最优解的距离较远，而右图切点2离目标函数原最优解的距离较近。观察可知，在切点2处，**约束函数的梯度方向与目标函数的负梯度方向一致。**
- 这就要求拉格朗日乘子  $\lambda > 0$ ，且满足：
$$-\nabla_x f(x) = \lambda \nabla_x g(x)$$

✗ Not a constrained  
local minimum as  
 $-\nabla_{\mathbf{x}} f(\mathbf{x})$  points  
in towards the  
feasible region



✓ Is a constrained  
local minimum as  
 $-\nabla_{\mathbf{x}} f(\mathbf{x})$  points  
away from the  
feasible region



对于不等式约束，只要满足一定的条件，依然可以使用拉格朗日乘子法解决，这里的条件便是著名的 **KKT 条件**（Karush-Kuhn-Tucker），是对等式约束下**拉格朗日条件**在不等式约束下的推广。

- 下面给出形式化的 KKT 条件。先写出一般的不等式约束优化问题（转发为小于等于0）

$$\min_x f(x)$$

$$s.t. \quad h_i(x) = 0, i = 1, 2, \dots, m$$

$$g_j(x) \leq 0, j = 1, 2, \dots, n$$

- 利用广义Lagrange 函数改为无约束优化问题：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^m \alpha_i h_i(x) + \sum_{j=1}^n \beta_j g_j(x)$$

- 根据前面分析，加上约束后，可行解  $x$  需要满足的 **KKT 条件**是：

$$\nabla_x L(x, \alpha, \beta) = 0 \quad (1)$$

$$\beta_j g_j(x) = 0, j = 1, 2, \dots, n \quad (2)$$

$$h_i(x) = 0, i = 1, 2, \dots, m \quad (3)$$

$$g_j(x) \leq 0, j = 1, 2, \dots, n \quad (4)$$

$$\beta_j \geq 0, j = 1, 2, \dots, n \quad (5)$$

- 其中：（2）称**互补松弛条件**，（3~4）是原条件，（5）是**不等式约束要求的**。

- 回到前面的**最大间隔最优化问题**，称为**原始问题**。通过求解对偶问题的最优解来求解原始问题，称为**对偶方法**。
- **优点**：一是对偶问题更容易求解，二是利用拉格朗日系数可以直接得到支持向量，三是便于引入核函数，进行非线性分类。

首先构建拉格朗日函数（Lagrange function）。为此，对每一个不等式约束，引进拉格朗日乘子（Lagrange multiplier） $\alpha_i \geq 0, i = 1, 2, \dots, N$ ，定义拉格朗日函数：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$$

其中， $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$  为拉格朗日乘子向量。

根据拉格朗日对偶性，原始问题的对偶问题是**极大极小问题**：

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha)$$

所以，为了得到对偶问题的解，需要先求  $L(w, b, \alpha)$  对  $w, b$  的极小，再求对  $\alpha$  的极大。



(1) 求  $\min_{w,b} L(w,b,\alpha)$

将拉格朗日函数  $L(w,b,\alpha)$  分别对  $w$ 、 $b$  求偏导数并令其等于0。

$$\nabla_w L(w,b,\alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\nabla_b L(w,b,\alpha) = -\sum_{i=1}^N \alpha_i y_i = 0$$

得  $w = \sum_{i=1}^N \alpha_i y_i x_i$  (7.19)

$$\sum_{i=1}^N \alpha_i y_i = 0$$
 (7.20)

将式 (7.19) 代入拉格朗日函数 (7.18) , 并利用式 (7.20) , 即得

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left( \left( \sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \end{aligned}$$

即

$$\min_{w, b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

(2) 求  $\min_{w, b} L(w, b, \alpha)$  对  $\alpha$  的极大, 即是对偶问题

$$\max_{\alpha} \quad -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (7.21)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N$$





将式 (7.21) 的目标函数由求极大转换成求极小，就得到下面与之**等价的对偶最优化问题**：

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad (7.22)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (7.23)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N \quad (7.24)$$

对**线性可分**训练数据集，假设对偶最优化问题(7.22)~(7.24) 的解为  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$ ，可以由  $\alpha^*$  求得原始最优化问题的解  $w^*, b^*$ 。

定理7.2 设  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$  是对偶最优化问题(7.22)~(7.23)的解, 则存在下标  $j$ , 使得  $\alpha_j^* > 0$ ,

并可按下式求得原始最优化问题 (7.13) ~ (7.14) 的解  $w^*, b^*$  :

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad (7.25)$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (7.26)$$

证明 根据C.3, KKT条件成立, 即得

$$\nabla_w L(w^*, b^*, \alpha^*) = w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0 \quad (7.27)$$

$$\nabla_b L(w^*, b^*, \alpha^*) = -\sum_{i=1}^N \alpha_i^* y_i = 0$$

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) = 0, \quad i = 1, 2, \dots, N$$

$$y_i (w^* \cdot x_i + b^*) - 1 \geq 0, \quad i = 1, 2, \dots, N$$

$$\alpha_i^* \geq 0, \quad i = 1, 2, \dots, N$$



由此得

$$w^* = \sum_i \alpha_i^* y_i x_i$$

其中至少有一个  $\alpha_j^* > 0$  (用反证法, 假设  $\alpha^* = 0$ , 由式 (7.27) 可知  $w^* = 0$ , 而不是  $w^* = 0$  原始最优化问题 (7.13) ~ (7.14) 的解, 产生矛盾, 对此  $j$  有)

$$y_j(w^* \cdot x_j + b^*) - 1 = 0 \quad (7.28)$$

将式(7.25) 代入式(7.28)并注意到,  $y_j^2 = 1$  即得

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

由此定理可知, 分离超平面可以写成

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0 \quad (7.29)$$

分离决策函数可以写成

$$f(x) = \text{sign} \left( \sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* \right) \quad (7.30)$$

支持向量机的对偶形式, 也称:  
支持向量展开形式



算法7.2 (线性可分支持向量机学习算法)

输入：线性可分训练集  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ , 其中,  $x_i \in X = R^n$ ,  $y_i \in Y = \{-1, +1\}, i = 1, 2, \dots, N$

输出：分离超平面和分类决策函数

训练数据只以内积形式出现!

(1) 构造并求解约束最优化问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \underline{(x_i \cdot x_j)} - \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N$$

求得最优解  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$



(2) 计算

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

并选择  $\alpha^*$  的一个正分量  $\alpha_j^* > 0$ , 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (\underline{x_i \cdot x_j})$$

(3) 求得分离超平面  $w^* \cdot x + b^* = 0$

分类决策函数:  $f(x) = \text{sign}(w^* \cdot x + b^*)$

由上述可知,  $w^*$ 和 $b^*$ 只依赖于训练数据中对应于 $\alpha^* > 0$ 的样本点  $(x_i, y_i)$ , 对应于 $\alpha^* = 0$ 的样本点对 $w^*$ 和 $b^*$ 没有影响。将训练集中对应于 $\alpha^* > 0$ 的实例点 $x_i$ 称为支持向量, 与前面对支持向量的定义是一致的

根据这一定义, 支持向量一定在间隔边界上。由KKT互补条件可知,

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) = 0, \quad i = 1, 2, \dots, N$$

对应于 $\alpha_i^* > 0$ 的实例 $x_i$ , 有

$$y_i (w^* \cdot x_i + b^*) - 1 = 0$$

或

$$w^* \cdot x_i + b^* = \pm 1$$

即 $x_i$ 一定在间隔边界上。这里的支持向量的定义与前面给出的支持向量的定义是一致的。

对于线性可分问题, 线性可分支持向量机分类器 (硬间隔最大化) 是完美的。在样本中出现轻微不可分时, 就需要更一般的SVM分类器。





### 3 支持向量机的优化算法\*

- 目标函数是二次的，约束条件是线性的，所以它是一个凸二次规划问题。同时，该目标函数结构特殊，可以通过拉格朗日对偶性 (Lagrange Duality) 变换到对偶变量 (dual variable) 的优化问题，即通过求解与原问题等价的对偶问题 (dual problem) 得到原始问题的最优解，这就是**线性可分条件下支持向量机的对偶算法**。
- 这样做的优点在于：一是对偶问题往往更容易求解；二是非零拉格朗日系数可以直接得到支持向量；三是可以自然的引入核函数，进而推广到非线性分类问题



- 构建Lagrange函数, 先求 $L(\mathbf{w}, w_0, \alpha)$ 对 $\mathbf{w}, w_0$ 最小, 再求对 $\alpha$ 最大

$$L(\mathbf{w}, w_0, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + w_0) - 1]$$

( 如果间隔内还存在点, 则 $y_i(\mathbf{w}^T \mathbf{x}_i + w_0) - 1 < 0$ , 那么 $L$ 就不会取得最小值。)

因此求解 $L$ 最小值的过程就是**搜索支持向量的过程**

- 令对 $\mathbf{w}$ 和 $w_0$ 的偏导为0, 解得:

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0$$

(注:  $\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w} = \sum w_i^2$ )

- 将其代回原Lagrange函数即得

注: 这也是一种带有正则化的**铰链损失 (Hinge Loss)**

$$\begin{aligned}\inf_{\mathbf{w}, w_0} L(\mathbf{w}, w_0, \alpha) &= \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i w_0 \\&= \frac{1}{2} \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i - \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i - w_0 \sum_{i=1}^m \alpha_i y_i \\&= -\frac{1}{2} \mathbf{w}^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i - w_0 \sum_{i=1}^m \alpha_i y_i \quad \leftarrow \text{这一项为0} \\&= -\frac{1}{2} \left( \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i \\&= -\frac{1}{2} \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i + \sum_{i=1}^m \alpha_i\end{aligned}$$

- 原优化问题化为了其对偶问题：

对 $\alpha_i$ 的求极大问题，相对容易

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t.} \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i=1,2,\dots,m$$

- 一般利用序列最小最优（Sequential Minimal Optimization, **SMO**）算法，求解上述对偶问题中的Lagrange乘子 $\alpha$ （参见西瓜书p124）



[扩展阅读：支持向量机通俗导论（理解SVM的三层境界）](#)

- 确定后求得 $w$ 和 $w_0$

$$w = \sum_{i=1}^m \alpha_i y_i x_i$$

- 对于任意支持向量 $x_i^s$ 都满足 $y_i \cdot f(x_i^s) = 1$ , 代入求得参数 $w_0$



$$y_i \cdot \left[ \left( \sum_{j=1}^m \alpha_j y_j x_j \right)^T x_i^s + w_0 \right] = 1$$

或者使用所有支持向量求解的 $w_0$ 再取平均值

- 注意：在求解Lagrange对偶问题时，要满足Karush-Kuhn-Tucker条件（KKT条件），在SVM中的KKT条件表示为：

$$\left\{ \begin{array}{l} \alpha_i \geq 0 \\ y_i f(\mathbf{x}_i) - 1 \geq 0 \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0 \end{array} \right.$$

- 要满足KKT条件，则要求所有**非支持向量所对应的Lagrange乘数 $\alpha_i$ 都等于0**。所以训练完成后，所有非支持向量都不需要保留，最终的**模型仅与支持向量有关**。对于新样本的预测也只要针对少量的“支持向量”计算



实际SVM的分类结果示例






武汉大学  
WUHAN UNIVERSITY

# 03软间隔与正则化


Soft margin and regularization

---

- 硬间隔线性SVM分类器 (SVC) 对越过支持面、进入缓冲区、但是不越过分隔面的测试实例点，能正确分类
- 但是硬间隔SVM分类器存在两个主要问题：
  - ① 只有在训练集是线性可分时才有效，才能拟合成功
  - ② 对训练集中的异常实例点非常敏感，导致间隔很窄



对线性不可分训练集，学习不到硬间隔SVM分类器



对有异常值的训练集，学习到的分类器泛化能力有限

- 要避免这些问题，需要考虑更加灵活的模型
- 目标是：尽可能在保持缓冲区尽可能宽阔和容忍一定程度的间隔违例之间找到好的平衡——这就是软间隔支持向量机的出发点
- 间隔违例：是指各类样本中的偏群点（deviates），这会导致SVM缓冲区变窄、间隔变小；也包括各类的离群点（特异点）（outlier），这使得异类数据靠得很近、乃至轻微地线性不可分（近似线性可分）



线性不可分意味着某些样本点  $(x_i, y_i)$  不能满足函数间隔大于等于1的约束条件 (7.14)。为了解决这个问题，可以对每个样本点  $(x_i, y_i)$  引进一个松弛变量  $\xi_i \geq 0$ ，使函数间隔加上松弛变量大于等于1。这样，约束条件为

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i$$

同时，对每个松弛变量  $\xi_i$ ，支付一个代价  $\xi_i$ 。目标函数由原来的  $\frac{1}{2} \|w\|^2$  变成

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (7.31)$$

这里，称为惩罚参数，一般由应用问题决定，C值大时对误分类的惩罚增大，C值小时对误分类的惩罚减小。最小化目标函数 (7.31) 包含两层含义：使  $\frac{1}{2} \|w\|^2$  尽量小即间隔尽量大，同时使误分类的个数尽量小，C是调和二者的系数。

- 松弛变量代表了对原来**硬约束（不能越过支持面）**的减弱，从而在尽可能保障缓冲区宽度的同时，**让部分偏群点落在缓冲区内但仍能被正确分类，让少量离群点虽然被错分但至少可以拟合出SVM分类器**
- 这样一来，与拟合线性可分SVM分类器一样，就对这种**近似线性可分的训练数据集**拟合出线性SVM——这就是**软间隔SVM的基本思想**

线性不可分的线性支持向量机的学习问题变成如下凸二次规划 (convex quadratic programming) 问题 (原始问题)

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad (7.32)$$

$$s.t. \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \quad (7.33)$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, N \quad (7.34)$$

定义7.5 (线性支持向量机) 对于给定的线性不可分的训练数据集, 通过求解凸二次规划问题, 即软间隔最大化问题 (7.32) ~ (7.34), 得到的分离超平面为

$$w^* \cdot x + b^* = 0 \quad (7.35)$$

以及相应的分类决策函数

$$f(x) = \text{sign}(w^* \cdot x + b^*) \quad (7.36)$$

称为线性支持向量机。

原始最优化问题 (7.32) ~ (7.34) 的拉格朗日函数是

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i (w \cdot x_i + b) - 1 + \xi_i) - \sum_{i=1}^N \mu_i \xi_i \quad (7.40)$$

其中,  $\alpha_i \geq 0, \mu_i \geq 0$ 。

对偶问题是拉格朗日函数的极大极小问题。首先求  $L(w, b, \xi, \alpha, \mu)$  对  $w, b, \xi$  的极小, 由

$$\nabla_w L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\nabla_b L(w, b, \xi, \alpha, \mu) = -\sum_{i=1}^N \alpha_i y_i = 0$$

得

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad (7.41)$$

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (7.42)$$

$$C - \alpha_i - \mu_i = 0 \quad (7.43)$$



将式 (7.41) ~ (7.43) 代入式 (7.40) , 得

$$\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

再对  $\min_{w, b, \xi} L(w, b, \xi, \alpha, \mu)$  求  $\alpha$  的极大, 即得对偶问题:

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \quad (7.44)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (7.45)$$

$$C - \alpha_i - \mu_i = 0 \quad (7.46)$$

$$\alpha_i \geq 0 \quad (7.47)$$

$$\mu_i \geq 0, \quad i = 1, 2, \dots, N \quad (7.48)$$

将对偶最优化问题 (7.44) ~ (7.48) 进行变化: 利用等式约束 (7.46) 消去  $\mu_i$ , 从而只留下变量  $\alpha_i$ , 并将约束 (7.46) ~ (7.48) 写成

$$0 \leq \alpha_i \leq C \quad (7.49)$$

再将对目标函数求极大转换为求极小, 于是得到对偶问题 (7.37) ~ (7.39)。



经过前面推导，得出一般的（软间隔）线性SVM原问题的**对偶问题**

原始问题 (7.32) ~ (7.34) 的对偶问题是

训练数据只以内积形式出现！

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \underline{x_i \cdot x_j} - \sum_{i=1}^N \alpha_i \quad (7.37)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (7.38)$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \quad (7.39)$$

通过求解对偶问题可以得到原始问题的解，进而确定分离超平面和决策函数。下面以定理的形式叙述原始问题与对偶问题最优解的关系

定理7.3 设  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$  是对偶问题 (7.37) ~ (7.39) 的一个解，若存在  $\alpha^*$  的一个分类  $\alpha_j^*$ ， $0 < \alpha_j^* < C$ ，则原始问题 (7.32) ~ (7.34) 的解  $w^*, b^*$ ，可按下式求得：

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad (7.50)$$

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* \underline{x_i \cdot x_j} \quad (7.51)$$

证明 原始问题是凸二次规划问题，解满足KKT条件。即得

$$\nabla_w L(w^*, b^*, \xi^*, \alpha^*, \mu^*) = w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0 \quad (7.52)$$

$$\nabla_b L(w^*, b^*, \xi^*, \alpha^*, \mu^*) = -\sum_{i=1}^N \alpha_i^* y_i = 0$$

$$\nabla_{\xi} L(w^*, b^*, \xi^*, \alpha^*, \mu^*) = C - \alpha^* - \mu^* = 0$$

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1 + \xi_i^*) = 0 \quad (7.53)$$

$$\mu_i^* \xi_i^* = 0 \quad (7.54)$$

$$y_i (w^* \cdot x_i + b^*) - 1 + \xi_i^* \geq 0$$

$$\xi_i^* \geq 0$$

$$\alpha_i^* \geq 0$$

$$\mu_i^* \geq 0, \quad i = 1, 2, \dots, N$$

由式 (7.52) 易知式 (7.50) 成立。再由式 (7.53) ~ (7.54) 可知，若存在  $\alpha_j^*, 0 < \alpha_j^* < C$ ，则  $y_j (w^* \cdot x_j + b^*) - 1 = 0$ 。

由此即得式 (7.51)。



由此定理可知，分离超平面可以写成

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0 \quad (7.55)$$

分类决策函数可以写成

$$f(x) = \text{sign} \left( \sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* \right) \quad (7.56)$$

式 (7.56) 为线性支持向量机的对偶形式。

算法7.3 (线性支持向量机学习算法)

输入: 训练数据集  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ , 其中  $x_i \in X = R^n$ ,  $y_i \in Y = \{-1, +1\}$ ,  $i = 1, 2, \dots, N$

输出: 分离超平面和分类决策函数

(1) 选择惩罚参数  $C > 0$ , 构造并求解凸二次规划问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N$$

求得最优解  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$ 。



(2) 计算  $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$

选择  $\alpha^*$  的一个分量  $\alpha_j^*$  适合条件  $0 < \alpha_j^* < C$ , 计算

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j)$$


(3) 求得分离超平面

$$w^* \cdot x + b^* = 0$$


分类决策函数:

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

在线性不可分的情况下，将对偶问题(7.37)~(7.39)的解  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)$  中对应于  $\alpha_i^* > 0$  的样本点  $(x_i, y_i)$  的实例  $x_i$  称为**支持向量(软间隔的支持向量)**。如下图所示，这时的支持向量要比线性可分时的情况复杂一些。图中，分离超平面由实线表示，间隔边界由虚线表示，正例点由“o”表示，负例点由“x”表示。图中还标出了实例  $x_i$  到**间隔边界**的距离  $\frac{\xi_i}{\|w\|}$ 。




- (一)  $\alpha^* = 0$ ，位于本侧支持面的外侧，分类正确（非支持向量）
- (二)  $0 < \alpha^* < C$ ，则有  $\xi^* = 0$ ，落在支持面上，分类正确
- (三)  $\alpha^* = C$ :
  - (1)  $0 < \xi^* < 1$ ，落在缓冲区内，分类正确
  - (2)  $\xi^* = 1$ ，落在分隔面上，分类任意
  - (3)  $\xi^* > 1$ ，落在分隔面错误的一侧，分类错误（越过分隔面）



使用高 $C$ 值SVM, 间隔违例较少, 但是间隔也较小





使用低 $C$ 值SVM，间隔违例较多，但是间隔较大，泛化能力更强



武汉大学  
WUHAN UNIVERSITY

# 04核方法

Kernel methods and nonlinear support vector machines

---

## 核函数与非线性推广

- 通过样本学习，确定了各 $\alpha_i$ 的值，从而得到了SVM的判决函数：

$$f(\mathbf{x}) = \left( \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^T \mathbf{x} + w_0 = \sum_{i=1}^m \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle + w_0$$

展开

$$\mathbf{w} = \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{pmatrix} = \begin{pmatrix} \alpha_1 y_1 x_{11} + \alpha_2 y_2 x_{21} + \cdots + \alpha_m y_m x_{m1} \\ \alpha_1 y_1 x_{12} + \alpha_2 y_2 x_{22} + \cdots + \alpha_m y_m x_{m2} \\ \vdots \\ \alpha_1 y_1 x_{1d} + \alpha_2 y_2 x_{2d} + \cdots + \alpha_m y_m x_{md} \end{pmatrix}$$

$x_i$ 若非支持向量，该列可去掉



- 在预测阶段，新点 $x$ 的预测，只需要计算它与支持向量的内积即可。这一点至关重要，是使用核函数进行**非线性推广**的基本前提



$$f(x) = \sum_{i=1}^m \alpha_i y_i \langle x_i, x \rangle + w_0$$

为什么可以写为内积形式，  
请大家自行推导



- 向量的内积也叫向量的数量积、点乘，几何意义是一个向量在另一个向量上的投影
- $$x_1 = \begin{pmatrix} x_{11} \\ \vdots \\ x_{1d} \end{pmatrix} \quad x_2 = \begin{pmatrix} x_{21} \\ \vdots \\ x_{2d} \end{pmatrix} \quad \langle x_1, x_2 \rangle = \sum_{i=1}^d x_{1i} x_{2i}$$


- 虽然在许多情况下，线性SVM分类器是有效的，并且通常出人意料的好，但是毕竟有很多数据集远**不是线性可分离**的。处理非线性数据集的方法之一是**添加更多特征**。先看几个例子



一维线性不可分数据 $(x_1)$ ，增加平方项特征 $x_2 = (x_1)^2$ 后，

$(x_1, x_2)$  在二维空间线性可分





设原空间为  $X \subset R^2$ ,  $x = (x^{(1)}, x^{(2)})^T \in X$ , 新空间为  $Z \subset R^2$ ,  $z = (z^{(1)}, z^{(2)})^T \in Z$ , 定义从原空间到新空间的变化（映射）：

$$z = \phi(x) = ((x^{(1)})^2, (x^{(2)})^2)^T$$

经过变换  $z = \phi(x)$ , 原空间  $X \subset R^2$  变换为新空间  $Z \subset R^2$ , 原空间中的点相应地变换为新空间中的点, 原空间中的椭圆

$$w_1(x^{(1)})^2 + w_2(x^{(2)})^2 + b = 0$$

变换成为新空间中的直线

$$w_1 z^{(1)} + w_2 z^{(2)} + b = 0$$

在变换后的新空间里, 直线  $w_1 z^{(1)} + w_2 z^{(2)} + b = 0$  可以将变换后的正负实例点正确分开。这样, 原空间的非线性可分问题就变成了新空间的线性可分问题。



- 上例说明，用线性分类方法求解非线性分类问题分为两步：首先使用一个合适的**变换**，将原空间数据映射到新空间；然后在新空间里，用**线性分类**学习方法拟合线性分类模型
- **核技巧**就属于这样的变换方法，但更进一步：  
用原矢量空间上的一个二元**函数**，表达变换矢量的**内积**。不用直接计算变换矢量的内积，**甚至连变换本身都不用知道**

定义7.6（核函数） 设  $\mathcal{X}$  是输入空间（欧氏空间  $R^n$  的子集或离散集合），又设  $H$  为特征空间（希尔伯特空间），如果存在一个从  $\mathcal{X}$  到  $H$  的映射

$$\phi(x): \mathcal{X} \rightarrow H \quad (7.65)$$

使得对所有  $x, z \in \mathcal{X}$ ，函数  $K(x, z)$  满足条件

$$K(x, z) = \phi(x) \cdot \phi(z) \quad (7.66)$$



- 回顾基函数：通过对样本线性组合的**基函数映射**后，可以让低维空间的非线性分类等价于高维空间的线性分类

$$\bullet \text{ SVM的非线性推广: } f(x) = \sum_{i=1}^m \alpha_i y_i \langle \phi(x_i), \phi(x) \rangle + w_0$$

- 多项式回归可以等价为线性回归进行计算：通过一组**基函数** $\phi(x)$ 将 $d$ 维（低维）的样本，映射到 $n$ 维（高维）空间中，使得低维多项式回归等价于高维线性回归

$$g(x) = [\phi_i(x)]^T w + w_0 \quad i=1, 2, \dots, n$$



#### 幂函数基函数

比如为一维样本空间的样本 $x$ 构造3个基函数： $x_i \xrightarrow{\phi(x)} \mathbf{z}_i = \begin{pmatrix} z_{i1} \\ z_{i2} \\ z_{i3} \end{pmatrix}$

$$z_{i1} = \phi_1(x_i) = x_i, z_{i2} = \phi_2(x_i) = x_i^2, z_{i3} = \phi_3(x_i) = x_i^3$$

$$\text{则: } y_i = w_1 x_i + w_2 x_i^2 + w_3 x_i^3 \quad \leftarrow \text{一维空间多项式回归}$$

$$\Rightarrow y'_i = w_1 z_{i1} + w_2 z_{i2} + w_3 z_{i3} \quad \leftarrow \text{三维空间线性回归}$$

#### 乘积项 (product term) 基函数

比如样本空间 $X=(x^{(1)}, x^{(2)})$ 是一个二维空间，构造5个基函数：

$$z_{i1} = \phi_1(\mathbf{x}_i) = x_{i1}, \phi_2(\mathbf{x}_i) = x_{i2}, \phi_3(\mathbf{x}_i) = x_{i1}^2, \phi_4(\mathbf{x}_i) = x_{i2}^2, \phi_5(\mathbf{x}_i) = x_{i1}x_{i2}$$

$$\text{则: } y_i = w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i1}^2 + w_4 x_{i2}^2 + w_5 x_{i1}x_{i2} \quad \leftarrow \text{二维空间非线性回归}$$

$$\Rightarrow y'_i = w_1 z_{i1} + w_2 z_{i2} + w_3 z_{i3} + w_4 z_{i4} + w_5 z_{i5} \quad \leftarrow \text{五维空间线性回归}$$

- 基函数 $\phi(x)$ 方法降低了回归模型复杂度，是一种将线性模型推广到非线性模型的代表性方法。但这种方法升高了样本空间的维数，且需要知道基函数 $\phi(x)$ 的具体形式，需要引入“核方法”对其进行进一步完善

- **基函数运算的缺点：在高维空间中计算内积**
- **核函数** (kernel function) 是一种函数，使得在样本的特征空间（低维空间）中直接计算内积，而其结果等同于对样本进行基函数映射后在高维空间计算的内积

$$K(\boldsymbol{\eta}, \boldsymbol{\xi}) = \langle \phi(\boldsymbol{\eta}), \phi(\boldsymbol{\xi}) \rangle$$



设两个向量  $\boldsymbol{\eta}_i = \begin{pmatrix} \eta_{i1} \\ \eta_{i2} \end{pmatrix}$   $\boldsymbol{\xi}_i = \begin{pmatrix} \xi_{i1} \\ \xi_{i2} \end{pmatrix}$ ，基函数为乘积项函数（同前例），则：

$$\langle \phi(\boldsymbol{\eta}_i), \phi(\boldsymbol{\xi}_i) \rangle = \eta_{i1}\xi_{i1} + \eta_{i1}^2\xi_{i1}^2 + \eta_{i2}\xi_{i2} + \eta_{i2}^2\xi_{i2}^2 + \eta_{i1}\eta_{i2}\xi_{i1}\xi_{i2}$$

换一个角度计算：

$$(\langle \boldsymbol{\eta}_i, \boldsymbol{\xi}_i \rangle + 1)^2 = 2\eta_{i1}\xi_{i1} + \eta_{i1}^2\xi_{i1}^2 + 2\eta_{i2}\xi_{i2} + \eta_{i2}^2\xi_{i2}^2 + 2\eta_{i1}\eta_{i2}\xi_{i1}\xi_{i2} + 1$$

高维空间的几个维度线性放缩一下，即可完全相等

## 核函数与非线性推广

- 引入核函数后，既可实现线性模型到**非线性**模型的推广，又可**降低**计算复杂度（在样本空间直接求内积简单）

- SVM的非线性推广（引入核函数）：

$$f(\mathbf{x}) = \sum_{i=1}^m \alpha_i y_i \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}) \rangle + w_0 \quad \Leftrightarrow \quad f(\mathbf{x}) = \sum_{i=1}^m \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + w_0$$

| 名称       | 表达式                                                                                                          | 参数                                       |
|----------|--------------------------------------------------------------------------------------------------------------|------------------------------------------|
| 线性核      | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$                                        |                                          |
| 多项式核     | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$                                    | $d \geq 1$ 为多项式的次数                       |
| 高斯核      | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$ | $\delta > 0$ 为高斯核的带宽(width)              |
| 拉普拉斯核    | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$      | $\delta > 0$                             |
| Sigmoid核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$                  | $\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$ |



- 核技巧应用到支持向量机，首先就是通过一个**非线性变换** $\phi$ ，将输入空间（欧氏空间 $\mathbf{R}^n$  或离散集合）的原始样本变换到一个新的特征空间（希尔伯特空间 $\mathcal{H}$ ），变换应尽可能使得在输入空间 $\mathbf{R}^n$ 中的、以超曲面形态分布、且相互纠缠从而线性不可分的两类或多类样本训练集，能在新的特征空间中以一种**近似线性可分**的形态出现。这样，线性不可分问题的分类器学习任务，就在变换后的特征空间中得以近似求解。
- 问题来了：**到底是找非线性变换 $\phi(\cdot)$ ，还是只需要找合适的核函数 $K(\cdot, \cdot)$ ？**

核技巧的想法是，在学习与预测中只定义核函数  $K(x, z)$ ，而不显式地定义映射函数  $\phi$ 。通常，直接计算  $K(x, z)$  比较容易，而通过  $\phi(x)$  和  $\phi(z)$  计算  $K(x, z)$  并不容易。注意， $\phi$  是输入空间  $\mathbf{R}^n$  到特征空间  $\mathcal{H}$  的映射，特征空间  $\mathcal{H}$  一般是高维的，甚至是无穷维的。可以看到，对于给定的核  $K(x, z)$ ，特征空间  $\mathcal{H}$  和映射函数  $\phi$  的取法并不唯一，可以取不同的特征空间，即便是在同一特征空间里也可以取不同的映射。

我们注意到在线性支持向量机的对偶问题中，无论是目标函数还是决策函数(分离超平面)都只涉及输入实例与实例之间的内积。在对偶问题的目标函数(7.37)中的内积  $x_i \cdot x_j$  可以用核函数  $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$  来代替。此时**对偶问题的目标函数**成为

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \underline{K(x_i, x_j)} - \sum_{i=1}^N \alpha_i \quad (7.67)$$

同样，分类决策函数中的内积也可以用核函数代替，而分类决策函数式成为

$$\begin{aligned} f(x) &= \text{sign} \left( \sum_{i=1}^{N_s} a_i^* y_i \underline{\phi(x_i) \cdot \phi(x)} + b^* \right) \\ &= \text{sign} \left( \sum_{i=1}^{N_s} a_i^* y_i \underline{K(x_i, x)} + b^* \right) \end{aligned} \quad (7.68)$$

训练数据只以内积形式出现！

- 如果能找到变换函数与核函数的前述求内积运算上的等值关系或者近似等值关系，利用核函数求内积，也能学到非线性分类问题的支持向量机
- 因不用显式计算特征变换值 $\phi$ ，因此学习是**在原空间通过 $K$ 隐式进行的**



- 利用核函数求变换特征的内积，不是在SVM拟合中的主要目的，毕竟，先做变换再做内积也不是不行的
  - 如何不用显式地构造变换，甚至都不需要知道这个变换是什么，就能找到一个合适的核函数，替代计算变换特征的内积，从而学习到一个非线性分类器，能分离原空间非线性可分数据
- 我们的问题就成为：一个二元函数**满足什么条件**，就可以成为满足我们目的的核函数？
- 可能会问：**为什么要绕这个大弯子去求SVM？**
  - 这是因为：从前面的例子知道，一般而言，为把非线性可分问题变换为线性可分的，需要向高维空间变换，因此高维空间矢量的内积计算就成为可能的计算瓶颈。如果能**选择合适的低计算需求的核函数**，就有可能降低计算量
  - 其他独特优点：**某些情况下，不能得到原始特征，能得到的是原始特征之间的相似关系，这时只能使用核函数学习**

要完整理解核函数，需要有些函数空间（尤其泛函分析）方面的知识，这里只给出一些**基本结论**

定理7.5（正定核的充要条件） 设  $K : X \times X \rightarrow R$  是对称函数，则  $K(x, z)$  为正定核函数的充要条件是对任意  $x_i \in X, i = 1, 2, \dots, m, K(x, z)$  对应的Gram矩阵

$$K = [K(x_i, x_j)]_{m \times m} \quad (7.85)$$

是半正定矩阵。

有了这个充要条件，就可以给出正定核函数的定义：

定义7.7（正定核的等价定义） 设  $X \subset R^n$ ， $K(x, z)$  是定义在  $X \times X$  上的对称函数，如果对任意  $x_i \in X, i = 1, 2, \dots, m, K(x, z)$  对应的Gram矩阵

$$K = [K(x_i, x_j)]_{m \times m} \quad (7.87)$$

是半正定矩阵，则称  $K(x, z)$  是正定核。



- 对于一个具体的核函数，严格检验它是否为正定是很不容易的，因为这要求对任意有限数据集  $\{x_1, x_1, \dots, x_m\}$ ，都需要验证核函数关于该数据集的Gram 阵是否为半正定的！
- 我们希望样本在特征空间内线性可分，因此变换特征的好坏对支持向量机的性能至关重要。在不知道特征变换形式时，也就不知道什么样的核函数是合适的，因此，**核函数的选择就成为支持向量机的最大变数**
- **核函数的选择：需结合领域知识，尽可能反映样本间的相似关系！**
- **相似性与距离度量相关，因此，适合某种距离度量的变换，可以作为选择核函数的参考（邓乃扬，2004，p.106）**

| 名称        | 表达式                                                                                                          | 参数                                       |
|-----------|--------------------------------------------------------------------------------------------------------------|------------------------------------------|
| 线性核       | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$                                           |                                          |
| 多项式核      | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$                                       | $d \geq 1$ 为多项式的次数                       |
| 高斯核       | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$ | $\sigma > 0$ 为高斯核的带宽(width)              |
| 拉普拉斯核     | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\sigma}\right)$      | $\sigma > 0$                             |
| Sigmoid 核 | $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$                     | $\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$ |



## 1. 多项式核函数(polynomial kernel function)

$$K(x, z) = (x \cdot z + 1)^p \quad (7.88)$$

对应的支持向量机是一个p次多项式分类器。在此情形下，分类决策函数成为

$$f(x) = \text{sign} \left( \sum_{i=1}^{N_s} a_i^* y_i (x_i \cdot x + 1)^p + b^* \right) \quad (7.89)$$

## 2. 高斯核函数(Gaussian kernel function)

$$K(x, z) = \exp \left( -\frac{\|x - z\|^2}{2\sigma^2} \right) \quad (7.90)$$

对应的支持向量机是高斯径向基函数(radialbasis function)分类器。在此情形下，分类决策函数成为

$$f(x) = \text{sign} \left( \sum_{i=1}^{N_s} a_i^* y_i \exp \left( -\frac{\|x - x_i\|^2}{2\sigma^2} \right) + b^* \right) \quad (7.91)$$



- 利用核技巧，只需将线性支持向量机对偶形式中的内积换成核函数，就可以将线性分类的学习方法，应用到非线性分类问题中，将线性支持向量机扩展到非线性支持向量机

定义 (**非线性支持向量机**) 从非线性分类训练集，通过核函数与软间隔最大化，或凸二次规划 (7.95)~(7.97)，学习得到的分类决策函数

$$f(x) = \text{sign} \left( \sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b^* \right) \quad (7.94)$$

称为非线性支持向量机， $K(x, z)$  是**正定核函数**。

算法7.4 (非线性支持向量机学习算法)

输入：训练数据集  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ , 其中  $x_i \in X = R^n, y_i \in Y = \{-1, +1\}, i = 1, 2, \dots, N$ ;

输出：分类决策函数。

(1) 选取适当的核函数和适当参数  $C$ , 构造并求解最优化问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \quad (7.95)$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (7.96)$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \quad (7.97)$$

求得最优解  $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$

(2) 选择  $\alpha^*$  的一个正分量  $0 < \alpha_j^* < C$ , 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i K(x_i, x_j)$$

(3) 构造决策函数:

$$f(x) = \text{sign} \left( \sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b^* \right)$$






武汉大学  
WUHAN UNIVERSITY

# 05 非线性支持向量机示例

Experimental example of nonlinear support vector machine

---





使用多项式核的非线性SVM，对鸛尾花数据的分类情况

```
from sklearn.datasets import make_moons
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures

polynomial_svm_clf = Pipeline((
    ("poly_features", PolynomialFeatures(degree=3)),
    ("scaler", StandardScaler()),
    ("svm_clf", LinearSVC(C=10, loss="hinge"))
))


polynomial_svm_clf.fit(X, y)
```



使用多项式核的非线性SVM，对鸢尾花数据的分类情况




```
from sklearn.svm import SVC
poly_kernel_svm_clf = Pipeline((
    ("scaler", StandardScaler()),
    ("svm_clf", SVC(kernel="poly", degree=3, coef0=1, C=5))
))
poly_kernel_svm_clf.fit(X, y)
```








使用高斯核的非线性SVM，对鸢尾花数据的分类情况

```
rbf_kernel_svm_clf = Pipeline((  
    ("scaler", StandardScaler()),  
    ("svm_clf", SVC(kernel="rbf", gamma=5, C=0.001))  
))  
rbf_kernel_svm_clf.fit(X, y)
```


$\beta = 0.0001$  $\beta = 0.01$  $\beta = 10$ 

使用高斯核的非线性回归

 $D = 1$  $D = 3$  $D = 12$ 

使用多式核的多项式回归

$$h_{i,j} = e^{-\beta \|\mathbf{x}_i - \mathbf{x}_j\|_2^2}$$



二分类（上排）、多分类（下排）的高斯核SVM

$$h_{i,j} = e^{-\beta \|\mathbf{x}_i - \mathbf{x}_j\|_2^2}$$

 计算SVM分类

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix

# 加载示例数据集 (使用Iris数据集)
iris = datasets.load_iris()
X = iris.data[:, :2] # 为了方便可视化, 只使用前两个特征
y = iris.target

# 将数据集拆分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.3, random_state=42)

# 标准化特征
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```





注意这个参数

```
# 创建SVM分类器并训练
svm_classifier = SVC(kernel='linear', C=1.0, random_state=42)
svm_classifier.fit(X_train, y_train)

# 预测测试集
y_pred = svm_classifier.predict(X_test)


# 打印分类结果
print(f"分类准确率: {accuracy_score(y_test, y_pred):.2f}")
print("分类报告:")
print(classification_report(y_test, y_pred))
```

# 绘制决策边界


```
def plot_decision_boundary(X, y, model):  
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1  
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1  
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.02),  
                          np.arange(y_min, y_max, 0.02))  
  
    Z = model.predict(np.c_[xx.ravel(), yy.ravel()])  
    Z = Z.reshape(xx.shape)  
    plt.contourf(xx, yy, Z, alpha=0.8)  
    plt.scatter(X[:, 0], X[:, 1], c=y, edgecolors='k',  
marker='o')  
    plt.xlabel('Feature 1')  
    plt.ylabel('Feature 2')  
    plt.title('SVM Decision Boundary')  
    plt.show()
```

# 可视化决策边界

```
plot_decision_boundary(X_test, y_test, svm_classifier)
```



## 模型



- 核心参数:

最大间隔的中心直线 $w$

即支持向量对应的Lagrange乘子

## 策略 (准则)

- 最大支持向量几何间隔:

$$\operatorname{argmin}_{w, w_0} \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w^T x_i + w_0) \geq 1 \quad i=1, 2, \dots, m$$

## 算法

- Lagrange对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \\ s.t. \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i=1, 2, \dots, m \end{aligned}$$

- KKT条件

- SMO优化

$$f(x) = \left( \sum_{i=1}^m \alpha_i y_i x_i \right)^T x + w_0 = \sum_{i=1}^m \alpha_i y_i \langle x_i, x \rangle + w_0$$

(仅与支持向量有关)





**课后阅读西瓜书第6章，结合损失函数来表达SVM，  
了解支持向量回归SVR的思想**



武汉大学  
WUHAN UNIVERSITY

# End of This Part

---