



第十章：降维与度量学习

—— 自强弘毅 求是拓新 ——

|| 目录 ||

CONTENTS

1 k近邻学习

2 低维嵌入

3 主成分分析

4 核化线性降维

5 流形学习

6 度量学习



01

k近邻学习



k近邻学习的工作机制



武汉大学

WUHAN UNIVERSITY

- **k近邻** (k-Nearest Neighbor, kNN) 学习是一种常用的**监督**学习方法，确定**训练样本**及某种恰当**距离度量**
- 对于某个给定的测试样本，找到训练集中距离最近的 k 个样本，基于这样的 k 个邻居的信息进行预测。对于**分类问题**使用**投票法**获得预测结果，对于**回归问题**使用**平均法**获得预测结果。还可基于距离远近进行**加权平均**或**加权投票**，**距离越近的样本权重越大**
 - **投票法**：选择这 k 个样本中出现**最多的**类别标记作为预测结果
 - **平均法**：将这 k 个样本的实值输出标记的**平均值**作为预测结果



- **懒惰学习** (lazy learning) : 此类学习技术在训练阶段仅仅是把样本保存起来, 训练时间开销为零, 待收到测试样本后再进行处理
- **急切学习** (eager learning) : 在训练阶段就对样本进行学习处理的方法
- **k近邻学习**没有显式的训练过程, 属于 “**懒惰学习**”



k近邻分类示意图



武汉大学
WUHAN UNIVERSITY




图 10.1 k 近邻分类器示意图. 虚线显示出等距线; 测试样本在 $k = 1$ 或 $k = 5$ 时被判别为正例, $k = 3$ 时被判别为反例.

- k 近邻分类器中的 k 是一个重要参数, 当 k 取不同值时, 分类结果会有显著不同。另一方面, 若采用不同的距离计算方式, 则找出的近邻可能有显著差别, 从而也会导致分类结果有显著不同



分析1NN二分类错误率



武汉大学
WUHAN UNIVERSITY

- 暂且假设距离计算是恰当的，即能够恰当地找出 k 个近邻，我们来对最近邻分类器（1NN，即 $k=1$ ）在二分类问题上的性能做一个简单的讨论。给定测试样本 x ，若其最近邻样本为 z ，则最近邻出错的概率就是 x 与 z 类别标记不同的概率，即

$$P(err) = 1 - \sum_{c \in \mathcal{Y}} P(c | \mathbf{x}) P(c | \mathbf{z}) \quad \text{式 (10.1)}$$

- 假设样本独立同分布，且对任意 x 和任意小正整数 δ ，在 x 附近 δ 距离范围内总能找到一个训练样本 z



分析1NN二分类错误率



武汉大学
WUHAN UNIVERSITY

- 换言之，对任意测试样本，总能在任意近的范围找到式 (10.1) 中的训练样本 z
- 令 $c^* = \arg \max_{c \in \mathcal{Y}} P(c | \mathbf{x})$ 表示贝叶斯最优分类器的结果，有

$$\begin{aligned} P(err) &= 1 - \sum_{c \in \mathcal{Y}} P(c | \mathbf{x}) P(c | \mathbf{z}) \\ &\simeq 1 - \sum_{c \in \mathcal{Y}} P^2(c | \mathbf{x}) \\ &\leq 1 - P^2(c^* | \mathbf{x}) \\ &= (1 + P(c^* | \mathbf{x})) (1 - P(c^* | \mathbf{x})) \\ &\leq 2 \times (1 - P(c^* | \mathbf{x})) \end{aligned}$$

泛化错误率不超过贝叶斯最优分类器错误率的2倍！



02

低维嵌入



- 上述讨论基于一个重要的假设：**任意测试样本 x 附近的任意小的 δ 距离范围内总能找到一个训练样本**，即训练样本的采样密度足够大，或称为**密采样**。然而，这个假设在现实任务中通常很难满足
- 若属性维数为1，当 $\delta = 0.001$ ，仅考虑单个属性，则需要1000个样本点平均分布在归一化后的属性取值范围内（事实上，除区间端点外，多于499个样本点即可），即可使得任意测试样本在其附近0.001距离范围内总能找到一个训练样本，此时最近邻分类器的错误率不超过贝叶斯最优分类器的错误率的两倍。若属性维数为20，若样本满足密采样条件，则至少需要 $(10^3)^{20} = 10^{60}$ 个样本（**宇宙空间基本粒子总数 10^{80} ！**）



- 现实应用中属性维数经常成千上万，要满足密采样条件所需的样本数目是无法达到的天文数字。许多学习方法都涉及距离计算，而高维空间会给距离计算带来很大的麻烦，例如当维数很高时甚至连计算内积都不再容易
- 在高维情形下出现的数据样本稀疏、距离计算困难等问题，是机器学习方法共同面临的严重障碍，被称为维数灾难（维数爆炸）



- 缓解维数灾难的一个重要途径是**降维**（dimension reduction），即通过某种**数学变换**，将原始高维属性空间转变为一个**低维子空间**（subspace），**在这个子空间中样本密度大幅度提高，距离计算也变得更加容易**
- **为什么能进行降维？** 因为数据样本虽然是高维的，但与学习任务密切相关的也许仅是某个**低维分布**，即高维空间中的一个**低维嵌入**（embedding），因而可以对数据进行有效的降维




图 10.2 低维嵌入示意图



- 若要求原始空间中样本之间的**距离**在低维空间中得以**保持**，即得到**多维缩放**（MDS，例如上图10.2）
- 假定有 m 个样本，在原始空间中的距离矩阵为 $\mathbf{D} \in \mathbb{R}^{m \times m}$ ，其第 i 行 j 列的元素 $dist_{ij}$ 为**样本 x_i 到 x_j 的距离**
- 目标是获得样本在 d' ($\leq d$) 维空间（**低维**）中的表示 $\mathbf{Z} \in \mathbb{R}^{d' \times m}$ ，且任意两个样本在 d' 维空间的欧氏距离**等于**原始空间中的距离
- 令 $\mathbf{B} = \mathbf{Z}^T \mathbf{Z} \in \mathbb{R}^{m \times m}$ ，其中 $\mathbf{B}$ 为**降维后的内积矩阵**， $b_{ij} = z_i^T z_j$ 有
$$\begin{aligned} dist_{ij}^2 &= |z_i|^2 + |z_j|^2 - 2z_i^T z_j \\ &= b_{ii} + b_{jj} - 2b_{ij} \end{aligned}$$



- 为便于讨论，令降维后的样本 $\mathbf{Z}$ 被**中心化**，即 $\sum_{i=1}^m z_i = 0$ ，
显然，矩阵 $\mathbf{B}$ 的行与列之和均为零，即

$$\sum_{i=1}^m b_{ij} = \sum_{j=1}^m b_{ij} = 0$$

易知 $\sum_{i=1}^m dist_{ij}^2 = \text{tr}(\mathbf{B}) + mb_{jj}$ $\sum_{j=1}^m dist_{ij}^2 = \text{tr}(\mathbf{B}) + mb_{ii}$

$$\sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2 = 2m \text{tr}(\mathbf{B})$$

其中 $\text{tr}(\cdot)$ 表示矩阵的**迹** (trace)， $\text{tr}(\mathbf{B}) = \sum_{i=1}^m |z_i|^2$ ，令

$$dist_{i\cdot}^2 = \frac{1}{m} \sum_{j=1}^m dist_{ij}^2 \quad dist_{\cdot j}^2 = \frac{1}{m} \sum_{i=1}^m dist_{ij}^2 \quad dist_{\cdot\cdot}^2 = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2$$



- 由此即可通过降维前后保持不变的距离矩阵 $\mathbf{D}$ 求取内积矩阵 $\mathbf{B}$

$$b_{ij} = -\frac{1}{2} (dist_{ij}^2 - dist_{i.}^2 - dist_{.j}^2 + dist_{..}^2)$$

- 对矩阵 $\mathbf{B}$ 做特征值分解 (eigenvalue decomposition), $\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$, 其中 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ 为特征值构成的对角矩阵, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$, $\mathbf{V}$ 为特征向量矩阵, 假定其中有 d^* 个非零特征值, 它们构成对角矩阵 $\mathbf{\Lambda}_* = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d^*})$ 令 $\mathbf{V}_*$ 表示相应的特征向量矩阵, 则 $\mathbf{Z}$ 可表达为 (理论上)

$$\mathbf{Z} = \mathbf{\Lambda}_*^{1/2} \mathbf{V}_*^T \in \mathbb{R}^{d^* \times m}$$



- 在现实应用中为了有效降维，往往仅需降维后的距离与原始空间中的距离尽可能接近，而不必严格相等。此时可取 $d' \ll d$ 个最大特征值构成对角矩阵 $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d'})$ ，令 $\tilde{\mathbf{V}}$ 表示相应的特征向量矩阵，则 $\mathbf{Z}$ 可表达为

$$\mathbf{Z} = \Lambda^{1/2} \tilde{\mathbf{V}}^T \in \mathbb{R}^{d' \times m}$$

- MDS算法的描述

输入：距离矩阵 $\mathbf{D} \in \mathbb{R}^{m \times m}$ ，其元素 $dist_{ij}$ 为样本 $\mathbf{x}_i$ 到 $\mathbf{x}_j$ 的距离；
低维空间维数 d' 。

过程：

- 1: 根据式(10.7)–(10.9)计算 $dist_{i.}^2$, $dist_{.j}^2$, $dist_{..}^2$;
- 2: 根据式(10.10)计算矩阵 $\mathbf{B}$;
- 3: 对矩阵 $\mathbf{B}$ 做特征值分解;
- 4: 取 $\tilde{\Lambda}$ 为 d' 个最大特征值所构成的对角矩阵, $\tilde{\mathbf{V}}$ 为相应的特征向量矩阵。

输出：矩阵 $\tilde{\mathbf{V}} \tilde{\Lambda}^{1/2} \in \mathbb{R}^{m \times d'}$ ，每行是一个样本的低维坐标



- 一般来说，欲获得低维子空间，最简单的是对原始高维空间进行线性变换。给定 d 维空间中的样本 $\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m)$, $\mathbf{X} \in \mathbb{R}^{d \times m}$ 变换之后得到 $d' \leq d$ 维空间中的样本 $\mathbf{Z} = \mathbf{W}^T \mathbf{X}$ 其中 $\mathbf{W} \in \mathbb{R}^{d \times d'}$ 是变换矩阵, $\mathbf{Z} \in \mathbb{R}^{d' \times m}$ 是样本在新空间中的表达 (线性降维)
- 变换矩阵 $\mathbf{W}$ 可视为 d' 个 d 维基向量。换言之, z_i 是原属性向量 x_i 在新坐标系 $\{w_1, w_2, \dots, w_{d'}\}$ 中的坐标向量。若 w_i 与 w_j 正交, 则新坐标系是一个正交坐标系, 此时 $\mathbf{W}$ 为正交变换。显然, 新空间中的属性是原空间中的各属性的线性组合
- 通过对变换矩阵施加不同约束, 实现不同的降维要求。降维前后学习器性能是否提升来评估降维效果



03

主成分分析



- 主成分分析 (Principal Component Analysis, PCA)

先考虑如下问题：对于正交属性空间中的样本点，如何用一个超平面对所有样本进行恰当的表达？

- 容易想到，若存在这样的超平面，那么它大概应具有这样的性质
 - 最近重构性：样本点到这个超平面的距离都足够近
 - 最大可分性：样本点在超平面上的投影能尽可能分开
- 基于最近重构性和最大可分性，能分别得到主成分分析的两种等价推导



- 假定数据样本进行了**中心化**，即 $\sum_i \mathbf{x}_i = \mathbf{0}$ ，再假定**投影**变换后得到的新坐标系为 $\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_d\}$ ，其中 $\mathbf{w}_i$ 是**标准正交基向量**， $\|\mathbf{w}_i\|_2 = 1$ ， $\mathbf{w}_i^T \mathbf{w}_j = 0 (i \neq j)$ 若**丢弃**新坐标系中的部分坐标，即将**维度降低**到 $d' < d$ ，则样本点 $\mathbf{x}_i$ 在低维坐标系中的投影是 $\mathbf{z}_i = (z_{i1}; z_{i2}; \dots; z_{id'})$ ，其中 $z_{ij} = \mathbf{w}_j^T \mathbf{x}_i$ 是 $\mathbf{x}_i$ 在低维坐标系下第 j 维的坐标，若基于 $\mathbf{z}_i$ 来**重构** $\mathbf{x}_i$ ，则会得到
$$\hat{\mathbf{x}}_i = \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j$$
- 考虑整个训练集，原样本点 $\mathbf{x}_i$ 与基于投影重构的样本点 $\hat{\mathbf{x}}$ 之间的距离为



$$\begin{aligned} \sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j - \mathbf{x}_i \right\|_2^2 &= \sum_{i=1}^m \mathbf{z}_i^T \mathbf{z}_i - 2 \sum_{i=1}^m \mathbf{z}_i^T \mathbf{W}^T \mathbf{x}_i + \text{const} \\ &\propto -\text{tr} \left(\mathbf{W}^T \left(\sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{W} \right) \end{aligned}$$

- 根据最近重构性，上式应被最小化，考虑到 $\mathbf{w}_j$ 是标准正交基， $\sum_i \mathbf{x}_i \mathbf{x}_i^T$ 是**协方差矩阵**，有


$$\min_{\mathbf{W}} -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W})$$

$$\text{s.t. } \mathbf{W}^T \mathbf{W} = \mathbf{I}$$

这就是主成分分析的优化目标



- 从最大可分性出发，能得到主成分分析的另一种解释，样本点 $\mathbf{x}_i$ 在新空间中超平面上的投影是 $\mathbf{W}^T \mathbf{x}_i$ ，若所有样本点的投影能尽可能分开，则应该使投影后样本点的方差最大化（承载更多有效信息），如图所示





- 投影后样本点的**协方差矩阵**是 $\sum_i \mathbf{W}^T \mathbf{x}_i \mathbf{x}_i^T \mathbf{W}$ ，于是优化目标可写为

$$\max_{\mathbf{W}} \text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \quad \text{s.t. } \mathbf{W}^T \mathbf{W} = \mathbf{I}$$

- 运用**拉格朗日乘子法**可将上述等价问题转发为**矩阵 $\mathbf{X} \mathbf{X}^T$ 的特征值问题**
- 于是，只需对协方差矩阵 $\mathbf{X} \mathbf{X}^T$ 进行**特征值分解**，将求得特征值排序： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ ，再取**前 d' 个特征值**对应的特征向量构成 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$ 。这就是主成分分析的解



输入：样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
低维空间维数 d' .

过程：

- 1: 对所有样本进行中心化: $\mathbf{x}_i \leftarrow \mathbf{x}_i - \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$;
- 2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^T$;
- 3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 做特征值分解;
- 4: 取最大的 d' 个特征值所对应的特征向量 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}$.

输出：投影矩阵 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$.

图 10.5 PCA 算法

上述方法与逐一选择方差最大方向的做法等价。对比MDS方法



- 降维后低维空间的维数 d' 通常是由用户**事先指定**，或通过
在 d' 值不同的低维空间中对 k 近邻分类器（或其它开销较
小的学习器）进行**交叉验证**来选取较好的 d' 值。对PCA，
还可从重构的角度设置一个**重构阈值**，例如 $t = 95\%$ ，然后
选取使下式成立的**最小 d' 值**

$$\frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^d \lambda_i} \geq t$$



- PCA仅需保留 $\mathbf{W}$ 与样本的均值向量（**保持一致性！**），即可通过简单的向量减法和矩阵-向量乘法将新样本投影至低维空间中
- 降维虽然会导致信息的**损失**，但一方面舍弃这些信息后能使得样本的**采样密度增大**；另一方面，当数据受到噪声影响时，最小的特征值所对应的特征向量往往与噪声有关，舍弃可以起到**去噪**效果




04


核化线性降维




- 线性降维方法假设从高维空间到低维空间的函数映射是**线性的**，然而在不少现实任务中，可能需要**非线性映射**才能找到恰当的低维嵌入



(a) 三维空间中的观察



(b) 本真二维结构



(c) PCA 降维结果

图 10.6 三维空间中观察到的 3000 个样本点，是从本真二维空间中矩形区域采样后以 S 形曲面嵌入，此情形下线性降维会丢失低维结构。图中数据点的染色显示出低维空间的结构。



- **核化主成分分析** (Kernelized PCA, KPCA) 是非线性降维的一种常用方法, 是基于核技巧对线性降维方法进行**核化** (kernelized)
- 假定我们将在**高维**特征空间中把数据投影到由 $\mathbf{W}$ 确定的超平面上, 即PCA欲求解

$$\left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{W} = \lambda \mathbf{W}$$

其中 $\mathbf{z}_i$ 是样本点 $\mathbf{x}_i$ 在**高维特征空间中的像**。令 $\alpha_i = \frac{1}{\lambda} \mathbf{z}_i^T \mathbf{W}$

$$\mathbf{W} = \frac{1}{\lambda} \left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{W} = \sum_{i=1}^m \mathbf{z}_i \frac{\mathbf{z}_i^T \mathbf{W}}{\lambda} = \sum_{i=1}^m \mathbf{z}_i \alpha_i$$



- 假定 z_i 是由**原始属性空间**中的样本点 x_i 通过映射 ϕ 产生, 即 $z_i = \phi(x_i), i = 1, 2, \dots, m$
- 若 ϕ 能被显式表达出来, 则通过它将样本映射至**高维空间**, 再在特征空间中实施PCA即可, 即有

$$\left(\sum_{i=1}^m \phi(x_i) \phi(x_i)^T \right) \mathbf{W} = \lambda \mathbf{W}$$

并且

$$\mathbf{W} = \sum_{i=1}^m \phi(x_i) \alpha_i$$

一般来说, ϕ 的具体形式未知, 引入核函数, 转化为对应核矩阵的特征值问题, 取核矩阵最大的前 d' 个特征值对应的特征向量。



- 对新样本 $\mathbf{x}$ ，其投影后的第 j ($j=1, 2, \dots, d'$) 维坐标为

$$\begin{aligned} z_j &= \mathbf{w}_j^T \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i^j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \\ &= \sum_{i=1}^m \alpha_i^j \kappa(\mathbf{x}_i, \mathbf{x}) \end{aligned}$$

其中 α_i^j 是**核矩阵的特征向量**的第 j 个分量，且已经过规范化。

由该式可知，为获得投影后的坐标，**KPCA**需对所有样本求**和**，因此它的计算开销较大。



05

流形学习



- 流形学习 (manifold learning) 是一类**借鉴了拓扑流形概念的降维方法**。流形是在局部与欧氏空间同胚的空间，换言之，它在局部具有**欧氏空间**的性质，能用欧氏距离来进行距离计算
- 若低维流形嵌入到高维空间中，则数据样本在高维空间的分布虽然看上去非常复杂，但在局部上仍具有欧氏空间的性质，因此，**可以容易地在局部建立降维映射关系，然后再设法将局部映射关系推广到全局**
- 当维数被降至二维或三维时，能对数据进行可视化展示，因此**流形学习也可被用于可视化**




等度量映射



武汉大学

WUHAN UNIVERSITY

- 低维流形嵌入到高维空间之后，直接在高维空间中计算直线距离具有**误导性**，因为高维空间中的直线距离在低维嵌入流形上不可达。而低维嵌入流形上两点间的本真距离是**测地线 (geodesic) 距离**



(a) 测地线距离与高维直线距离



- 流形上的距离：测地线距离
- 我们的地球表面就是一个嵌入到3维特征空间中的2维流形
- 球面上的测点线不是直线，因为直线根本不在球面上





等度量映射




武汉大学

WUHAN UNIVERSITY

- 给定样本数据集 $x_1, x_2, \dots, x_n \in \mathbb{R}^N$
- 希望找到能够**保持流形的几何结构**的低维特征表示


$$y_1, y_2, \dots, y_n \in \mathbb{R}^d$$






- 根据样本集构造邻接图（只有近邻存在连接）
- 图上两点之间的**最短路径**对应于流形上测地线距离的一个近似值
- 保证低维特征空间中两点的欧式距离与原来的测地线距离尽量相等

$$\min_y \sum_{ij} [D(x_i, x_j) - \|y_i - y_j\|^2]$$



F





● Isomap算法

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
近邻参数 k ;
低维空间维数 d' .

过程:


- 1: **for** $i = 1, 2, \dots, m$ **do**
- 2: 确定 $\mathbf{x}_i$ 的 k 近邻;
- 3: $\mathbf{x}_i$ 与 k 近邻点之间的距离设置为欧氏距离, 与其他点的距离设置为无穷大;
- 4: **end for**
- 5: 调用最短路径算法计算任意两样本点之间的距离 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$;
- 6: 将 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$ 作为 MDS 算法的输入;
- 7: **return** MDS 算法的输出

输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

训练一个回归学习器（高维坐标作为输入、低维坐标作为输出）
对新样本在低维空间的坐标进行预测；近邻图的构建会对最短
路径计算造成影响。



- 局部线性嵌入 (Locally Linear Embedding, LLE)
- 局部线性嵌入**试图保持邻域内的线性关系**，并使得该线性关系在降维后的空间中继续保持



$$\mathbf{x}_i = w_{ij} \mathbf{x}_j + w_{ik} \mathbf{x}_k + w_{il} \mathbf{x}_l$$



- LLE先为每个样本 $\mathbf{x}_i$ 找到其**近邻下标集合** Q_i , 然后计算出基于 Q_i 的中的样本点对 $\mathbf{x}_i$ 进行线性重构的系数 w_i

$$\begin{aligned} \min_{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m} \quad & \sum_{i=1}^m \left\| \mathbf{x}_i - \sum_{j \in Q_i} w_{ij} \mathbf{x}_j \right\|_2^2 \\ \text{s.t.} \quad & \sum_{j \in Q_i} w_{ij} = 1 \end{aligned}$$

其中 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 均为已知, 令 $C_{jk} = (\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_k)$, w_{ij} 有闭式解

$$w_{ij} = \frac{\sum_{k \in Q_i} C_{jk}^{-1}}{\sum_{l, s \in Q_i} C_{ls}^{-1}}$$



- LLE在低维空间中**保持** w_i **不变**，于是 x_i 对应的**低维空间**坐标 z_i 可通过下式求解

$$\min_{z_1, z_2, \dots, z_m} \sum_{i=1}^m \left\| z_i - \sum_{j \in Q_i} w_{ij} z_j \right\|_2^2$$

- 令 $\mathbf{Z} = (z_1, z_2, \dots, z_m) \in \mathbb{R}^{d' \times m}$, $(\mathbf{W})_{ij} = w_{ij}$

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W})$$

则上式可重写为下式，并通过**特征值分解**求解 (**乘子法**)

$$\min_{\mathbf{Z}} \text{tr}(\mathbf{Z}\mathbf{M}\mathbf{Z}^T), \text{ s.t. } \mathbf{Z}\mathbf{Z}^T = \mathbf{I}$$



● LLE算法（特征向量矩阵的转置即为低维投影）

输入：样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
近邻参数 k ;
低维空间维数 d' .

过程:

- 1: **for** $i = 1, 2, \dots, m$ **do**
- 2: 确定 $\mathbf{x}_i$ 的 k 近邻;
- 3: 从式(10.27)求得 $w_{ij}, j \in Q_i$;
- 4: 对于 $j \notin Q_i$, 令 $w_{ij} = 0$;
- 5: **end for**
- 6: 从式(10.30)得到 $\mathbf{M}$;
- 7: 对 $\mathbf{M}$ 进行特征值分解;
- 8: **return** $\mathbf{M}$ 的最小 d' 个特征值对应的特征向量

输出：样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

图 10.10 LLE 算法



06

度量学习



- 在机器学习中，对高维数据进行降维的主要目的是希望找到一个**合适的低维空间**，在此空间中进行学习能比原始空间性能更好
- 事实上，每个空间对应了在样本属性上定义的一个距离度量，而寻找**合适的空间**，实质上就是在寻找一个**合适的距离度量**。那么，为何不直接尝试“学习”出一个合适的距离度量呢？---**度量学习**



- 欲对距离度量进行学习，必须有一个**便于学习**的距离度量表达形式。对两个 d 维样本 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ ，它们之间的平方欧氏距离可写为

$$\text{dist}_{\text{ed}}^2(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = \text{dist}_{ij,1}^2 + \text{dist}_{ij,2}^2 + \dots + \text{dist}_{ij,d}^2$$

其中 $\text{dist}_{ij,k}$ 表示 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 在第 k 维上的距离。若假定不同属性的重要性不同，则可引入属性权重 $\mathbf{w}$ ，得到

$$\begin{aligned} \text{dist}_{\text{wed}}^2(\mathbf{x}_i, \mathbf{x}_j) &= \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = w_1 \cdot \text{dist}_{ij,1}^2 + w_2 \cdot \text{dist}_{ij,2}^2 \\ &\quad + \dots + w_d \cdot \text{dist}_{ij,d}^2 = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{W} (\mathbf{x}_i - \mathbf{x}_j) \end{aligned}$$

$w_i \geq 0$, $\mathbf{W} = \text{diag}(\mathbf{w})$ 是一个对角矩阵, $(\mathbf{W})_{ii} = w_i$



- $\mathbf{W}$ 的非对角元素均为零，这意味着坐标轴是正交的，即属性之间无关；但现实问题中往往不是这样，例如考虑西瓜的“重量”和“体积”这两个属性，它们显然是正相关的，其对应的坐标轴不再正交。为此将 $\mathbf{W}$ 替换为一个普通的**半正定对称矩阵** $\mathbf{M}$ ，于是就得到了**马氏距离** (Mahalanobis distance)

$$\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2$$

其中 $\mathbf{M}$ 亦称**度量矩阵**，而**度量学习**则是对 $\mathbf{M}$ 进行学习



- 注意到为了保持距离非负且对称， M 必须是（半）正定对称矩阵，即必有正交基 P 使得 M 能写为 $M = PP^T$
- 对 M 进行学习当然要设置一个目标。假定我们是希望提高近邻分类器的性能，则可将 M 直接嵌入到近邻分类器的评价指标中去，通过优化该性能指标相应地求得 M
- 下面以近邻成分分析为例讨论



- 近邻成分分析 (Neighbourhood Component Analysis, NCA) 在进行判别时通常使用**多数投票法**，邻域中的每个样本投1票，邻域外的样本投0票。不妨将其替换为**概率投票法**。对于任意样本 $\mathbf{x}_j$ ，它对 $\mathbf{x}_i$ 分类结果影响的概率为

$$p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_M^2)}{\sum_l \exp(-\|\mathbf{x}_i - \mathbf{x}_l\|_M^2)} \quad \text{式 (10.35)}$$

- 当 $i = j$ 时， p_{ij} 最大。显然， $\mathbf{x}_j$ 对 $\mathbf{x}_i$ 的影响随着它们之间距离的增大而减小。若以**留一法 (LOO) 正确率的最大化为目标**，则可计算 $\mathbf{x}_i$ 的留一法正确率，即它被自身之外的所有样本正确分类的概率为 $p_i = \sum_{j \in \Omega_i} p_{ij}$



- 整个样本集上的留一法正确率为

$$\sum_{i=1}^m p_i = \sum_{i=1}^m \sum_{j \in \Omega_i} p_{ij}$$

- 将式 (10.35) 带入上式, 再考虑到 $\mathbf{M} = \mathbf{P}\mathbf{P}^T$ 则NCA的优化目标为

$$\min_{\mathbf{P}} 1 - \sum_{i=1}^m \sum_{j \in \Omega_i} \frac{\exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_j\|_2^2)}{\sum_l \exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_l\|_2^2)}$$

求解即可得到**最大化近邻分类器LOO正确率**的距离度量矩阵 $\mathbf{M}$



- 实际上，我们不仅能把**错误率**这样的监督学习目标作为度量学习的优化目标，还能在度量学习中引入**领域知识**
- 若已知某些样本相似、某些样本不相似，则可定义**必连** (must-link) 约束集合 $\mathcal{M}$ 与**勿连** (cannot-link) 约束集合 $\mathcal{C}$ ， $(\mathbf{x}_i, \mathbf{x}_j) \in \mathcal{M}$ 表示 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 相似， $(\mathbf{x}_i, \mathbf{x}_k) \in \mathcal{C}$ 表示 $\mathbf{x}_i$ 与 $\mathbf{x}_k$ 不相似
- 显然，我们希望**相似的样本之间距离较小**，**不相似的样本之间距离较大**



- 于是可通过求解下面这个凸优化问题**获得适当的度量矩阵**

$$\begin{aligned} \min_{\mathbf{M}} \quad & \sum_{(\mathbf{x}_i, \mathbf{x}_j) \in \mathcal{M}} \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2 \\ \text{s.t.} \quad & \sum_{(\mathbf{x}_i, \mathbf{x}_k) \in \mathcal{C}} \|\mathbf{x}_i - \mathbf{x}_k\|_{\mathbf{M}}^2 \geq 1 \\ & \mathbf{M} \succeq 0 \end{aligned}$$

其中约束 $\mathbf{M} \succeq 0$ 表明 $\mathbf{M}$ 必须是半正定的。上式要求在不相似样本间的距离不小于1的前提下，使相似样本间的距离尽可能小



- 不同的度量学习方法针对不同目标获得“好”的半正定对称距离度量矩阵 $\mathbf{M}$ ，若 $\mathbf{M}$ 是一个**低秩矩阵**，则通过对 $\mathbf{M}$ 进行特征值分解，总能找到一组正交基，其正交基数目为矩阵 $\mathbf{M}$ 的秩 $\text{rank}(\mathbf{M})$ ，小于原属性数 d
- 于是，度量学习学得的结果可衍生出一个**降维矩阵（投影矩阵）**

$$\mathbf{P} \in \mathbb{R}^{d \times \text{rank}(\mathbf{M})}$$

能用于降维的目的



**课后阅读西瓜书第10章
比较MDS与PCA、LLE与PCA、
ISOMap与MDS; KPCA的思
想; 度量学习与降维**



武汉大学
WUHAN UNIVERSITY

谢谢

自强弘毅 求是拓新