



武漢大學

WUHAN UNIVERSITY

第9讲 聚类





武汉大学
WUHAN UNIVERSITY

||| 目 录 |||

CONTENTS

01 聚类任务

02 性能度量

03 距离计算

04 原型聚类

05 密度聚类

06 层次聚类




武汉大学
WUHAN UNIVERSITY

01 聚类任务

Overview of clustering task

- 在**无监督学习 (unsupervised learning)** 中，训练样本的标记信息是**未知**的，目标是通过对无标记训练样本的学习来揭示数据的**内在性质及规律**，为进一步的数据分析提供**基础**。
- 此类学习任务中研究最多、应用最广的是**聚类(clustering)**，除聚类外，常见的无监督学习任务还有**密度估计**(density estimation)、**异常检测**(anomaly detection)等...





- 按照**物以类聚**的思想，对未知类别的样本集根据样本之间的**相似程度**分类，相似的归为一类，不相似的归为另一类，故这种分类称为**聚类分析(Clustering analysis)**，又常常叫做“**聚类**”。
- **相似性测度**、**聚类准则**和**聚类算法**称为聚类分析的三要素。
- **相似性测度**用于衡量同类样本的类似性和不同类样本的差异性。常用的测度有：距离、夹角余弦等。
- 在相同的相似性测度下，对同样的数据，一般而言是可以给出**多种聚类结果**的。为了评价聚类效果的优劣，需要定义**准则函数**（常用的准则函数是误差平方和准则）。有了相似性测度和准则函数后，聚类就变成了使准则函数取极值的**优化算法**问题。



- 聚类 (Clustering) 是按照**某个特定标准** (如距离), 把一个数据集分割成**不同的类或簇**, 使得**同一个簇内的数据对象的相似性尽可能大**, 同时**不在同一个簇中的数据对象的差异性也尽可能地大**。聚类后同一类的数据尽可能聚集到一起, 不同类数据尽量分离。
- 聚类试图将数据集中的样本**划分为若干个通常是不相交的子集**, 每个子集称为一个**簇**。通过这样划分, 每个簇可能对应于一些**潜在的概念** (类别), 如 “浅色瓜” “深色瓜”, “有籽瓜” “无籽瓜”, 甚至 “本地瓜” “外地瓜” 等。需说明的是, **这些概念对聚类算法而言事先是未知的**, 聚类过程仅能自动形成簇结构, 簇所对应的概念语义需由**使用者**来把握和命名。



- 假定**样本集** $D = \{x_1, x_2, \dots, x_m\}$ 包含 m 个**无标记样本**，每个样本 $x_i = \{x_{i1}, x_{i2}, \dots, x_{in}\}$ 是一个 **n 维的特征向量**，聚类算法将样本集 D 划分成 **k 个不相交的簇** $\{C_l | l = 1, 2, \dots, k\}$ ，其中 $C_{l'} \cap C_l = \emptyset, l' \neq l$ ，且 $D = \bigcup_{l=1}^k C_l$ ；
- 相应地，用 $\lambda_j \in \{1, 2, \dots, k\}$ 表示**样本 x_j 的簇标记 (cluster label)**，即 $x_j \in C_{\lambda_j}$ 。于是，聚类的结果可用**包含 m 个元素的簇标记向量** $\lambda = (\lambda_1, \lambda_2, \dots, \lambda_m)$ 来表示。




聚类与分类的区别：

- **聚类(Clustering)**：把相似的数据划分到一起，具体划分时并不关注该类的标签，目标是把相似的数据聚合到一起，属于一种**无监督学习**(Unsupervised Learning)方法；
- **分类(Classification)**：把不同的数据划分开，其过程是通过训练数据集获得一个分类器，再通过分类器去预测未知数据，属于一种**有监督学习**(Supervised Learning)方法。

聚类既可以作为一个**单独过程**（用于找寻数据内在的分布结构），也可作为分类等其他学习任务的**前驱过程**。

提问：肉眼观察以下数据可以聚成几类？





武汉大学
WUHAN UNIVERSITY

02 性能度量

Validity Index

- **聚类性能度量亦称为聚类“有效性指标”**。一方面，对于聚类结果，我们根据某些性能度量来**评估聚类好坏**；另一方面，若明确了度量方法，可直接将其**作为优化目标**，从而得到符合要求的聚类结果
- 如何将样本划分到不同的簇？直观上来说，我们希望 **“簇内的样本尽可能相似，簇间的样本尽可能有差异”**
- 性能度量大致有两类
 - **外部指标 (external index)**：将聚类结果与某个“参考模型”进行比较
 - **内部指标 (internal index)**：直接考察聚类结果而不利用任何参考模型

- 对数据集 $D = \{x_1, x_2, \dots, x_m\}$, 假定通过**聚类给出的簇**划分为 $C = \{C_1, C_2, \dots, C_k\}$ 。**参考模型给出的簇**划分为 $C^* = \{C_1^*, C_2^*, \dots, C_s^*\}$ 。相应地, 令 λ 与 λ^* 分别表示与 C 和 C^* 对应的簇标记向量。将样本两两配对考虑, 定义:

$$a = |SS|, SS = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$$

$$b = |SD|, SD = \{(x_i, x_j) | \lambda_i = \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$$

$$c = |DS|, DS = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$$

$$d = |DD|, DD = \{(x_i, x_j) | \lambda_i \neq \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$$

x_i 在聚类簇 C 中的簇号

x_i 在参考簇 C^* 中的簇号

- 其中**集合 SS 包含了在 C 中隶属于相同簇且在 C^* 中也属于相同簇的样本对**, **集合 SD 包含了在 C 中隶属于相同簇但在 C^* 中属于不同簇的样本对**, 由于每个样本对 (x_i, x_j) ($i < j$) 仅能出现在一个集合中, 因此有 $a + b + c + d = m(m - 1)/2$ 成立?

➤ 聚类分析常用的**外部指标**:

Jaccard系数
Jaccard Coefficient, JC

$$JC = \frac{a}{a + b + c}$$

FM指数
Fowlkes and Mallows Index,
FMI

$$FMI = \sqrt{\frac{a}{a + b} \times \frac{a}{a + c}}$$

Rand指数
Rand Index, RI

$$RI = \frac{2(a + d)}{m(m - 1)}$$

➤ 上述指标的结果**均在[0, 1]区间**, **值越大越好**。

- 考虑聚类结果的簇划分 $C = \{C_1, C_2, \dots, C_k\}$, 定义一个簇 C 内**样本的平均距离**为:

$$\text{avg}(C) = \frac{2}{|C|(|C| - 1)} \sum_{x_i, x_j \in C} \text{dist}(x_i, x_j)$$

- 簇 C 内样本间的**最远距离**为:

$$\text{diam}(C) = \max_{x_i, x_j \in C} \text{dist}(x_i, x_j)$$

- 簇 C_i 与簇 C_j **最近样本间的距离**为:

$$d_{\min}(C_i, C_j) = \min_{x_i \in C_i, x_j \in C_j} \text{dist}(x_i, x_j)$$

- 定义 $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ 为簇 C_i 内样本的均值向量，则两个聚类簇 C_i 和 C_j 的中心距离为：

$$d_{\text{cen}}(C_i, C_j) = \text{dist}(\mu_i, \mu_j)$$

- 聚类分析常用的内部指标：

DB指数
Davies-Bouldin Index,
DBI

$$\text{DBI} = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\text{avg}(C_i) + \text{avg}(C_j)}{d_{\text{cen}}(\mu_i, \mu_j)} \right)$$

Dunn指数
Dunn Index,
DI

$$\text{DI} = \min_{1 \leq i \leq k} \left\{ \min_{j \neq i} \left(\frac{d_{\min}(C_i, C_j)}{\max_{1 \leq l \leq k} \text{diam}(C_l)} \right) \right\}$$

DBI 指数越小（或DI指数越大） 就越就意味着簇内距离越小同时簇间距离越大，说明**聚类的性能越好**。



武汉大学
WUHAN UNIVERSITY

03 距离计算

Distance Calculation



- 对函数 $dist(\cdot, \cdot)$, 若它是一个“距离度量” (distance measure), 则应满足一些基本性质:
- 非负性: $dist(x_i, x_j) \geq 0$;
 - 同一性: $dist(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$
 - 对称性: $dist(x_i, x_j) = dist(x_j, x_i)$
 - 直通性: $dist(x_i, x_j) \leq dist(x_i, x_k) + dist(x_k, x_j)$

给定数据集 $D = \{x_1, x_2, \dots, x_m\}$, 样本空间由 d 维向量构成 $x_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$, 机器学习中**常用的距离度量**有:

闵可夫斯基距离
Minkowski Distance
(p 范数)

$$L_p(x_i, x_j) = \left[\sum_{l=1}^d |x_{il} - x_{jl}|^p \right]^{\frac{1}{p}}$$

欧式距离
Euclidean Distance
(2范数)

$$L_2(x_i, x_j) = \left[\sum_{l=1}^d |x_{il} - x_{jl}|^2 \right]^{\frac{1}{2}} = \|x_i - x_j\|_2$$

闵氏距离的特例

曼哈顿距离
Manhattan Distance
(1范数)

$$L_1(x_i, x_j) = \sum_{l=1}^d |x_{il} - x_{jl}|$$

对于数据集 $D = \{x_1, x_2, \dots, x_m\}$, 其样本的**均值向量** $\mu = (\mu_1, \mu_2, \dots, \mu_d)^T$, 样本的**协方差矩阵**为 Σ , 则样本 x_i 到分布之间的距离

马氏距离
Mahalanobis Distance

$$D_M(x_i) = \sqrt{(x_i - \mu)^T \Sigma^{-1} (x_i - \mu)}$$

样本 x_i 到 x_j 的距离

马氏距离
Mahalanobis Distance

$$D_M(x_i, x_j) = \sqrt{(x_i - x_j)^T \Sigma^{-1} (x_i - x_j)}$$

可以发现如果 Σ^{-1} 是**单位矩阵**时, 马氏距离简化为欧式距离。

n 维模式向量 X_i 、 X_j 间的**闵氏距离**表示为：

$$D_m(X_i, X_j) = \left[\sum_{k=1}^n |x_{ik} - x_{jk}|^m \right]^{1/m}$$

式中， x_{ik} 、 x_{jk} 分别表示 X_i 和 X_j 的第 k 个分量。也称为 **m-范数**。

当 $m=2$ 时，闵氏距离为欧氏距离。


当 $m=1$ 时：

$$D_1(X_i, X_j) = \sum_{k=1}^n |x_{ik} - x_{jk}|$$

称为 **“街区”距离** (“City block” distance)、**曼哈顿距离**。

示例：当 $k=2$ 时：图中

$$D_1(X_i, X_j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}|$$





设 $\mathbf{X}_1$ 、 $\mathbf{X}_2$ 为两个 n 维模式样本

$$\mathbf{X}_1 = [x_{11}, x_{12}, \dots, x_{1n}]^T \quad \mathbf{X}_2 = [x_{21}, x_{22}, \dots, x_{2n}]^T$$

欧氏距离定义为：

$$\begin{aligned} D(\mathbf{X}_1, \mathbf{X}_2) &= \|\mathbf{X}_1 - \mathbf{X}_2\| = \sqrt{(\mathbf{X}_1 - \mathbf{X}_2)^T (\mathbf{X}_1 - \mathbf{X}_2)} \\ &= \sqrt{(x_{11} - x_{21})^2 + \dots + (x_{1n} - x_{2n})^2} \end{aligned}$$

距离越小，越相似。

注意：

- 各维特征最好代表**相同**物理量；
- 各特征量的**量纲**应该一致。



- 属性介绍

- **连续属性 (continuous attribute)**: 在定义域上有无穷多个可能的取值
- **离散属性 (categorical attribute)**: 在定义域上是有限个 (可数个) 可能的取值
- **有序属性 (ordinal attribute)**: 例如定义域为{1,2,3}的离散属性, “1” 与 “2” 比较接近、与 “3” 比较远, 称为有序属性
- **无序属性 (non-ordinal attribute)**: 例如定义域为{飞机, 火车, 轮船}这样的离散属性, 不能直接在属性值上进行计算, 称为无序属性



- Value Difference Metric, VDM (处理无序属性)

令 $m_{u,a}$ 表示属性 u 上取值为 a 的样本数, $m_{u,a,i}$ 表示在第 i 个样本簇中在属性 u 上取值为 a 的样本数, k 为样本簇数, 则属性 u 上两个离散值 a 与 b 之间的 VDM 距离为

$$VDM_p(a, b) = \sum_{i=1}^k \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

- MinkovDM_p (处理混合属性)

$$\text{MinkovDM}_p(\mathbf{x}_i, \mathbf{x}_j) = \left(\sum_{u=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^n \text{VDM}_p(x_{iu}, x_{ju}) \right)^{\frac{1}{p}}$$




- 加权距离（**样本中不同属性的重要性不同时**）

$$\text{dist}_{\text{wmk}}(\mathbf{x}_i, \mathbf{x}_j) = \left(w_1 \cdot |x_{i1} - x_{j1}|^p + \cdots + w_n \cdot |x_{in} - x_{jn}|^p \right)^{\frac{1}{p}}$$

- 需注意的是，通常我们是基于某种形式的**距离**来定义相似度量（similarity measure），**距离越大，相似度越小**。然而，用于相似度度量的距离**未必一定要满足距离度量的所有基本性质**，尤其是直递性。
- 在某些任务中我们希望有这样的相似度量：“人” “马” 分别与 “人马” 相似，但 “人” 与 “马” 很不相似；要达到这个目的，可以令 “人” “马” 与 “人马” 之间的距离都比较小，但 “人” 与 “马” 之间的距离很大

- 此时该距离不再满足直递性，这样的距离称为**非度量距离**（non-metric distance），此外，本节介绍的距离计算式都是事先定义好的，但在不少现实任务中，有必要基于数据样本来确定合适的距离计算式，这可通过距离**度量学习**（distance metric learning）来实现。





武汉大学
WUHAN UNIVERSITY

04 原型聚类

Prototype-based clustering



- 原型聚类：也称为**基于原型的聚类**（**prototype-based clustering**），此类算法假设**聚类结构**能通过一组原型刻画
- **原型**是指样本空间中具有**代表性的“点”**
- 算法过程：通常情况下，算法先对原型进行**初始化**，再对原型进行**迭代更新**求解
- 接下来，介绍几种著名的原型聚类算法：
k均值算法、学习向量量化算法、高斯混合聚类算法



- 给定样本集 $D = \{x_1, x_2, \dots, x_m\}$ 。定义 k -means 算法中针对聚类所得簇 $C = \{C_1, C_2, \dots, C_k\}$ 最小化平方误差：

$$E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2$$

其中 $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ 是簇 C_i 的**均值向量（又称为参考向量、质心、重心）**。 E 刻画了簇内样本围绕簇均值向量的**紧密程度**， E 越小簇内样本的相似度越高。该优化问题是一个**NP难**问题

- k -means 的优化目标：

$$C^* = \{C_1, C_2, \dots, C_k\}^* = \underset{C_1, C_2, \dots, C_k}{\operatorname{argmin}} E$$



1. 算法流程 (贪心策略)

- 初始化每个簇的均值向量
- repeat
 1. (更新) 簇划分
 2. 计算每个簇的均值向量
- until 当前均值向量均未更新


● 算法伪代码如右图

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
聚类簇数 k .

过程:



```

1: 从  $D$  中随机选择  $k$  个样本作为初始均值向量  $\{\mu_1, \mu_2, \dots, \mu_k\}$ 
2: repeat
3:   令  $C_i = \emptyset$  ( $1 \leq i \leq k$ )
4:   for  $j = 1, 2, \dots, m$  do
5:     计算样本  $x_j$  与各均值向量  $\mu_i$  ( $1 \leq i \leq k$ ) 的距离:  $d_{ji} = \|x_j - \mu_i\|_2$ ;
6:     根据距离最近的均值向量确定  $x_j$  的簇标记:  $\lambda_j = \arg \min_{i \in \{1, 2, \dots, k\}} d_{ji}$ ;
7:     将样本  $x_j$  划入相应的簇:  $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$ ;
8:   end for
9:   for  $i = 1, 2, \dots, k$  do
10:    计算新均值向量:  $\mu'_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ ;
11:    if  $\mu'_i \neq \mu_i$  then
12:      将当前均值向量  $\mu_i$  更新为  $\mu'_i$ 
13:    else
14:      保持当前均值向量不变
15:    end if
16:  end for
17: until 当前均值向量均未更新
输出: 簇划分  $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ 
  
```



k均值算法的执行过程（动画）




- 经典 k -means算法有几个缺点：需要提前确定 k 值，对初始质心点敏感，对异常数据敏感



初始质心选取不当



➤ 经典k-means算法有几个缺点：需要提前确定k值，对初始质心点敏感，对异常数据敏感



k选取不当



例：已知20个模式样本如下，试用K-均值算法分类。

$$\mathbf{X}_1 = [0,0]^T \quad \mathbf{X}_2 = [1,0]^T \quad \mathbf{X}_3 = [0,1]^T \quad \mathbf{X}_4 = [1,1]^T$$

$$\mathbf{X}_5 = [2,1]^T \quad \mathbf{X}_6 = [1,2]^T \quad \mathbf{X}_7 = [2,2]^T \quad \mathbf{X}_8 = [3,2]^T$$

$$\mathbf{X}_9 = [6,6]^T \quad \mathbf{X}_{10} = [7,6]^T \quad \mathbf{X}_{11} = [8,6]^T \quad \mathbf{X}_{12} = [6,7]^T$$

$$\mathbf{X}_{13} = [7,7]^T \quad \mathbf{X}_{14} = [8,7]^T \quad \mathbf{X}_{15} = [9,7]^T \quad \mathbf{X}_{16} = [7,8]^T$$

$$\mathbf{X}_{17} = [8,8]^T \quad \mathbf{X}_{18} = [9,8]^T \quad \mathbf{X}_{19} = [8,9]^T \quad \mathbf{X}_{20} = [9,9]^T$$

解：① 取 $K=2$ ，并选： $\mathbf{Z}_1(1) = \mathbf{X}_1 = [0,0]^T$ $\mathbf{Z}_2(1) = \mathbf{X}_2 = [1,0]^T$

② 计算距离，聚类：

$$\mathbf{X}_1: \left. \begin{array}{l} D_1 = \|\mathbf{X}_1 - \mathbf{Z}_1(1)\| = 0 \\ D_2 = \|\mathbf{X}_1 - \mathbf{Z}_2(1)\| = \sqrt{(0-1)^2 + (0-0)^2} = \sqrt{1} \end{array} \right\} \Rightarrow D_1 < D_2 \Rightarrow \mathbf{X}_1 \in S_1(1)$$

$$\mathbf{X}_2: \left. \begin{array}{l} D_1 = \|\mathbf{X}_2 - \mathbf{Z}_1(1)\| = \sqrt{1} \\ D_2 = \|\mathbf{X}_2 - \mathbf{Z}_2(1)\| = 0 \end{array} \right\} \Rightarrow D_2 < D_1 \Rightarrow \mathbf{X}_2 \in S_2(1)$$



$$\mathbf{X}_3: \left. \begin{aligned} D_1 &= \|\mathbf{X}_3 - \mathbf{Z}_1(1)\| = \sqrt{(0-0)^2 + (1-0)^2} = \sqrt{1} \\ D_2 &= \|\mathbf{X}_3 - \mathbf{Z}_2(1)\| = \sqrt{(0-1)^2 + (1-0)^2} = \sqrt{2} \end{aligned} \right\} \Rightarrow D_1 < D_2 \Rightarrow \mathbf{X}_3 \in S_1(1)$$

$$\mathbf{X}_4: \left. \begin{aligned} D_1 &= \|\mathbf{X}_4 - \mathbf{Z}_1(1)\| = \sqrt{(1-0)^2 + (1-0)^2} = \sqrt{2} \\ D_2 &= \|\mathbf{X}_4 - \mathbf{Z}_2(1)\| = \sqrt{(1-1)^2 + (1-0)^2} = \sqrt{1} \end{aligned} \right\} \Rightarrow D_2 < D_1 \Rightarrow \mathbf{X}_4 \in S_2(1)$$

....., 可得到:

$$S_1(1) = \{\mathbf{X}_1, \mathbf{X}_3\} \quad N_1 = 2$$

$$S_2(1) = \{\mathbf{X}_2, \mathbf{X}_4, \mathbf{X}_5, \dots, \mathbf{X}_{20}\} \quad N_2 = 18$$

③ 计算新的聚类中:

$$\mathbf{Z}_1(2) = \frac{1}{N_1} \sum_{\mathbf{X} \in S_1(1)} \mathbf{X} = \frac{1}{2} (\mathbf{X}_1 + \mathbf{X}_3) = \frac{1}{2} \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = \begin{bmatrix} 0 \\ 0.5 \end{bmatrix}$$

$$\mathbf{Z}_2(2) = \frac{1}{N_2} \sum_{\mathbf{X} \in S_2(1)} \mathbf{X} = \frac{1}{18} (\mathbf{X}_2 + \mathbf{X}_4 + \dots + \mathbf{X}_{20}) = \begin{bmatrix} 5.67 \\ 5.33 \end{bmatrix}$$

④ 判断: $\because \mathbf{Z}_j(2) \neq \mathbf{Z}_j(1) \quad j = 1, 2$, 故返回第②步。



② 从新的聚类中心得:

$$\left. \begin{array}{l} X_1 : D_1 = \|X_1 - Z_1(2)\| = \dots \\ D_2 = \|X_1 - Z_2(2)\| = \dots \end{array} \right\} \Rightarrow X_1 \in S_1(2)$$

⋮

$$\left. \begin{array}{l} X_{20} : D_1 = \|X_{20} - Z_1(2)\| = \dots \\ D_2 = \|X_{20} - Z_2(2)\| = \dots \end{array} \right\} \Rightarrow X_{20} \in S_2(2)$$

有: $S_1(2) = \{X_1, X_2, \dots, X_8\} \quad N_1 = 8$

$$S_2(2) = \{X_9, X_{10}, \dots, X_{20}\} \quad N_2 = 12$$

③ 计算聚类中心:

$$Z_1(3) = \frac{1}{N_1} \sum_{X \in S_1(2)} X = \frac{1}{8} (X_1 + X_2 + \dots + X_8) = \begin{bmatrix} 1.25 \\ 1.13 \end{bmatrix}$$

$$Z_2(3) = \frac{1}{N_2} \sum_{X \in S_2(2)} X = \frac{1}{12} (X_9 + X_{10} + \dots + X_{20}) = \begin{bmatrix} 7.67 \\ 7.33 \end{bmatrix}$$



$$\textcircled{4} \quad \because \mathbf{Z}_j(3) \neq \mathbf{Z}_j(2) \quad j = 1, 2$$

返回第②步，以 $\mathbf{Z}_1(3)$ ， $\mathbf{Z}_2(3)$ 为中心进行聚类。

② 以新的聚类中心分类，求得的分类结果与前一次迭代结果相同：

$$S_1(3) = S_1(2) \quad S_2(3) = S_2(2)$$

③ 计算新聚类中心向量值，聚类中心与前一次结果相同，即：

$$\mathbf{Z}_j(4) = \mathbf{Z}_j(3), \quad j = 1, 2$$

④ $\because \mathbf{Z}_j(4) = \mathbf{Z}_j(3)$ 故算法收敛，得聚类中心为

$$\mathbf{Z}_1 = \begin{bmatrix} 1.25 \\ 1.13 \end{bmatrix}, \quad \mathbf{Z}_2 = \begin{bmatrix} 7.67 \\ 7.33 \end{bmatrix}$$

结果图示：




图2.10 K-均值算法聚类结果



“动态” 聚类法




聚类过程中，
聚类（簇）中心位置或簇包含的样本个数
不断发生变化。


2. 算法讨论

结果很容易受到所选**聚类中心个数**和其**初始位置**，以及**模式样本的几何性质（尺寸、密度、整体性状、异常值）**及**读入次序**等的**影响**。


实际应用中，需要**试探不同的k值**和**选择不同的聚类中心起始值**。




Original Points




Optimal Clustering



Sub-optimal Clustering




Original Points




K-means (3 Clusters)

1、当待聚类数据中**各个自然类的样本数据量不平衡**时，k均值的效果不太理想。




Original Points




K-means (3 Clusters)

2、当待聚类数据中各个自然类的样本密度不一致时，K均值的效果也不太理想。



Original Points




K-means (2 Clusters)

3、当待聚类数据中各个自然类的样本分布不是球形时，k均值的效果也不太理想。


K均值适合的聚类数据类型是，其自然族：**球形、等尺寸、等密度**



- 以下两个数据集的 k 均值聚类的理想相似度和邻近度矩阵的相关性。





Corr = -0.9235





Corr = -0.5810



- 根据聚类标签对相似性矩阵进行**排序**，并目视检查。




- 可以看出随机数据中的聚类不是那么清晰



k-means





3. 聚类准则函数 J_j 与 K 的关系曲线

上述K-均值算法，其类型数目**假定**已知为 K 个。当 K 未知时，可以令 K 逐渐增加，此时 J_j 会单调减少。最初减小速度快，但当 K 增加到一定数值时，减小速度会减慢，直到 $K = \text{总样本数}N$ 时， $J_j = 0$ 。 $J_j - K$ 关系曲线如下图：



曲线的拐点 A 对应着接近最优的 K 值（ J 值减小量、计算量以及分类效果的**权衡**）。

并非所有的情况都容易找到关系曲线的**拐点**。**迭代自组织的数据分析算法**可以确定模式类的个数 K 。





- 学习向量量化 (Learning Vector Quantization, LVQ)

该方法试图找到一组**原型向量**来刻画聚类结构。与一般聚类算法不同的是，**LVQ假设数据样本带有类别标记**，学习过程中利用样本的这些监督信息来辅助聚类。

- 给定样本集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，每个样本 x_j 是由 n 个属性描述的特征向量 $(x_{j1}; x_{j2}; \dots; x_{jn})$ ， $y_j \in Y$ 是样本 x_j 的类别标记，LVQ 的目标是学得一组 n 维原型向量 $\{p_1, p_2, \dots, p_q\}$ ，每个原型向量代表一个聚类簇，簇标记 $t_i \in Y$



● 算法伪代码

输入: 样本集 $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}$;
 原型向量个数 q , 各原型向量预设的类别标记 $\{t_1, t_2, \dots, t_q\}$;
 学习率 $\eta \in (0, 1)$.

过程:

```

1: 初始化一组原型向量  $\{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_q\}$ 
2: repeat
3:   从样本集  $D$  随机选取样本  $(\mathbf{x}_j, y_j)$ ;
4:   计算样本  $\mathbf{x}_j$  与  $\mathbf{p}_i$  ( $1 \leq i \leq q$ ) 的距离:  $d_{ji} = \|\mathbf{x}_j - \mathbf{p}_i\|_2$ ;
5:   找出与  $\mathbf{x}_j$  距离最近的原型向量;  $i^* = \arg \min_{i \in \{1, 2, \dots, q\}} d_{ji}$ ;
6:   if  $y_j = t_{i^*}$  then
7:      $\mathbf{p}' = \mathbf{p}_{i^*} + \eta \cdot (\mathbf{x}_j - \mathbf{p}_{i^*})$ 
8:   else
9:      $\mathbf{p}' = \mathbf{p}_{i^*} - \eta \cdot (\mathbf{x}_j - \mathbf{p}_{i^*})$ 
10:  end if
11: 将原型向量  $\mathbf{p}_{i^*}$  更新为  $\mathbf{p}'$ 
12: until 满足停止条件
13: return 当前原型向量
  
```

输出: 原型向量 $\{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_q\}$

- 显然LVQ的关键是第6-10行, 即**如何更新原型向量**, 直观上看, 对样本 $\mathbf{x}_j$, 若最近的原型向量 $\mathbf{p}_{i^*}$ 与 $\mathbf{x}_j$ 的类别标记相同, 则**令 $\mathbf{p}_{i^*}$ 向 $\mathbf{x}_j$ 的方向靠拢**, 如第7行所示, 此时新原型向量为 $\mathbf{p}' = \mathbf{p}_{i^*} + \eta \cdot (\mathbf{x}_j - \mathbf{p}_{i^*})$


- $\mathbf{p}'$ 与 $\mathbf{x}_j$ 之间的距离为:

$$\begin{aligned} \|\mathbf{p}' - \mathbf{x}_j\|_2 &= \|\mathbf{p}_{i^*} + \eta \cdot (\mathbf{x}_j - \mathbf{p}_{i^*}) - \mathbf{x}_j\|_2 \\ &= (1 - \eta) \cdot \|\mathbf{p}_{i^*} - \mathbf{x}_j\|_2 \end{aligned}$$

- 令学习率 $\eta \in (0, 1)$, 则原型向量 $\mathbf{p}_{i^*}$ 在更新为 $\mathbf{p}'$ 之后更接近 $\mathbf{x}_j$



- 算法聚类效果 (西瓜书p207)



学得原型向量后，
可实现对于样本空间的簇划分，任意
样本被划入与其距离最近的原型向量
所代表的簇中。亦即每个原型向量定
义了与之相关的一个区域，该区域中
每个样本与原型向量的距离不大于它
与其他原型向量的距离。



- 与k均值、LVQ用**原型向量**来刻画聚类结构不同，**高斯混合聚类 (Mixture-of-Gaussian)** 采用**概率模型 (高斯分布)** 来表达聚类原型。
- 多元高斯分布的定义

对 n 维样本空间 χ 中的**随机向量** x ，若 x 服从高斯分布，其概率密度函数为

$$p(x) = \frac{1}{2\pi^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)}$$

其中 μ 是 n 维均值向量， Σ 是 $n \times n$ 的协方差矩阵，也可将概率密度函数记作 **$p(x|\mu, \Sigma)$**



- 高斯混合分布的定义

$$p_{\mathcal{M}}(\mathbf{x}) = \sum_{i=1}^k \alpha_i \cdot p(\mathbf{x} \mid \boldsymbol{\mu}_i, \Sigma_i)$$

- 该分布由 k 个混合分布组成，**每个成分对应一个高斯分布**，其中 $\boldsymbol{\mu}_i$ 与 Σ_i 是第 i 个高斯混合成分的参数，而 $\alpha_i > 0$ 为相应的混合系数， $\sum_{i=1}^k \alpha_i = 1$ 。**高斯混合分布是一个概率分布**
- **假设样本的生成过程由高斯混合分布给出**，首先**根据 $\alpha_1, \alpha_2, \dots, \alpha_k$ 定义的先验分布选择高斯混合成分**，其中 α_i 为选择第个 i 混合成分的概率。



- 然后，根据被选择的混合成分的概率密度函数进行采样，从而生成相应的样本
- 若训练集 $D = \{x_1, x_2, \dots, x_m\}$ 由上述过程生成，令随机变量 $z_j \in \{1, 2, \dots, k\}$ 表示生成样本 x_j 的高斯混合成分，其取值未知，显然 z_j 的先验概率 $P(z_j = i)$ 对应于 $\alpha_i \{i = 1, 2, \dots, k\}$ ，根据贝叶斯定理， z_j 的后验分布对应于：

$$\begin{aligned} p_{\mathcal{M}}(z_j = i \mid x_j) &= \frac{P(z_j = i) \cdot p_{\mathcal{M}}(x_j \mid z_j = i)}{p_{\mathcal{M}}(x_j)} \\ &= \frac{\alpha_i \cdot p(x_j \mid \mu_i, \Sigma_i)}{\sum_{l=1}^k \alpha_l \cdot p(x_j \mid \mu_l, \Sigma_l)} \end{aligned}$$

从原型聚类的角度来看，高斯混合聚类采用高斯分布对原型进行刻画，簇划分由原型对应的后验概率确定（样本被划分为上式取最大的簇标记对应的簇）



- 模型求解：最大化（对数）似然：

$$\begin{aligned} LL(D) &= \ln \left(\prod_{j=1}^m p_{\mathcal{M}}(\mathbf{x}_j) \right) \\ &= \sum_{j=1}^m \ln \left(\sum_{i=1}^k \alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \Sigma_i) \right) \end{aligned}$$

- 令 $\frac{\partial LL(D)}{\partial \mu_i} = 0$ ，则有：

$$\sum_{j=1}^m \frac{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \Sigma_i)}{\sum_{l=1}^k \alpha_l \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_l, \Sigma_l)} (\mathbf{x}_j - \boldsymbol{\mu}_i) = 0$$



- 由 z_j 的后验分布公式以及 $\gamma_{ji} = p_M(z_j = i | x_j)$, 有:

$$\mu_i = \frac{\sum_{j=1}^m \gamma_{ji} x_j}{\sum_{j=1}^m \gamma_{ji}}$$

- 类似的, 由 $\frac{\partial LL(D)}{\partial \Sigma_i} = 0$ 可得

$$\Sigma_i = \frac{\sum_{j=1}^m \gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^m \gamma_{ji}}$$

对于混合系数 α_i 求解, 利用拉格朗日乘子法, 即可得 α_i 由样本属于该成分的平均后验概率确定



- 算法伪代码

2-12行基于EM算法
对模型参数进行迭
代更新，直到达到
最大迭代轮数或者
似然增长很少

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
高斯混合成分个数 k .

过程:


- 1: 初始化高斯混合分布的模型参数 $\{(\alpha_i, \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \mid 1 \leq i \leq k\}$
- 2: **repeat**
- 3: **for** $j = 1, \dots, m$ **do**
- 4: 根据(9.30)计算 $\mathbf{x}_j$ 由各混合成分生成的后验概率, 即

$$\gamma_{ji} = p_{\mathcal{M}}(z_j = i \mid \mathbf{x}_j) \quad (1 \leq i \leq k)$$
- 5: **end for**
- 6: **for** $i = 1, \dots, k$ **do**
- 7: 计算新均值向量: $\boldsymbol{\mu}'_i = \frac{\sum_{j=1}^m \gamma_{ji} \mathbf{x}_j}{\sum_{j=1}^m \gamma_{ji}};$
- 8: 计算新协方差矩阵: $\boldsymbol{\Sigma}'_i = \frac{\sum_{j=1}^m \gamma_{ji} (\mathbf{x}_j - \boldsymbol{\mu}'_i)(\mathbf{x}_j - \boldsymbol{\mu}'_i)^\top}{\sum_{j=1}^m \gamma_{ji}};$
- 9: 计算新混合系数: $\alpha'_i = \frac{\sum_{j=1}^m \gamma_{ji}}{m};$
- 10: **end for**
- 11: 将模型参数 $\{(\alpha_i, \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \mid 1 \leq i \leq k\}$ 更新为 $\{(\alpha'_i, \boldsymbol{\mu}'_i, \boldsymbol{\Sigma}'_i) \mid 1 \leq i \leq k\}$
- 12: **until** 满足停止条件
- 13: $C_i = \emptyset \quad (1 \leq i \leq k)$
- 14: **for** $j = 1, \dots, m$ **do**
- 15: 根据(9.31)确定 $\mathbf{x}_j$ 的簇标记 λ_j ;
- 16: 将 $\mathbf{x}_j$ 划入相应的簇: $C_{\lambda_j} = C_{\lambda_j} \cup \{\mathbf{x}_j\}$
- 17: **end for**
- 18: **return** 簇划分结果


输出: 簇划分 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$




- 算法聚类效果 (西瓜书p211)




(a) 5轮迭代后



(b) 10轮迭代后



(c) 20轮迭代后



(d) 50轮迭代后



武汉大学
WUHAN UNIVERSITY

05 密度聚类

Density-based clustering


1 DBSCAN聚类密度

- 密度聚类也称为**基于密度的聚类**（density-based clustering），此类算法假设聚类结构能通过样本分布的**紧密程度**来确定。通常情况下，密度聚类算法从样本密度的角度来考察样本之间的**可连接性**，并基于可连接样本不断扩展聚类簇来获得最终的聚类结果。
- **DBSCAN**是一种基于密度的聚类算法（density-based clustering），其基于一组“邻域”参数（ ϵ , $MinPts$ ）来刻画样本分布的紧密程度。



➤ 给定样本集 $D = \{x_1, x_2, \dots, x_m\}$ ，定义如下几个概念：

- **ϵ -邻域**：对 $x_j \in D$ ，其 ϵ -邻域包含样本集 D 中与 x_j 的距离 **不大于 ϵ** 的样本（假设为**欧氏距离**）
- **核心对象**：若 x_j 的 ϵ -邻域 **至少包含 $MinPts$ 个样本**，则 x_j 是一个核心对象
- **密度直达**：若 x_j 位于 x_i 的 ϵ -邻域中，且 x_i 是核心对象，则 x_j 由 x_i **密度直达**
- **密度可达**：对 x_i 与 x_j ，若存在**样本序列** $p_1, p_2, \dots, p_n$ ，其中 $p_1 = x_i$ ， $p_n = x_j$ 且 p_{i+1} 由 p_i 密度直达，则称 x_j 由 x_i **密度可达**
- **密度相连**：对 x_i 与 x_j ，若存在 x_k 使得 x_i 与 x_j 均由 x_k 密度可达，则称 x_i 与 x_j **密度相连**



- x_2 由 x_1 密度直达
- x_3 由 x_1 密度可达
- x_3 与 x_4 密度相连
- 直达与可达的差别？可达与相连的差别？

ϵ 描述了某一样本的邻域距离阈值，
 $MinPts$ 描述了某一样本的距离为 ϵ 的邻域中样本个数的阈值

红色点均为核心对象， $MinPts = 3$

绿色点均为异常点，既不是核心点也不是边界点

像不像疫情期间的密接、次密接、次次密接



- 基于上述概念，DBSCAN将“簇”定义为：**由密度可达关系导出的最大的密度相连样本集合**。给定邻域参数 $(\epsilon, MinPts)$ ，簇 $C \subseteq D$ 是满足以下性质的非空样本子集：

- 连续性： $x_i \in C, x_j \in C \Rightarrow x_i$ 与 x_j 密度相连
- 最大性： $x_i \in C, x_j$ 由 x_i 密度可达 $\Rightarrow x_j \in C$

- 一个DBSCAN的簇里面可以有**一个或者多个核心对象**：

- 如果只有一个核心对象，则**簇里其他的非核心对象样本都在这个核心对象的 ϵ -邻域里**；
- 如果有多个核心对象，则**簇里的任意一个核心对象的 ϵ -邻域中一定有一个其他的核心对象，否则这两个核心对象无法密度可达**。这些核心对象的 ϵ -邻域里所有的样本的集合组成一个DBSCAN聚类簇。



2 DBSCAN聚类步骤

- DBSCAN算法初始任意选择一个核心对象，然后**找到所有这个核心对象能够密度可达的样本集合，即为一个聚类簇**。接着继续选择另一个没有类别的核心对象去寻找密度可达的样本集合，这样就得到另一个聚类簇。**一直运行到所有核心对象都有类别为止。**

- 从任意核心对象出发，基于密度可达性扩展聚类。完成一簇后再挑选未被选中的核心对象重复过程，直至遍历完所有核心对象

DBSCAN流程

- 根据给定的邻域参数(ϵ , $MinPts$)找出所有的核心对象

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
邻域参数 (ϵ , $MinPts$).

过程:

- 1: 初始化核心对象集合: $\Omega = \emptyset$
- 2: **for** $j = 1, 2, \dots, m$ **do**
- 3: 确定样本 x_j 的 ϵ -邻域 $N_\epsilon(x_j)$;
- 4: **if** $|N_\epsilon(x_j)| \geq MinPts$ **then**
- 5: 将样本 x_j 加入核心对象集合: $\Omega = \Omega \cup \{x_j\}$
- 6: **end if**
- 7: **end for**

先确定核心对象




- 以任意核心点为出发点，找出由其密度可达的样本生成聚类簇，直到所有核心对象均被访问过为止

```
8: 初始化聚类簇数:  $k = 0$ 
9: 初始化未访问样本集合:  $\Gamma = D$ 
10: while  $\Omega \neq \emptyset$  do
11:   记录当前未访问样本集合:  $\Gamma_{old} = \Gamma$ ;
12:   随机选取一个核心对象  $o \in \Omega$ , 初始化队列  $Q = \langle o \rangle$ ;
13:    $\Gamma = \Gamma \setminus \{o\}$ ;
14:   while  $Q \neq \emptyset$  do
15:     取出队列  $Q$  中的首个样本  $q$ ;
16:     if  $|N_{\epsilon}(q)| \geq MinPts$  then
17:       令  $\Delta = N_{\epsilon}(q) \cap \Gamma$ ;
18:       将  $\Delta$  中的样本加入队列  $Q$ ;
19:        $\Gamma = \Gamma \setminus \Delta$ ;
20:     end if
21:   end while
22:    $k = k + 1$ , 生成聚类簇  $C_k = \Gamma_{old} \setminus \Gamma$ ;
23:    $\Omega = \Omega \setminus C_k$ 
24: end while
输出: 簇划分  $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ 
```

判断是否为核心对象

若是，则将该核心对象领域内的密度直达样本加入簇

在未被聚类的核心对象中选一个为种子，继续执行算法

DBSCAN聚类算法的执行过程
(动画)

epsilon = 1.00
minPoints = 4


Restart



Pause




DBSCAN Cluster Process



3 DBSCAN聚类分析

提问：不同参数对聚类结果造成什么影响？

不同 ϵ 值的聚类结果

不同MinPts值的聚类结果



- 一般来说，DBSCAN算法有以下几个特点：
- 需要**提前确定** ϵ 和MinPts值
 - **不需要提前设置聚类类别的个数**
 - 对初值（初始核心对象）**选取不敏感**，对噪声不敏感
 - **对密度不均的数据聚合效果不好**



武汉大学
WUHAN UNIVERSITY

06 层次聚类

Hierarchical clustering



- 层次聚类 (Hierarchical Clustering) 试图在不同层次对数据进行划分, 可以**自上而下**或**自下而上**实现。自下而上的算法在一开始就将每个数据点视为一个单一的聚类, 然后依次合并 (或聚集) 类, 直到所有类合并成一个包含所有数据点的单一聚类。自上而下的方法则先将所有数据看作一类, 然后逐步划分。



- **凝聚的方法 (agglomerative)** (自下向上、聚合)

思想: 将每个对象作为单独的一组, 然后根据同类相近, 异类相异的原则, 合并对象, 直到所有的组合成一个, 或达到一个终止条件为止

- **分裂的方法 (divisive)** (自上向下、拆分)

思想: 将所有的对象置于一类, 在迭代的每一步中, 一个类不断地分为更小的类, 直到每个对象在单独的一个类中, 或达到一个终止条件

1 层次聚类思想



层次聚类示意图 (动画)

层次聚类其实是一组**有依赖关系**的聚类，后一聚类依赖前一聚类结果，是在前一聚类结果的基础上，按照一定规则进行新的聚类。因为有依赖关系，因此这一组聚类就形成一个**树状结构**。

层次聚类有分为：凝聚式（agglomerative）和 分裂式（divisive）两种不同的方法。

1. 算法描述

【以下讨论的是**凝聚式层次聚类法**】

1) N 个初始模式样本自成一类，即建立 N 类：

$$G_1(0), G_2(0), \dots, G_N(0)$$

计算各类之间（即各样本间）的距离，得一 $N \times N$ 维**距离矩阵** $D(0)$ 。

“0”表示初始状态。



2) 假设已求得距离矩阵 $\mathbf{D}(n)$ (n 为逐次聚类合并的次数), 找出 $\mathbf{D}(n)$ 中的**最小元素**, 将其对应的两类合并为一类。由此建立新的分类:

$$G_1(n+1), G_2(n+1), \dots$$

3) 再次计算: 经过合并后, 各个类别之间的距离, 得 $\mathbf{D}(n+1)$ 。
显然, $\mathbf{D}(n+1)$ 的维数是 $\mathbf{D}(n)$ 的维数**减一**。

4) 跳至第2步, 重复计算及合并。

结束条件:

- 1) 取距离阈值 T , 当 $\mathbf{D}(n)$ 的最小分量**超过给定值 T** 时 (即: **当前各聚类间的距离, 都足够大**), 算法停止。所得即为聚类结果。
- 2) 或不设阈值 T , 一直将全部样本**聚成一类为止**, 输出聚类的分级树 (得到全部可能的聚类结果——**谱系聚类**的名称由来)。

2. 问题讨论：类间距离计算方法


1) 最短距离法（单链距离法）

如果 H 、 K 是两个聚类，则两类间的最短距离定义为：

$$D_{HK} = \min \{D(X_H, X_K)\} \quad X_H \in H, X_K \in K$$

$D(X_H, X_K)$ ： H 类中的某个样本 X_H 和 K 类中的某个样本 X_K 之间的欧氏距离。

D_{HK} ： H 类中所有样本与 K 类中所有样本之间的最小距离。




如果 K 类由 I 和 J 两类合并而成, 且 H 与 I , H 与 J 的距离已计算

$$D_{HI} = \min \{D(X_H, X_I)\} \quad X_H \in H, X_I \in I$$

$$D_{HJ} = \min \{D(X_H, X_J)\} \quad X_H \in H, X_J \in J$$

则有**递推关系**: $D_{HK} = \min \{D_{HI}, D_{HJ}\}$



2) 最长距离法 (全链距离法)

$$D_{HK} = \max \{D(X_H, X_K)\} \quad X_H \in H, X_K \in K$$

若 K 类由 I 、 J 两类合并而成

$$D_{HI} = \max \{D(X_H, X_I)\} \quad X_H \in H, X_I \in I$$

$$D_{HJ} = \max \{D(X_H, X_J)\} \quad X_H \in H, X_J \in J$$

则有**递推关系**: $D_{HK} = \max \{D_{HI}, D_{HJ}\}$



3) 类平均距离法 (组平均距离法)

$$D_{HK} = \sqrt{\frac{1}{n_H n_K} \sum_{\substack{i \in H \\ j \in K}} d_{ij}^2}$$

d_{ij}^2 : H 类任一样本 $\mathbf{x}_i$ 和 K 类任一样本 $\mathbf{x}_j$ 之间的欧氏距离平方 (与书中表达稍不同)。

若 K 类由 I 类和 J 类合并产生, 则有**递推关系**

$$D_{HK} = \sqrt{\frac{n_I}{n_I + n_J} D_{HI}^2 + \frac{n_J}{n_I + n_J} D_{HJ}^2}$$

定义类间距离的方法不同, 聚类结果会不太一致。实际问题中常用几种不同的方法, 比较聚类结果, 从而**选择一个比较切合实际的聚类。**



例：给出6个**5维**模式样本如下，按**最短距离准则**进行系统聚类分类。

$$\mathbf{X}_1 = [0, 3, 1, 2, 0]^T \quad \mathbf{X}_2 = [1, 3, 0, 1, 0]^T \quad \mathbf{X}_3 = [3, 3, 0, 0, 1]^T$$

$$\mathbf{X}_4 = [1, 1, 0, 2, 0]^T \quad \mathbf{X}_5 = [3, 2, 1, 2, 1]^T \quad \mathbf{X}_6 = [4, 1, 1, 1, 0]^T$$

解：（1）首先，将每一样本看作单独一类，得：

$$G_1(0) = \{\mathbf{X}_1\} \quad G_2(0) = \{\mathbf{X}_2\} \quad G_3(0) = \{\mathbf{X}_3\}$$

$$G_4(0) = \{\mathbf{X}_4\} \quad G_5(0) = \{\mathbf{X}_5\} \quad G_6(0) = \{\mathbf{X}_6\}$$

计算各类间欧氏距离，并填表：

$$D_{12}(0) = \|\mathbf{X}_1 - \mathbf{X}_2\| = \left[(x_{11} - x_{21})^2 + (x_{12} - x_{22})^2 + (x_{13} - x_{23})^2 + (x_{14} - x_{24})^2 + (x_{15} - x_{25})^2 \right]^{1/2}$$

$$= [1 + 0 + 1 + 1 + 0]^{1/2} = \sqrt{3}$$

$$D_{13}(0) = [3^2 + 0 + 1 + 2^2 + 1]^{1/2} = \sqrt{15} \quad , \quad D_{14}(0) \quad D_{15}(0) \quad , D_{16}(0) \quad ;$$

$$D_{23}(0) \quad D_{24}(0) \quad D_{25}(0) \quad D_{26}(0) \quad ; \quad D_{34}(0) \quad D_{35}(0) \quad D_{36}(0) \quad \dots$$



得距离矩阵 $D(0)$:

$D(0)$	$G_1(0)$	$G_2(0)$	$G_3(0)$	$G_4(0)$	$G_5(0)$	$G_6(0)$
$G_1(0)$	0					
$G_2(0)$	$\sqrt{3}$	0				
$G_3(0)$	$\sqrt{15}$	$\sqrt{6}$	0			
$G_4(0)$	$\sqrt{6}$	$\sqrt{5}$	$\sqrt{13}$	0		
$G_5(0)$	$\sqrt{11}$	$\sqrt{8}$	$\sqrt{6}$	$\sqrt{7}$	0	
$G_6(0)$	$\sqrt{21}$	$\sqrt{14}$	$\sqrt{8}$	$\sqrt{11}$	$\sqrt{4}$	0

(2) 将最小距离 $\sqrt{3}$ 对应的类 $G_1(0)$ 和 $G_2(0)$ 合并为1类, 得新的分类。

$$G_{12}(1) = \{G_1(0), G_2(0)\}$$

$$G_3(1) = \{G_3(0)\} \quad G_4(1) = \{G_4(0)\}$$

$$G_5(1) = \{G_5(0)\} \quad G_6(1) = \{G_6(0)\}$$

计算聚类后的距离矩阵 $D(1)$:

由 $D(0)$ 递推出 $D(1)$ 。



$D(0)$	$G_1(0)$	$G_2(0)$	$G_3(0)$	$G_4(0)$	$G_5(0)$	$G_6(0)$
$G_1(0)$	0					
$G_2(0)$	$\sqrt{3}$	0				
$G_3(0)$	<u>$\sqrt{15}$</u>	<u>$\sqrt{6}$</u>	0			
$G_4(0)$	<u>$\sqrt{6}$</u>	<u>$\sqrt{5}$</u>	$\sqrt{13}$	0		
$G_5(0)$	<u>$\sqrt{11}$</u>	<u>$\sqrt{8}$</u>	$\sqrt{6}$	$\sqrt{7}$	0	
$G_6(0)$	<u>$\sqrt{21}$</u>	<u>$\sqrt{14}$</u>	$\sqrt{8}$	$\sqrt{11}$	$\sqrt{4}$	0

$D(1)$	$G_{12}(1)$	$G_3(1)$	$G_4(1)$	$G_5(1)$	$G_6(1)$
$G_{12}(1)$	0				
$G_3(1)$	$\sqrt{6}$	0			
$G_4(1)$	$\sqrt{5}$	$\sqrt{13}$	0		
$G_5(1)$	$\sqrt{8}$	$\sqrt{6}$	$\sqrt{7}$	0	
$G_6(1)$	$\sqrt{14}$	$\sqrt{8}$	$\sqrt{11}$	$\sqrt{4}$	0

(3) 将 $D(1)$ 中最小值 $\sqrt{4}$
对应的类合为一类,
得 $D(2)$ 。

$D(2)$	$G_{12}(2)$	$G_3(2)$	$G_4(2)$	$G_{56}(2)$
$G_{12}(2)$	0			
$G_3(2)$	$\sqrt{6}$	0		
$G_4(2)$	$\sqrt{5}$	$\sqrt{13}$	0	
$G_{56}(2)$	$\sqrt{8}$	$\sqrt{6}$	$\sqrt{7}$	0



(4) 将 $D(2)$ 中最小值 $\sqrt{5}$ 对应的类合为一类，得 $D(3)$ 。

$D(2)$	$G_{12}(2)$	$G_3(2)$	$G_4(2)$	$G_{56}(2)$
$G_{12}(2)$	0			
$G_3(2)$	<u>$\sqrt{6}$</u>	0	<u>$\sqrt{13}$</u>	
$G_4(2)$	* $\sqrt{5}$	$\sqrt{13}$	0	
$G_{56}(2)$	<u>$\sqrt{8}$</u>	<u>$\sqrt{6}$</u>	<u>$\sqrt{7}$</u>	0


$D(3)$	$G_{124}(3)$	$G_3(3)$	$G_{56}(3)$
$G_{124}(3)$	0		
$G_3(3)$	$\sqrt{6}$	0	
$G_{56}(3)$	$\sqrt{7}$	$\sqrt{6}$	0

若给定阈值为 $T = \sqrt{5}$, $D(3)$ 中的最小元素 $\sqrt{6} > T$ 聚类结束。

$$G_1 = \{X_1, X_2, X_4\} \quad G_2 = \{X_3\} \quad G_3 = \{X_5, X_6\}$$

若无阈值，继续分下去，最终全部样本归为一类。

可给出聚类过程的树状表示图。



↑
类间距离
阈值增大，
分类变粗。

层次聚类法的树形图表示

2 AGNES聚类方法

- AGNES (AGglomerative NESting) 聚类是一种采用**自底向上聚合策略**的层次聚类算法。该算法通过不断合并距离最近的聚类簇，直到达到预设的聚类簇个数或满足其他停止条件为止

AGNES流程

假设有 m 个待聚类的样本，

- 1、初始化：把每个样本归为一簇，计算每两个簇之间的距离，也就是样本与样本之间的相似度；
- 2、寻找各个簇之间**最近**的两个簇，把他们归为一类（簇的总数减少一个）
- 3、重新计算新生成的这个簇与各个旧簇之间的**相似度（递推）**；
- 重复2和3直到所有样本点都归为一簇，结束

➤ 可以看出其中最关键的一步就是**计算两个类簇的相似度**，这里有多种度量方法（西瓜书）

- 单链接（single-linkage）：取类间最小距离

$$d_{\min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} \text{dist}(x, z)$$

- 全链接（complete-linkage）：取类间最大距离

$$d_{\max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} \text{dist}(x, z)$$

- 均链接（average-linkage）：取类间两两的平均距离

$$d_{\text{avg}}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} \text{dist}(x, z)$$

➤ 很容易看出：单链接的**包容性极强**，全链接则**只要存在缺点就坚决不合并**，均连接则是**从全局出发顾全大局的一种度量**。




➤ 层次聚类方法的特点：

- 层次聚类算法**不要求我们指定聚类的数量**，我们甚至可以选择哪个聚类看起来最好。
此外，该算法**对距离度量的选择不敏感**；
- 当底层数据具有层次结构时，**可以恢复层次结构**；
- 层次聚类的优点是以**低效率**为代价的，通常具有 $O(n^3)$ 的时间复杂度，与 k -means和高斯混合模型的线性时间复杂度不同

延伸阅读：复杂网络的社区发现

- 近20年来，**复杂网络** (complex network) 研究广泛，是复杂系统的抽象。人们发现复杂网络具有一定的**社区结构**，即复杂网络并不是一大批性质完全相同的节点随机连接在一起，也不是各种类型的节点之间不相关的随意链接，而是“**乱中有序**”——**相同类型节点之间连接较多，构成一个一个的小社区** (Community)







延伸阅读：复杂网络的社区发现

- 在大型复杂网络中进行**社区发现**与搜索算法，具有重要的实际意义
 - **社会关系网络**中，能够显示根据兴趣、职业、地域、背景而形成的真实的社会团体。从而可以进行**人物分析、职业推荐、圈子推荐、好友推荐、校友发现、以及精准广告投放**
 - **引文网络社区**中，可以根据主题词、作者、内容、单位进行文章搜索与发掘。可以按照用户搜索词进行相关推荐，或者对引用次数及质量分析确定影响因子，或者论文查重算法的设计，都需要网络社区理论做支撑
 - **生物化学网络社区**。此类网络中的社区可以是某一类型的功能单元，发现其中社区有助于有效地理解、开发这些网络，例如生物学领域的食物链分析、人类基因库分析等

延伸阅读：复杂网络的社区发现

- **层次聚类思想在复杂网络社区发现中被广泛应用。** 根据网络中结点间的紧密度或者相似度，将网络划分为若干子集。思路分为分裂方法(Divisive Method)和凝聚方法(Agglomerative Method)。GN(Girvan-Newman)算法是比较著名的分裂算法，Newman方法是基于模块相似度的凝聚方法



- [1] Girvan M, Newman M E J. Community structure in social and biological networks[J]. PNAS, 2001, 99(12): 7821-7826.
- [2] Newman M E J. Fast algorithm for detecting community structure in networks[J]. Physical Review E, 2004, 69(6): 066133.



武漢大學
WUHAN UNIVERSITY

End of This Part

课后阅读西瓜书第9章。扩展思考：K均值算法与高斯混合聚类有何关系？聚类集成有何优点？聚类方法如何用于异常检测？