



第十三章：半监督学习

—— 自强弘毅 求是拓新 ——



|| 目录 ||

CONTENTS

- 1 未标记样本**
- 2 生成式方法**
- 3 半监督SVM**
- 4 图半监督学习**
- 5 基于分歧的方法**
- 6 半监督聚类**



01

未标记样本



背景-半监督学习



武汉大学
WUHAN UNIVERSITY

(纯) 半监督学习

待测数据

模型

品瓜师

有标记样本

无标记样本

直推学习


少量标记样本，大量未标记
样本咋办？全部标记、主动
学习、**半监督**



背景-主动学习



武汉大学
WUHAN UNIVERSITY





- **未标记样本**虽未直接包含标记信息，但若它们与有标记样本是从同样的数据源**独立同分布**采样而来，则它们所包含的关于数据分布的信息对**建立模型**将大有裨益。下图给出了一个直观的例示，若仅基于图中的一个正例和一个反例，则由于待判别样本恰位于两者正中间，大体上只能随机猜测；若能**观察到图中的未标记样本**，则将很有把握地判别为正例




图 (13.1)



- 让学习器**不依赖外界交互、自动地利用未标记样本**来提升学习性能，就是**半监督学习** (semi-supervised learning)
半监督学习的现实需求非常强烈，因为在现实应用中往往能容易地收集到大量未标记样本，而获取**标记**却需耗费人力、物力
- 例如，在进行计算机辅助医学影像分析时，可以从医院获得大量医学影像，但若希望医学专家把影像中的病灶全都标识出来则是不现实的



- 要利用未标记样本，必然要做一些将未标记样本所揭示的**数据分布**信息与**类别标记**相联系的**假设**
- 最常见的是**聚类假设** (cluster assumption)，即假设数据存在簇结构，同一个**簇**的样本属于同一个**类别**，图(13.1)就是基于聚类假设来利用未标记样本，由于待预测样本与正例样本通过未标记样本的**撮合聚在一起**，与相对分离的反例样本相比，待判别样本更可能属于正类



未标记样本的假设



武汉大学
WUHAN UNIVERSITY

- 半监督学习中另一种常见的假设是**流形假设**（manifold assumption），即假设数据分布在一个流形结构上，**邻近**的样本拥有**相似的输出值**。**邻近程度常用相似程度来刻画**，因此，流形假设可看作聚类假设的**推广**，但流形假设对输出值没有限制（**不一定是类别**），因此比聚类假设的适用范围更广，可用于更多类型的学习任务
- 事实上，无论聚类假设还是流形假设，其本质都是“**相似的样本拥有相似的输出**”这个基本假设



半监督学习类型



武汉大学
WUHAN UNIVERSITY

- 半监督学习可进一步划分为**纯** (pure) **半监督学习**和**直推学习** (transductive learning)
- 纯半监督学习假定训练数据中的未标记样本并非待预测的数据，而直推学习则假定学习过程中所考虑的未标记样本恰是待预测数据，学习的目的就是在这些未标记样本上获得最优泛化性能
- 换言之，纯半监督学习是基于**开放世界**假设，希望学得模型能适用于训练过程中**未观察到的**数据；而直推学习是基于**封闭世界**假设，仅试图对学习过程中**观察到的**未标记数据进行预测



02

生成式方法



- **生成式方法** (generative methods) 是直接基于生成式模型的方法，此类方法假设所有数据（无论是否有标记）都是由**同一个潜在的模型**生成的
- 这个假设使得我们能通过潜在模型的参数将未标记数据与学习目标联系起来，而未标记数据的标记则可看作模型的**缺失参数**，通常可基于**EM算法**进行极大似然估计求解，此类方法的区别主要在于**生成式模型的假设**，不同的模型假设将产生不同的方法



- 给定样本 $\mathbf{x}$ ，其真实类别标记为 $y \in \mathcal{Y}$ ，其中 $\mathcal{Y} = \{1, 2, \dots, N\}$ 为所有可能的类别。假设样本由高斯混合模型生成，且每个类别对应一个高斯混合成分，换言之，数据样本是基于如下概率密度生成

$$p(\mathbf{x}) = \sum_{i=1}^N \alpha_i \cdot p(\mathbf{x} | \boldsymbol{\mu}_i, \Sigma_i)$$

- 其中，混合系数 $\alpha_i \geq 0$ ， $\sum_{i=1}^N \alpha_i = 1$ ； $p(\mathbf{x} | \boldsymbol{\mu}_i, \Sigma_i)$ 是样本 $\mathbf{x}$ 属于第 i 个高斯混合成分的概率； $\boldsymbol{\mu}_i$ 和 Σ_i 为该高斯混合成分的参数



- 令 $f(x) \in \mathcal{Y}$ 表示模型 f 对 x 的**预测标记**, $\Theta \in \{1, 2, \dots, N\}$ 表示样本 x **隶属的高斯混合成分**, 由**最大化后验概率**可知

$$\begin{aligned} f(x) &= \arg \max_{j \in \mathcal{Y}} p(y = j | x) \\ &= \arg \max_{j \in \mathcal{Y}} \sum_{i=1}^N p(y = j, \Theta = i | x) && \text{式 (13.2)} \\ &= \arg \max_{j \in \mathcal{Y}} \sum_{i=1}^N p(y = j | \Theta = i, x) \cdot p(\Theta = i | x) \end{aligned}$$

- 其中
$$p(\Theta = i | x) = \frac{\alpha_i \cdot p(x | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(x | \mu_i, \Sigma_i)}$$

为样本 x 由第 i 个高斯混合成分生成的**后验概率**



- 由于**假设每个类别对应一个高斯混合成分**，因此 $p(y = j | \Theta = i, \mathbf{x})$ **仅与样本 $\mathbf{x}$ 所属的高斯混合成分 Θ 有关**，可用 $p(y = j | \Theta = i)$ 代替。不失一般性，假定第 i 个类别对应于第 i 个高斯混合成分，即 $p(y = j | \Theta = i) = 1$ **当且仅当 $i = j$** 否则 $p(y = j | \Theta = i) = 0$
- 不难发现，式 (13.2) 中估计 $p(y = j | \Theta = i, \mathbf{x})$ **需知道样本的标记**，因此仅能使用有标记数据；而 $p(\Theta = i | \mathbf{x})$ **不涉及样本标记**，因此有标记和未标记数据均可利用，通过引入大量的未标记数据，对这一项的估计可望由于数据量的增长而更为准确，于是式 (13.2) 整体的估计可能会**更准确**



- 给定有标记样本集 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$ 和 未标记样本集 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$, $l \ll u$, $l + u = m$, 假设所有样本**独立同分布**, 且都是由同一个高斯混合模型生成的
- 用极大似然法来估计高斯混合模型的参数

$$\{(\alpha_i, \boldsymbol{\mu}_i, \Sigma_i) \mid 1 \leq i \leq N\}, D_l \cup D_u$$

的对数似然是

$$\begin{aligned} LL(D_l \cup D_u) = & \sum_{(\mathbf{x}_j, y_j) \in D_l} \ln \left(\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j \mid \boldsymbol{\mu}_i, \Sigma_i) \cdot p(y_j \mid \Theta = i, \mathbf{x}_j) \right) \\ & + \sum_{\mathbf{x}_j \in D_u} \ln \left(\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j \mid \boldsymbol{\mu}_i, \Sigma_i) \right) \end{aligned} \quad \text{式 (13.4)}$$



- 式 (13.4) 由两项组成：基于有标记数据 D_l 的有监督项和基于未标记数据 D_u 的无监督项。显然，高斯混合模型参数估计可用EM算法求解，迭代更新式如下的E步和M步
- E步：根据当前模型参数计算未标记样本 x_j 属于各高斯混合成分的概率

$$\gamma_{ji} = \frac{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \Sigma_i)}$$



- **M步**：基于 γ_{ij} 更新模型参数 ， 其中 l_i 表示第 i 类的有标记样本数目

$$\begin{aligned}\mu_i &= \frac{1}{\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} \mathbf{x}_j + \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \mathbf{x}_j \right) \\ \Sigma_i &= \frac{1}{\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} (\mathbf{x}_j - \mu_i) (\mathbf{x}_j - \mu_i)^T \right. \\ &\quad \left. + \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} (\mathbf{x}_j - \mu_i) (\mathbf{x}_j - \mu_i)^T \right) \\ \alpha_i &= \frac{1}{m} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i \right)\end{aligned}$$



- 将上述过程中的高斯混合模型换成混合专家模型、朴素贝叶斯模型等即可推导出其他的生成式半监督学习方法。此类方法简单，易于实现，在有标记数据极少的情形下往往比其他方法性能更好
- 然而，此类方法有一个关键：模型假设必须准确，即假设的生成式模型必须与真实数据分布吻合，否则利用未标记数据反倒会降低泛化性能。遗憾的是，在现实任务中往往很难事先做出准确的模型假设，除非拥有充分可靠的领域知识
- 求得模型参数后，则可通过式 (13.2) 对样本进行分类



03


半监督SVM



半监督SVM



武汉大学
WUHAN UNIVERSITY





- 半监督支持向量机中最著名的是**TSVM** (Transductive Support Vector Machine) 与标准SVM一样, TSVM也是针对**二分类**问题的学习方法
- TSVM试图考虑对未标记样本进行各种可能的**标记指派** (label assignment), 即尝试将每个未标记样本分别作为**正例或反例**, 然后在所有这些结果中, 寻求一个在所有样本 (包括有标记样本和进行了标记指派的未标记样本) 上**间隔最大化**的划分超平面, 一旦划分超平面得以确定, 未标记样本的**最终标记指派**就是其预测结果



- 形式化地说, 给定 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$ 和 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$, 其中 $y_i \in \{-1, +1\}$, $l \ll u$, $l + u = m$ 。TSVM的学习目标是为 D_u 中的样本给出预测标记 $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$, $\hat{y}_i \in \{-1, +1\}$, 使得

$$\min_{\mathbf{w}, b, \hat{\mathbf{y}}, \boldsymbol{\xi}} \frac{1}{2} \|\mathbf{w}\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i$$

$$\text{s.t. } y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, l,$$

$$\hat{y}_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = l+1, l+2, \dots, m,$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, m$$


式 (13.9)



- 其中, (w, b) 确定了一个划分超平面; ξ 为松弛向量, $\xi_i (i=1, 2, \dots, l)$ 对应于有标记样本, $\xi_i (i=l+1, l+2, \dots, m)$ 对应于未标记样本; C_l 与 C_u 是由用户指定的用于平衡模型复杂度、有标记样本与未标记样本重要程度的折中参数
- 显然, 尝试未标记样本的各种标记指派是一个穷举过程, 仅当未标记样本很少时才有可能直接求解, 在一般情形下, 必须考虑更高效的优化策略



- TSVM采用局部搜索来迭代地寻找近似解





- 在对未标记样本进行标记指派及调整的过程中，有可能出现**类别不平衡**问题，即某类的样本远多于另一类，这将对SVM的训练造成困扰
- 为了**减轻类别不平衡性所造成的不利影响**，可对算法稍加改进：将优化目标中的 C_u 项拆分为 C_u^+ 与 C_u^- 两项，分别对应基于伪标记而当作正、反例使用的未标记样本，并在初始化时令 $C_u^+ = \frac{u_-}{u_+} C_u^-$
- 其中 u_+ 与 u_- 为基于伪标记而当作正、反例使用的未标记样本数



● TSVM算法

输入: 有标记样本集 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$;

未标记样本集 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$;

折中参数 C_l, C_u .

过程:

1: 用 D_l 训练一个 SVM_l ;

2: 用 SVM_l 对 D_u 中样本进行预测, 得到 $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$;

3: 初始化 $C_u \ll C_l$;

4: **while** $C_u < C_l$ **do**

5: 基于 $D_l, D_u, \hat{\mathbf{y}}, C_l, C_u$ 求解式(13.9), 得到 $(\mathbf{w}, b), \xi$;

6: **while** $\exists \{i, j \mid (\hat{y}_i \hat{y}_j < 0) \wedge (\xi_i > 0) \wedge (\xi_j > 0) \wedge (\xi_i + \xi_j > 2)\}$ **do**

7: $\hat{y}_i = -\hat{y}_i$;

8: $\hat{y}_j = -\hat{y}_j$;

9: 基于 $D_l, D_u, \hat{\mathbf{y}}, C_l, C_u$ 重新求解式(13.9), 得到 $(\mathbf{w}, b), \xi$

10: **end while**

11: $C_u = \min\{2C_u, C_l\}$

12: **end while**

输出: 未标记样本的预测结果: $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$



- 在图中算法的第6-10行中，若存在一对未标记样本 x_i 与 x_j ，其标记指派 $\hat{y}_i$ 与 $\hat{y}_j$ 不同，且对应的松弛变量满足 $\xi_i + \xi_j > 2$ ，则意味着 $\hat{y}_i$ 与 $\hat{y}_j$ 很可能是错误的，需对二者进行交换后重新求解式 (13.9)，这样每轮迭代后均可使式 (13.9) 的目标函数值**下降**
- 显然，**搜寻标记指派可能出错的每一对未标记样本进行调整**，是一个涉及巨大计算开销的大规模优化问题，因此，**半监督SVM研究的一个重点是如何设计出高效的优化求解策略**



04

图半监督学习



- 给定一个数据集，我们可将其映射为一个**图**，数据集中每个样本对应于图中一个结点，若两个样本之间的**相似度很高**（或相关性很强），则对应的结点之间存在一条**边**，边的**强度**（strength）正比于样本之间的**相似度**（或相关性）
- 可将有标记样本所对应的结点想象为**染过色**，而未标记样本所对应的结点则**尚未染色**。于是，**半监督学习就对应于颜色在图上扩散或传播的过程**
- 由于一个图对应了一个**矩阵**，这就使得我们能基于矩阵运算来进行半监督学习算法的推导与分析



- 给定 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$ 和 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$
 $l \ll u, l + u = m$, 先基于 $D_l \cup D_u$ 构建一个图 $G = (V, E)$,
其中结点集 $V = \{\mathbf{x}_1, \dots, \mathbf{x}_l, \mathbf{x}_{l+1}, \dots, \mathbf{x}_{l+u}\}$, 边集 E 可表示为一个亲和矩阵 (affinity matrix), 常基于高斯函数定义为

$$(\mathbf{W})_{ij} = \begin{cases} \exp\left(\frac{-|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma^2}\right), & \text{if } i \neq j; \\ 0, & \text{otherwise} \end{cases} \quad \text{式 (13.11)}$$

- 其中 $i, j \in \{1, 2, \dots, m\}$, $\sigma > 0$ 是用户指定的高斯函数带宽参数



- 假定从图 $G = (V, E)$ 将学得一个实值函数 $f : V \rightarrow \mathbb{R}$ ，其对应的分类规则为 $y_i = \text{sign}(f(\mathbf{x}_i))$, $y_i \in \{-1, +1\}$
- 直观上看，相似的样本应具有相似的标记，可定义关于 f 的能量函数 (energy function) (能量最小即最优)

$$\begin{aligned} E(f) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} (f(\mathbf{x}_i) - f(\mathbf{x}_j))^2 \\ &= \frac{1}{2} \left(\sum_{i=1}^m d_i f^2(\mathbf{x}_i) + \sum_{j=1}^m d_j f^2(\mathbf{x}_j) - 2 \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} f(\mathbf{x}_i) f(\mathbf{x}_j) \right) \\ &= \sum_{i=1}^m d_i f^2(\mathbf{x}_i) - \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} f(\mathbf{x}_i) f(\mathbf{x}_j) \\ &= \mathbf{f}^T (\mathbf{D} - \mathbf{W}) \mathbf{f} \end{aligned} \quad \text{式 (13.12)}$$



- 其中 $\mathbf{f} = (\mathbf{f}_l^T \mathbf{f}_u^T)^T$, $\mathbf{f}_l = (f(\mathbf{x}_1); f(\mathbf{x}_2); \dots; f(\mathbf{x}_l))$, $\mathbf{f}_u = (f(\mathbf{x}_{l+1}); f(\mathbf{x}_{l+2}); \dots; f(\mathbf{x}_{l+u}))$ 分别为函数 f 在有标记样本与未标记样本上的预测结果, $\mathbf{D} = \text{diag}(d_1, d_2, \dots, d_{l+u})$ 是一个对角矩阵, 其对角元素 $d_i = \sum_{j=1}^{l+u} (\mathbf{W})_{ij}$ 为矩阵 $\mathbf{W}$ 的第 i 行元素之和
- 具有最小能量的函数 f 在有标记样本上满足 $f(\mathbf{x}_i) = y_i$ ($i = 1, 2, \dots, l$), 在未标记样本上满足 $\Delta \mathbf{f} = 0$, 其中 $\Delta = \mathbf{D} - \mathbf{W}$ 为拉普拉斯矩阵 (Laplacian matrix)。以第 l 行与第 l 列为界, 采用分块矩阵表示方式

$$\mathbf{W} = \begin{bmatrix} \mathbf{W}_{ll} & \mathbf{W}_{lu} \\ \mathbf{W}_{ul} & \mathbf{W}_{uu} \end{bmatrix} \quad \mathbf{D} = \begin{bmatrix} \mathbf{D}_{ll} & \mathbf{0}_{lu} \\ \mathbf{0}_{ul} & \mathbf{D}_{uu} \end{bmatrix}$$



- 式 (13.12) 可重写为

$$\begin{aligned} E(f) &= (\mathbf{f}_l^T \mathbf{f}_u^T) \left(\begin{bmatrix} \mathbf{D}_{ll} & \mathbf{0}_{lu} \\ \mathbf{0}_{ul} & \mathbf{D}_{uu} \end{bmatrix} - \begin{bmatrix} \mathbf{W}_{ll} & \mathbf{W}_{lu} \\ \mathbf{W}_{ul} & \mathbf{W}_{uu} \end{bmatrix} \right) \begin{bmatrix} \mathbf{f}_l \\ \mathbf{f}_u \end{bmatrix} \\ &= \mathbf{f}_l^T (\mathbf{D}_{ll} - \mathbf{W}_{ll}) \mathbf{f}_l - 2\mathbf{f}_u^T \mathbf{W}_{ul} \mathbf{f}_l + \mathbf{f}_u^T (\mathbf{D}_{uu} - \mathbf{W}_{uu}) \mathbf{f}_u \end{aligned}$$

- 由 $\frac{\partial E(f)}{\partial \mathbf{f}_u} = \mathbf{0}$ 可得 $\mathbf{f}_u = (\mathbf{D}_{uu} - \mathbf{W}_{uu})^{-1} \mathbf{W}_{ul} \mathbf{f}_l$ 式 (13.15)

- 令 $\mathbf{P} = \mathbf{D}^{-1} \mathbf{W} = \begin{bmatrix} \mathbf{D}_{ll}^{-1} & \mathbf{0}_{lu} \\ \mathbf{0}_{ul} & \mathbf{D}_{uu}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{W}_{ll} & \mathbf{W}_{lu} \\ \mathbf{W}_{ul} & \mathbf{W}_{uu} \end{bmatrix}$
$$= \begin{bmatrix} \mathbf{D}_{ll}^{-1} \mathbf{W}_{ll} & \mathbf{D}_{ll}^{-1} \mathbf{W}_{lu} \\ \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul} & \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu} \end{bmatrix}$$

即 $\mathbf{P}_{uu} = \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu}$, $\mathbf{P}_{ul} = \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul}$



- 式 (13.15) 可重写为

$$\begin{aligned} f_u &= (\mathbf{D}_{uu} (\mathbf{I} - \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu}))^{-1} \mathbf{W}_{ul} \mathbf{f}_l \\ &= (\mathbf{I} - \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu})^{-1} \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul} \mathbf{f}_l \\ &= (\mathbf{I} - \mathbf{P}_{uu})^{-1} \mathbf{P}_{ul} \mathbf{f}_l \end{aligned}$$

- 于是，将 D_l 上的标记信息作为 $\mathbf{f}_l = (y_1; y_2; \dots; y_l)$ 代入上式，即可利用求得的 $\mathbf{f}_u$ 对未标记样本进行预测
- 上面描述的是一个针对二分类问题的标记传播 (label propagation) 方法，下面来看一个适用于多分类问题的标记传播方法



- 假定 $y_i \in \mathcal{Y}$, 仍基于 $D_l \cup D_u$ 构建一个图 $G = (V, E)$, 其中结点集 $V = \{\mathbf{x}_1, \dots, \mathbf{x}_l, \dots, \mathbf{x}_{l+u}\}$, 边集所对应的 $\mathbf{W}$ 仍使用式 (13.11), 对角矩阵 $\mathbf{D} = \text{diag}(d_1, d_2, \dots, d_{l+u})$ 的对角元素
$$d_i = \sum_{j=1}^{l+u} (\mathbf{W})_{ij}$$
- 定义一个 $(l+u) \times |\mathcal{Y}|$ 的非负标记矩阵 $\mathbf{F} = (\mathbf{F}_1^T, \mathbf{F}_2^T, \dots, \mathbf{F}_{l+u}^T)^T$ 其第 i 行元素 $\mathbf{F}_i = ((\mathbf{F})_{i1}, (\mathbf{F})_{i2}, \dots, (\mathbf{F})_{i|\mathcal{Y}|})$ 为**示例** $\mathbf{x}_i$ 的标记向量, 相应的**分类规则**为 $y_i = \arg \max_{1 \leq j \leq |\mathcal{Y}|} (\mathbf{F})_{ij}$



- 对 $i = 1, 2, \dots, m, j = 1, 2, \dots, |\mathcal{Y}|$, 将 $\mathbf{F}$ 初始化为

$$\mathbf{F}(0) = (\mathbf{Y})_{ij} = \begin{cases} 1, & \text{if } (1 \leq i \leq l) \wedge (y_i = j); \\ 0, & \text{otherwise} \end{cases}$$

显然, $\mathbf{Y}$ 的前 l 行就是有 l 个有标记样本的标记向量

- 基于 $\mathbf{W}$ 构造一个标记传播矩阵 $\mathbf{S} = \mathbf{D}^{-\frac{1}{2}} \mathbf{W} \mathbf{D}^{-\frac{1}{2}}$, 其中

$$\mathbf{D}^{-\frac{1}{2}} = \text{diag}\left(\frac{1}{\sqrt{d_1}}, \frac{1}{\sqrt{d_2}}, \dots, \frac{1}{\sqrt{d_{l+u}}}\right) \quad \text{于是迭代计算式为}$$

$$\mathbf{F}(t+1) = \alpha \mathbf{S} \mathbf{F}(t) + (1-\alpha) \mathbf{Y} \quad \text{式 (13.19)}$$



- 其中 $\alpha \in (0, 1)$ 为用户指定的参数，用于对标记传播项 $\mathbf{SF}(t)$ 与初始化项 $\mathbf{Y}$ 的重要性进行折中，基于式 (13.19) 迭代至收敛可得

$$\mathbf{F}^* = \lim_{t \rightarrow \infty} \mathbf{F}(t) = (1 - \alpha) (\mathbf{I} - \alpha \mathbf{S})^{-1} \mathbf{Y}$$

- 由 $\mathbf{F}^*$ 可获得 D_u 中样本的标记 $(\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$
- 算法描述如下页图所示



● 迭代式标记传播算法

输入: 有标记样本集 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$;
未标记样本集 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$;
构图参数 σ ;
折中参数 α .

过程:

- 1: 基于式(13.11)和参数 σ 得到 $\mathbf{W}$;
- 2: 基于 $\mathbf{W}$ 构造标记传播矩阵 $\mathbf{S} = \mathbf{D}^{-\frac{1}{2}} \mathbf{W} \mathbf{D}^{-\frac{1}{2}}$;
- 3: 根据式(13.18)初始化 $\mathbf{F}(0)$;
- 4: $t = 0$;
- 5: **repeat**
- 6: $\mathbf{F}(t+1) = \alpha \mathbf{S} \mathbf{F}(t) + (1 - \alpha) \mathbf{Y}$;
- 7: $t = t + 1$
- 8: **until** 迭代收敛至 $\mathbf{F}^*$
- 9: **for** $i = l+1, l+2, \dots, l+u$ **do**
- 10: $y_i = \arg \max_{1 \leq j \leq |\mathcal{Y}|} (\mathbf{F}^*)_{ij}$
- 11: **end for**

输出: 未标记样本的预测结果: $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$



- 事实上，上页图中的算法对应于正则化框架

$$\min_{\mathbf{F}} \frac{1}{2} \left(\sum_{i,j=1}^{l+u} (\mathbf{W})_{ij} \left\| \frac{1}{\sqrt{d_i}} \mathbf{F}_i - \frac{1}{\sqrt{d_j}} \mathbf{F}_j \right\|^2 \right) + \mu \sum_{i=1}^l |\mathbf{F}_i - \mathbf{Y}_i|^2$$

- 其中 $\mu > 0$ 为正则化参数，当 $\mu = \frac{1-\alpha}{\alpha}$ 时，上式的最优解恰为上页图算法的迭代收敛解 $\mathbf{F}^*$



- 图半监督学习方法在**概念上相当清晰**，且易于通过对所涉矩阵运算的分析来探索算法性质，但此类算法的缺陷也相当明显
 - 首先是在**存储开销**上，若样本数为 $O(m)$ ，则算法中所涉及的矩阵规模为 $O(m^2)$ ，这使得此类算法**很难直接处理大规模数据**
 - 另一方面，由于构图过程仅能考虑训练样本集，难以判知新样本在图中的位置，因此，在**接收到新样本**时，或是将其加入原数据集对图进行重构**并重新进行标记传播**，或是需**引入额外的预测机制**



05

基于分歧的方法



- **基于分歧的方法** (disagreement-based methods) 使用**多学习器**，而学习器之间的**分歧** (disagreement) 对未标记数据的利用至关重要
- **协同训练** (co-training) 是基于分歧的方法的**重要代表**，它最初是针对**多视图** (multi-view) 数据设计的，因此也被看作**多视图学习** (multi-view learning) 的代表



基于分歧的方法



武汉大学
WUHAN UNIVERSITY

- 在不少现实应用中，一个数据对象往往同时拥有多个属性集（attribute set），每个属性集就构成了一个视图（view）。例如对一部电影来说，它拥有多个属性集：图像画面信息对应的属性集、声音信息对应的属性集、字幕信息对应的属性集、网上的宣传讨论所对应的属性集等
- 每个属性集都可看作一个视图，一个电影片段表示为样本 $(\langle \mathbf{x}^1, \mathbf{x}^2 \rangle, y)$ ，其中 $\mathbf{x}^i$ 是样本在视图 i 中的示例，即基于该视图属性描述而得的属性向量，不妨假定 $\mathbf{x}^1$ 为图像视图中的属性向量， $\mathbf{x}^2$ 为声音视图中的属性向量； y 是标记，假定是电影的类型，例如“动作片”、“爱情片”， $(\langle \mathbf{x}^1, \mathbf{x}^2 \rangle, y)$ 这样的数据就是多视图数据



● 协同训练算法

输入: 有标记样本集 $D_l = \{(\langle x_1^1, x_1^2 \rangle, y_1), \dots, (\langle x_l^1, x_l^2 \rangle, y_l)\}$;

未标记样本集 $D_u = \{\langle x_{l+1}^1, x_{l+1}^2 \rangle, \dots, \langle x_{l+u}^1, x_{l+u}^2 \rangle\}$;

缓冲池大小 s ;

每轮挑选的正例数 p ;

每轮挑选的反例数 n ;

基学习算法 $\mathcal{L}$;

学习轮数 T .

过程:

1: 从 D_u 中随机抽取 s 个样本构成缓冲池 D_s ;

2: $D_u = D_u \setminus D_s$;

3: **for** $j = 1, 2$ **do**

4: $D_l^j = \{(\langle x_i^j, y_i \rangle) \mid (\langle x_i^j, x_i^{3-j} \rangle, y_i) \in D_l\}$;

5: **end for**

6: **for** $t = 1, 2, \dots, T$ **do**

7: **for** $j = 1, 2$ **do**

8: $h_j \leftarrow \mathcal{L}(D_l^j)$;

9: 考察 h_j 在 $D_s^j = \{\langle x_i^j, x_i^{3-j} \rangle \mid \langle x_i^j, x_i^{3-j} \rangle \in D_s\}$ 上的分类置信度, 挑选 p 个正例置信度最高的样本 $D_p \subset D_s$ 、 n 个反例置信度最高的样本 $D_n \subset D_s$;

10: 由 D_p^j 生成伪标记正例 $\tilde{D}_p^{3-j} = \{(\langle x_i^{3-j}, +1 \rangle) \mid x_i^j \in D_p^j\}$;

11: 由 D_n^j 生成伪标记反例 $\tilde{D}_n^{3-j} = \{(\langle x_i^{3-j}, -1 \rangle) \mid x_i^j \in D_n^j\}$;

12: $D_s = D_s \setminus (D_p \cup D_n)$;

13: **end for**

14: **if** h_1, h_2 均未发生改变 **then**

15: **break**

16: **else**

17: **for** $j = 1, 2$ **do**

18: $D_l^j = D_l^j \cup (\tilde{D}_p^j \cup \tilde{D}_n^j)$;

19: **end for**

20: 从 D_u 中随机抽取 $2p + 2n$ 个样本加入 D_s .

21: **end if**

22: **end for**

输出: 分类器 h_1, h_2



- 协同训练过程虽简单，但令人惊讶的是，理论证明显示出，若两个视图充分且条件独立，则可利用未标记样本通过协同训练将弱分类器的泛化性能提升到任意高
- 不过，视图的条件独立性在现实任务中通常很难满足，因此性能提升幅度不会那么大，但研究表明，即使在更弱的条件下，**协同训练**仍可有效地提升弱分类器的性能



- 协同训练算法本身是为多视图数据而设计的，但此后出现了一些能在**单视图数据**上使用的变体算法，它们或使用不同的**学习算法**、或使用不同的数据**采样**、甚至使用不同的**参数设置**来产生不同的学习器，也能有效地利用未标记数据来提升性能
- 后续理论研究发现，此类算法事实上**无需数据拥有多视图**，仅需弱学习器之间具有显著的**分歧**（或差异），即可通过**相互提供伪标记样本**的方式来**提高泛化性能**



- 基于分歧的方法只需采用**合适的基学习器**，就较少受到模型假设、损失函数非凸性和数据规模问题的影响，学习方法简单有效、理论基础相对坚实、适用范围较为广泛
- 为了使用此类方法，**需能生成具有显著分歧、性能尚可的多个学习器**，但当有标记样本很少、尤其是数据不具有多视图时，要做到这一点并不容易



06

半监督聚类



- **聚类**是一种典型的无监督学习任务，然而在现实聚类任务中我们往往能获得一些额外的监督信息，于是可通过**半监督聚类**（semi-supervised clustering）来利用监督信息以获得更好的聚类效果
- 聚类任务中获得的监督信息大致有**两种类型**
 - 第一种类型是**必连**（must-link）与**勿连**（cannot-link）约束，前者是指样本必属于同一个簇，后者则是指样本必不属于同一个簇
 - 第二种类型的监督信息则是**少量的有标记样本**



- 约束 k 均值 (Constrained k-means) 算法是利用第一类监督信息的代表
- 该算法是 k 均值算法的扩展, 给定样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$ 以及 “必连” 关系集合 $\mathcal{M}$ 和 “勿连” 关系集合 $\mathcal{C}$, $(\mathbf{x}_i, \mathbf{x}_j) \in \mathcal{M}$ 表示 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 必属于同簇, $(\mathbf{x}_i, \mathbf{x}_j) \in \mathcal{C}$ 表示 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 必不属于同簇。该算法是 k 均值算法的扩展, 它在聚类过程中要确保 $\mathcal{M}$ 与 $\mathcal{C}$ 中的约束得以满足, 否则将返回错误提示, 算法如下页图



● 约束 k 均值算法

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
必连约束集合 $\mathcal{M}$;
勿连约束集合 $\mathcal{C}$;
聚类簇数 k .

过程:

- 1: 从 D 中随机选取 k 个样本作为初始均值向量 $\{\mu_1, \mu_2, \dots, \mu_k\}$;
- 2: **repeat**
- 3: $C_j = \emptyset$ ($1 \leq j \leq k$);
- 4: **for** $i = 1, 2, \dots, m$ **do**
- 5: 计算样本 x_i 与各均值向量 μ_j ($1 \leq j \leq k$) 的距离: $d_{ij} = \|x_i - \mu_j\|_2$;
- 6: $\mathcal{K} = \{1, 2, \dots, k\}$;
- 7: **is_merged** = false;
- 8: **while** $\neg$ **is_merged** **do**
- 9: 基于 $\mathcal{K}$ 找出与样本 x_i 距离最近的簇: $r = \arg \min_{j \in \mathcal{K}} d_{ij}$;
- 10: 检测将 x_i 划入聚类簇 C_r 是否会违背 $\mathcal{M}$ 与 $\mathcal{C}$ 中的约束;
- 11: **if** $\neg$ **is_violated** **then**
- 12: $C_r = C_r \cup \{x_i\}$;
- 13: **is_merged** = true
- 14: **else**
- 15: $\mathcal{K} = \mathcal{K} \setminus \{r\}$;
- 16: **if** $\mathcal{K} = \emptyset$ **then**
- 17: **break**并返回错误提示
- 18: **end if**
- 19: **end if**
- 20: **end while**
- 21: **end for**
- 22: **for** $j = 1, 2, \dots, k$ **do**
- 23: $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$;
- 24: **end for**
- 25: **until** 均值向量均未更新

输出: 簇划分 $\{C_1, C_2, \dots, C_k\}$



● 以西瓜数据集4.0为例

编号	密度	含糖率	编号	密度	含糖率	编号	密度	含糖率
1	0.697	0.460	11	0.245	0.057	21	0.748	0.232
2	0.774	0.376	12	0.343	0.099	22	0.714	0.346
3	0.634	0.264	13	0.639	0.161	23	0.483	0.312
4	0.608	0.318	14	0.657	0.198	24	0.478	0.437
5	0.556	0.215	15	0.360	0.370	25	0.525	0.369
6	0.403	0.237	16	0.593	0.042	26	0.751	0.489
7	0.481	0.149	17	0.719	0.103	27	0.532	0.472
8	0.437	0.211	18	0.359	0.188	28	0.473	0.376
9	0.666	0.091	19	0.339	0.241	29	0.725	0.445
10	0.243	0.267	20	0.282	0.257	30	0.446	0.459



- 令样本 x_4 与 x_{25} , x_{12} 与 x_{20} , x_{14} 与 x_{17} 之间存在必连约束, x_2 与 x_{21} , x_{13} 与 x_{23} , x_{19} 与 x_{23} 之间存在勿连约束, 即

$$\mathcal{M} = \{(x_4, x_{25}), (x_{25}, x_4), (x_{12}, x_{20}), (x_{20}, x_{12}), (x_{14}, x_{17}), (x_{17}, x_{14})\}$$

$$\mathcal{C} = \{(x_2, x_{21}), (x_{21}, x_2), (x_{13}, x_{23}), (x_{23}, x_{13}), (x_{19}, x_{23}), (x_{23}, x_{19})\}$$

- 设聚类簇数 $k = 3$, 随机选取样本 x_6, x_{12}, x_{27} 作为初始均值向量, 下页图显示出约束 k 均值算法在不同迭代轮数后的聚类结果。经5轮迭代后均值向量不再发生变化 (与第4轮迭代相同), 于是得到最终聚类结果


$$C_1 = \{x_3, x_5, x_7, x_9, x_{13}, x_{14}, x_{16}, x_{17}, x_{21}\};$$

$$C_2 = \{x_6, x_8, x_{10}, x_{11}, x_{12}, x_{15}, x_{18}, x_{19}, x_{20}\};$$


$$C_3 = \{x_1, x_2, x_4, x_{22}, x_{23}, x_{24}, x_{25}, x_{26}, x_{27}, x_{28}, x_{29}, x_{30}\}$$




● 实验结果




(a) 第 1 轮迭代后



(b) 第 2 轮迭代后



(c) 第 3 轮迭代后



(d) 第 4 轮迭代后



- 第二种监督信息是**少量有标记样本**，即假设少量有标记样本属于 k 个聚类簇（**是指簇标记，不是指类别标记**）
- 这样的监督信息利用起来很容易：直接将它们作为**种子**，用它们**初始化 k 均值算法的 k 个聚类中心**，并且在聚类簇迭代更新过程中**不改变种子样本的簇隶属关系**，这样就得到了**约束种子 k 均值**（Constrained Seed k-means）算法



● 约束种子 k 均值算法

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
少量有标记样本 $S = \bigcup_{j=1}^k S_j$;
聚类簇数 k .


过程:

- 1: **for** $j = 1, 2, \dots, k$ **do**
- 2: $\mu_j = \frac{1}{|S_j|} \sum_{\mathbf{x} \in S_j} \mathbf{x}$
- 3: **end for**
- 4: **repeat**
- 5: $C_j = \emptyset$ ($1 \leq j \leq k$);
- 6: **for** $j = 1, 2, \dots, k$ **do**
- 7: **for all** $\mathbf{x} \in S_j$ **do**
- 8: $C_j = C_j \cup \{\mathbf{x}\}$
- 9: **end for**
- 10: **end for**
- 11: **for all** $\mathbf{x}_i \in D \setminus S$ **do**
- 12: 计算样本 $\mathbf{x}_i$ 与各均值向量 μ_j ($1 \leq j \leq k$) 的距离: $d_{ij} = \|\mathbf{x}_i - \mu_j\|_2$;
- 13: 找出与样本 $\mathbf{x}_i$ 距离最近的簇: $r = \arg \min_{j \in \{1, 2, \dots, k\}} d_{ij}$;
- 14: 将样本 $\mathbf{x}_i$ 划入相应的簇: $C_r = C_r \cup \{\mathbf{x}_i\}$
- 15: **end for**
- 16: **for** $j = 1, 2, \dots, k$ **do**
- 17: $\mu_j = \frac{1}{|C_j|} \sum_{\mathbf{x} \in C_j} \mathbf{x}$;
- 18: **end for**
- 19: **until** 均值向量均未更新


输出: 簇划分 $\{C_1, C_2, \dots, C_k\}$




● 实验结果




(a) 第 1 轮迭代后



(b) 第 2 轮迭代后



(c) 第 3 轮迭代后



(d) 第 4 轮迭代后



武汉大学
WUHAN UNIVERSITY

谢谢

自强弘毅 求是拓新

课后阅读西瓜书第13章