



武汉大学

WUHAN UNIVERSITY

第十二讲：强化学习



武汉大学
WUHAN UNIVERSITY

01 强化学习问题基本设置

02 K -摇臂赌博机

03 有模型学习

04 免模型学习

05 值函数近似

06 模仿学习



07 基于人类反馈的强化学习



武汉大学
WUHAN UNIVERSITY


01 强化学习问题基本设置

Basic Settings of Reinforcement Learning Problems





Richard S. Sutton



Current Projects




Reinforcement Learning

A large part of the lab's research focus is on developing new reinforcement learning algorithms with particular focus on cyber-physical systems and scaling up to large-scale applications.

Representative Publication:

TEXPLORE: Real-Time Sample-Efficient Reinforcement Learning for Robots (*Machine Learning*, 2013).

[Full List of Relevant Publications]



Multiagent Systems

One main theme of the lab is the study of interactions among independent autonomous agents (including robots), be they teammates, adversaries, or neither. Some of our research on this topic contributes to and makes use of game theory.

Representative Publication:

Multiagent Systems: A survey from a machine learning perspective (*Autonomous Robots*, 2000).

[Full List of Relevant Publications]



Robot Soccer

One of the main application domains is robot soccer, both in simulation and on real-world platforms, including the RoboCup championships.

Representative Publication:

Reinforcement Learning for Behavior, 2005).

[Full List of Relevant Publications]

[Project Page]

[Watch Video]




Peter Stone



- 例子：瓜农种西瓜


种下瓜苗后：（为简便，仅考虑浇水和不浇水两个动作，不考虑施肥、除草、杀虫等）





- 例子：瓜农种西瓜
 - 多步决策过程
 - 当前操作仅能得到某种反馈，很难判断对于最终结果的影响
 - 过程中包含状态、动作、反馈 (奖赏) 等
 - 需多次种瓜，在过程中不断摸索，才能总结出较好的种瓜策略


种下瓜苗后：(为简便，仅考虑浇水和不浇水两个动作，不考虑施肥、除草等)





- 例子：瓜农种西瓜
 - 多步决策过程
 - 当前操作仅能得到某种反馈，很难判断对于最终结果的影响
 - 过程中包含状态、动作、反馈 (奖赏) 等
 - 需多次种瓜，在过程中不断摸索，才能总结出较好的种瓜策略

种下瓜苗后：(为简便，仅考虑浇水和不浇水两个动作，不考虑施肥、除草等)



抽象该过程：强化学习 (reinforcement learning)




- 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述



□ 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述


- 机器所处的环境 E
 - 例如在种西瓜任务中, 环境是西瓜生长的自然世界





□ 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述


- 机器所处的环境 E
 - 例如在种西瓜任务中, 环境是西瓜生长的自然世界
- 状态空间 $X : x \in X$ 是机器感知到的环境的描述
 - 瓜苗长势的描述






□ 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述

- 机器所处的环境 E
 - 例如在种西瓜任务中, 环境是西瓜生长的自然世界
- 状态空间 $X : x \in X$ 是机器感知到的环境的描述
 - 瓜苗长势的描述...
- 机器能采取的行为空间 A
 - 浇水, 施不同的肥、喷洒不同的农药等可供选择的动作




□ 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述

- 机器所处的环境 E
 - 例如在种西瓜任务中, 环境是西瓜生长的自然世界
- 状态空间 $X: x \in X$ 是机器感知到的环境的描述
 - 瓜苗长势的描述
- 机器能采取的行为空间 A
 - 浇水, 施不同的肥、喷洒不同的农药等可供选择的动作
- 策略(policy) $\pi: X \rightarrow A$ (或 $\pi: X \times A \rightarrow \mathbb{R}$ **随机性策略**)
 - 根据瓜苗状态是缺水时, 返回动作浇水




□ 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述

- 机器所处的环境 E
 - 例如在种西瓜任务中, 环境是西瓜生长的自然世界
- 状态空间 $X: x \in X$ 是机器感知到的环境的描述
 - 瓜苗长势的描述
- 机器能采取的行为空间 A
 - 浇水, 施不同的肥、喷洒不同的农药等可供选择的动作
- 策略(policy) $\pi: X \rightarrow A$ (或 $\pi: X \times A \rightarrow \mathbb{R}$ **随机性策略**)
 - 根据瓜苗状态是缺水时, 返回动作浇水
- 潜在的状态转移(概率)函数 $P: X \times A \times X \rightarrow \mathbb{R}$
 - 瓜苗当前状态缺水, 选择动作浇水, 有一定概率恢复健康, 也有一定概率无法恢复




□ 强化学习常用马尔可夫决策过程 (Markov Decision Process, MDP) 描述

- 机器所处的环境 E
 - 例如在种西瓜任务中, 环境是西瓜生长的自然世界
- 状态空间 $X : x \in X$ 是机器感知到的环境的描述
 - 瓜苗长势的描述
- 机器能采取的行为空间 A
 - 浇水, 施肥等
- 策略(policy) $\pi: X \rightarrow A$ (或 $\pi: X \times A \rightarrow \mathbb{R}$ **随机性策略**)
 - 根据瓜苗状态是缺水时, 返回动作浇水 (**通过在环境中不断尝试而习得**)
- 潜在的状态转移(概率)函数 $P: X \times A \times X \rightarrow \mathbb{R}$
 - 瓜苗当前状态缺水, 选择动作浇水, 有一定概率恢复健康, 也有一定概率无法恢复
- 潜在的奖赏(reward)函数 $R: X \times A \times X \rightarrow \mathbb{R}$ (或 $R: X \times X \rightarrow \mathbb{R}$ **只与状态转移有关**)
 - 瓜苗健康对应奖赏+1, 瓜苗凋零对应奖赏-10
- 机器通过执行动作**影响**环境, 通过观察转移后的状态和返回的奖赏**感知**环境, 但**状态转移和奖赏返回不受机器控制**



- 强化学习对应了四元组

$$E = \langle X, A, P, R \rangle$$



$$a = \pi(x)$$

$$\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$$

□ 强化学习对应了四元组

$$E = \langle X, A, P, R \rangle$$

□ 强化学习的目标

- 机器通过在环境中不断尝试从而
 学到一个策略 π , **要找到长期累积奖赏
 最大化大的策略**


$$T \text{ 步累积奖赏: } \mathbb{E}[\frac{1}{T} \sum_{t=1}^T r_t]$$

$$\gamma \text{ 折扣累积奖赏: } \mathbb{E}[\sum_{t=0}^{+\infty} \gamma^t r_{t+1}]$$

$$a = \pi(x)$$

$$\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$$


$$\text{最大化 } \mathbb{E}[\frac{1}{T} \sum_{t=1}^T r_t]$$






□ 强化学习 vs. 监督学习

- 监督学习：给定有标记样本




□ 强化学习 vs. 监督学习

- 监督学习：给有标记样本



- 强化学习：没有有标记样本，通过执行动作之后反馈的**奖励**来学习。



- 但是，一般不知道在什么状态下应该做什么动作，只有等到最终结果揭晓，才能通过**反思**之前的动作是否正确来进行学习（学习最优策略）。强化学习在某种意义上可以认为是具有“**延迟标记信息**”的监督学习




武汉大学
WUHAN UNIVERSITY

02 K-摇臂赌博机

K-armed Bandit


□ K-摇臂赌博机 (K-Armed Bandit)

- 只有一个虚拟状态（或者说没有状态），K个动作
- 只涉及一步决策，选择一个摇臂后立即获得奖励，不涉及状态转移
- 每个摇臂的奖赏服从某个期望未知的分布
- 执行有限次动作
- 最大化累积奖赏（期望意义下）



□ K-摇臂赌博机 (K-Armed Bandit)

- 只有一个虚拟状态（或者说没有状态），K个动作
- 只涉及**一步**决策，选择一个摇臂后立即获得奖励，不涉及状态转移
- 每个摇臂的奖赏服从某个期望未知的概率分布
- 执行有限次动作
- 最大化累积奖赏（期望意义下）




□ 强化学习面临的主要困难：探索-利用窘境 (Exploration-Exploitation dilemma)

- 探索：估计不同摇臂的优劣 (奖赏期望的大小)
- 利用：选择当前最优的摇臂 (奖赏期望最大)

□ K-摇臂赌博机 (K-Armed Bandit)

- 只有一个虚拟状态（或者说没有状态），K个动作
- 只涉及一步决策，选择一个摇臂后立即获得奖励，不涉及状态转移
- 每个摇臂的奖赏服从某个期望未知的分布
- 执行有限次动作
- 最大化累积奖赏（期望意义下）



□ 单步强化学习任务对应K-摇臂赌博机

□ 每个摇臂的奖赏由一个**概率分布**确定，通过一次尝试并不能估计该摇臂的平均奖赏

□ 强化学习面临的主要困难：探索-利用窘境 (Exploration-Exploitation dilemma)，亦即在资源有限条件下，加强了一方则会自然削弱另一方

- 探索：估计不同摇臂的优劣 (奖赏期望的大小)
- 利用：选择目前为止平均奖赏最大的摇臂

□ 解决方法是在探索与利用之间进行**折中**

- ϵ -贪心
- Softmax



□ ϵ -贪心

- 以 ϵ 的概率探索：均匀随机选择一个摇臂
- 以 $1 - \epsilon$ 的概率利用：选择当前平均奖赏最高的摇臂（**若有多个，则随机选择一个**）



□ ϵ -贪心

- 以 ϵ 的概率探索：均匀随机选择一个摇臂
- 以 $1 - \epsilon$ 的概率利用：选择当前**平均奖赏(增量式计算)**最高的摇臂
- 若尝试次数很大，则一段时间后不需要探索，**可以令 ϵ 按某种方式逐步减小**

□ Softmax：基于当前已知的摇臂**平均奖赏**来对探索与利用折中

- 若某个摇臂当前的平均奖赏越大，则它被选择的概率越高
- 概率分配使用Boltzmann分布：

$$P(k) = \frac{e^{\frac{Q(k)}{\tau}}}{\sum_{i=1}^K e^{\frac{Q(i)}{\tau}}}$$

其中， $Q(i)$ 记录当前摇臂的平均奖赏。 τ 趋于0时，Softmax趋向于利用； τ 趋于无穷大时，Softmax趋向于探索

□ ϵ -贪心

- 以 ϵ 的概率探索：均匀随机选择一个摇臂
- 以 $1 - \epsilon$ 的概率利用：选择当前平均奖赏最高的摇臂

□ Softmax：基于当前已知的摇臂平均奖赏来对探索与利用折中

- 若某个摇臂当前的平均奖赏越大，则它被选择的概率越高
- 概率分配使用Boltzmann分布：

$$P(k) = \frac{e^{\frac{Q(k)}{\tau}}}{\sum_{i=1}^K e^{\frac{Q(i)}{\tau}}}$$

其中， $Q(i)$ 记录当前摇臂的平均奖赏

□ 两种算法都有一个折中参数 ϵ 或 τ ，算法性能孰好孰坏取决于具体应用问题（p377）

□ 用累计奖赏代替K-摇臂赌博机算法中的奖赏函数，离散状态、离散动作上的**多步**强化学习可以将每个状态上**动作选择**看作一个K-摇臂赌博机问题，基于赌博机算法选择动作，但**没有考虑马尔可夫决策过程的特性**



武汉大学
WUHAN UNIVERSITY

03 有模型学习

Model-based Learning



- 有模型学习 (model-based learning): $E = \langle X, A, P, R \rangle$
- X, A, P, R 均已知
 - 方便起见, 假设状态空间和动作空间均**有限**



- 有模型学习 (model-based learning): $E = \langle X, A, P, R \rangle$
 - X, A, P, R 均已知
 - 方便起见, 假设状态空间和动作空间均有限
- 强化学习的目标: **找到使累积奖赏最大的策略** π

□ 有模型学习 (model-based learning): $E = \langle X, A, P, R \rangle$

- X, A, P, R 均已知
- 方便起见, 假设状态空间和动作空间均有限

□ 强化学习的目标: **找到使累积奖赏最大的策略** π

□ 策略评估: 使用某种策略所带来的累积奖赏

状态值函数: 从状态 x 出发, 使用策略 π 所带来的累积奖赏

$$\begin{cases} V_T^\pi(x) = \mathbb{E}_\pi \left[\frac{1}{T} \sum_{t=1}^T r_t | x_0 = x \right], & T \text{ 步累积奖赏;} \\ V_\gamma^\pi(x) = \mathbb{E}_\pi \left[\sum_{t=0}^{+\infty} \gamma^t r_{t+1} | x_0 = x \right], & \gamma \text{ 折扣累积奖赏.} \end{cases}$$

状态-动作值函数: 从状态 x 出发, 执行动作 a 后再使用策略 π 所带来的累积奖赏

$$\begin{cases} Q_T^\pi(x, a) = \mathbb{E}_\pi \left[\frac{1}{T} \sum_{t=1}^T r_t | x_0 = x, a_0 = a \right]; \\ Q_\gamma^\pi(x, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{+\infty} \gamma^t r_{t+1} | x_0 = x, a_0 = a \right]. \end{cases}$$

□ 给定 π 值函数的计算：值函数具有简单的**递归形式**

- T 步累积奖赏:

$$V_T^\pi(x) = \mathbb{E}_\pi \left[\frac{1}{T} \sum_{t=1}^T r_t | x_0 = x \right]$$

$$= \mathbb{E}_\pi \left[\frac{1}{T} r_1 + \frac{T-1}{T} \frac{1}{T-1} \sum_{t=2}^T r_t | x_0 = x \right] \quad (\text{全概率公式})$$

$$\stackrel{\leftarrow}{=} \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} \mathbb{E}_\pi \left[\frac{1}{T-1} \sum_{t=1}^{T-1} r_t | x_0 = x' \right] \right)$$

$$= \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^\pi(x') \right). \quad \text{Bellman方程}$$

- 使用上述的递归形式计算值函数实际上是一种**动态规划算法**。同样可得到 γ 折扣奖赏的 Bellman方程，并且通过**状态值函数**可以直接计算**状态动作值函数**（P379式16.10）

□ 给定 π ，值函数的计算：值函数具有简单的递归形式

● T 步累积奖赏：

$$\begin{aligned} V_T^\pi(x) &= \mathbb{E}_\pi \left[\frac{1}{T} \sum_{t=1}^T r_t | x_0 = x \right] \\ &= \mathbb{E}_\pi \left[\frac{1}{T} r_1 + \frac{T-1}{T} \frac{1}{T-1} \sum_{t=2}^T r_t | x_0 = x \right] \quad (\text{全概率公式}) \\ &\stackrel{\leftarrow}{=} \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} \mathbb{E}_\pi \left[\frac{1}{T-1} \sum_{t=1}^{T-1} r_t | x_0 = x' \right] \right) \\ &= \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^\pi(x') \right). \quad \text{Bellman方程} \end{aligned}$$

● γ 折扣累积奖赏：

$$V_\gamma^\pi(x) = \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a (R_{x \rightarrow x'}^a + \gamma V_\gamma^\pi(x')).$$



□ 给定 π , **状态-动作值函数**的计算: 通过值函数来表示

$$\begin{cases} Q_T^\pi(x, a) = \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^\pi(x') \right); \\ Q_\gamma^\pi(x, a) = \sum_{x' \in X} P_{x \rightarrow x'}^a \left(R_{x \rightarrow x'}^a + \gamma V_\gamma^\pi(x') \right). \end{cases}$$

□ 给定 π , 状态-动作值函数的计算: 通过值函数来表示

$$\begin{cases} Q_T^\pi(x, a) = \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^\pi(x') \right); \\ Q_\gamma^\pi(x, a) = \sum_{x' \in X} P_{x \rightarrow x'}^a \left(R_{x \rightarrow x'}^a + \gamma V_\gamma^\pi(x') \right). \end{cases}$$

□ 最优策略, 最优值函数, 最优状态-动作值函数 (策略改进)

- **最优策略**: 最大化累积奖赏

$$\pi^* = \operatorname{argmax}_{\pi} \sum_{x \in X} V^\pi(x).$$

- **最优值函数 (最优策略对应的值函数)**:

$$\forall x \in X: V^*(x) = V^{\pi^*}(x).$$

- **最优状态-动作值函数 (西瓜书p380式(16.15))**



- 策略改进：将非最优策略改进为最优策略

□ 策略改进：将策略选择的动作改变为当前最优的动作

- 最优值函数/最优策略满足：

$$\begin{cases} V_T^*(x) = \max_{a \in A} \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^*(x') \right); \\ V_\gamma^*(x) = \max_{a \in A} \sum_{x' \in X} P_{x \rightarrow x'}^a \left(R_{x \rightarrow x'}^a + \gamma V_\gamma^*(x') \right). \end{cases}$$

最优值函数Bellman方程



$$V^*(x) = \max_{a \in A} Q^{\pi^*}(x, a).$$

□ 策略改进：将策略选择的动作改变为当前最优的动作

● 最优值函数/最优策略满足：

$$\begin{cases} V_T^*(x) = \max_{a \in A} \sum_{x' \in X} P_{x \rightarrow x'}^a \left(\frac{1}{T} R_{x \rightarrow x'}^a + \frac{T-1}{T} V_{T-1}^*(x') \right); \\ V_\gamma^*(x) = \max_{a \in A} \sum_{x' \in X} P_{x \rightarrow x'}^a \left(R_{x \rightarrow x'}^a + \gamma V_\gamma^*(x') \right). \end{cases}$$

最优值函数Bellman方程



$$V^*(x) = \max_{a \in A} Q^{\pi^*}(x, a).$$

- 由最优值函数可得**最优状态-动作值函数**
- 非最优策略的改进方式：将策略选择的动作**改变为当前最优的动作**（直到策略不发生变化，此时满足最优Bellman方程，即找到了最优策略---此改变可使得值函数关于策略单调递增）

$$\pi'(x) = \operatorname{argmax}_{a \in A} Q^\pi(x, a).$$

□ 策略迭代 (policy iteration): 求解最优策略的方法

- 随机策略作为初始策略
- 策略评估+策略改进+策略评估+策略改进+.....
- 直到策略收敛

输入: MDP 四元组 $E = \langle X, A, P, R \rangle$;
累积奖赏参数 T .

过程:

```

1:  $\forall x \in X : V(x) = 0, \pi(x, a) = \frac{1}{|A(x)|}$ ;
2: loop
3:   for  $t = 1, 2, \dots$  do
4:      $\forall x \in X : V'(x) = \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a (\frac{1}{t} R_{x \rightarrow x'}^a + \frac{t-1}{t} V(x'))$ ;
5:     if  $t = T + 1$  then
6:       break
7:     else
8:        $V = V'$ 
9:     end if
10:  end for
11:  $\forall x \in X : \pi'(x) = \arg \max_{a \in A} Q(x, a)$ ;
12: if  $\forall x : \pi'(x) = \pi(x)$  then
13:   break
14: else
15:    $\pi = \pi'$ 
16: end if
17: end loop

```

输出: 最优策略 π

图 16.8 基于 T 步累积奖赏的策略迭代算法



- 策略迭代 (policy iteration): 求解最优策略的方法
 - 随机策略作为初始策略
 - 策略评估+策略改进+策略评估+策略改进+.....
 - 直到策略收敛
- 策略迭代算法的缺点
 - 每次改进策略后都要重新评估策略, 导致耗时
- 策略改进与值函数改进 (V函数值增大) 一致, 可得到**值迭代算法 (见西瓜书图16.9)**

输入: MDP 四元组 $E = \langle X, A, P, R \rangle$;
累积奖赏参数 T .

过程:

```
1:  $\forall x \in X : V(x) = 0, \pi(x, a) = \frac{1}{|A(x)|}$ ;  
2: loop  
3:   for  $t = 1, 2, \dots$  do  
4:      $\forall x \in X : V'(x) = \sum_{a \in A} \pi(x, a) \sum_{x' \in X} P_{x \rightarrow x'}^a (\frac{1}{t} R_{x \rightarrow x'}^a + \frac{t-1}{t} V(x'))$ ;  
5:     if  $t = T + 1$  then  
6:       break  
7:     else  
8:        $V = V'$   
9:     end if  
10:  end for  
11:   $\forall x \in X : \pi'(x) = \arg \max_{a \in A} Q(x, a)$ ;  
12:  if  $\forall x : \pi'(x) = \pi(x)$  then  
13:    break  
14:  else  
15:     $\pi = \pi'$   
16:  end if  
17: end loop
```

输出: 最优策略 π

图 16.8 基于 T 步累积奖赏的策略迭代算法



□ 有模型学习小结

- 强化学习任务可归结为基于**动态规划的寻优**问题
- 与监督学习不同，这里并未**涉及到泛化能力**，而是为每一个状态找到最好的动作

□ 问题：如果模型未知呢？



武汉大学
WUHAN UNIVERSITY

04 免模型学习

Model-free Learning



- 免模型学习 (model-free learning): 更加符合实际情况

- **转移概率, 奖赏函数未知**
- 甚至环境中的**状态数目也未知**
- 假定状态空间有限

学习算法不依赖环境建模---免（无）模型学习



□ 免模型学习 (model-free learning): 更加符合实际情况

- 转移概率, 奖赏函数未知
- 甚至环境中的状态数目也未知
- 假定状态空间有限

学习算法不依赖环境建模---免（无）模型学习

□ 免模型学习所面临的困难

- 策略无法评估（无全概率展开）
- 无法通过值函数计算状态-动作值函数
- 机器只能从一个起始状态开始探索环境



□ 免模型学习 (model-free learning): 更加符合实际情况

- 转移概率, 奖赏函数未知
- 甚至环境中的状态数目也未知
- 假定状态空间有限

□ 免模型学习所面临的困难

- 策略无法评估 (无全概率展开)
- 无法通过状态值函数计算状态-动作值函数
- 机器只能从一个起始状态开始探索环境

□ 解决困难的办法

- 多次采样, 平均累计奖赏作为期望累计奖赏的近似
- 直接估计每一对状态-动作的值函数
- 在探索过程中逐渐发现各个状态



- 蒙特卡罗强化学习：采样轨迹，用样本均值近似期望



□ 蒙特卡罗强化学习：采样轨迹，用样本均值近似期望

● 策略评估：蒙特卡罗法

- 从起始状态出发，执行**某策略**进行采样
- 对轨迹中出现的每对状态-动作，记录其后的奖赏之和
- 采样多条轨迹，每个状态-动作对的累积奖赏采样取平均，即得状态-动作值函数估计

一条轨迹：

$$\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$$



□ 蒙特卡罗强化学习：采样轨迹，用样本均值近似期望

- 策略评估：蒙特卡罗法
 - 从起始状态出发，执行某策略进行采样
 - 对轨迹中出现的每对状态-动作，记录其后的奖赏之和
 - 采样多条轨迹，每个状态-动作对的累积奖赏采样取平均，即得状态-动作值函数估计
- 策略改进：换入当前最优动作

一条轨迹：

$$\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$$



□ 蒙特卡罗强化学习：采样轨迹，用样本均值近似期望

● 策略评估：蒙特卡罗法

- 从起始状态出发，执行某策略进行采样
- 对轨迹中出现的每对状态-动作，记录其后的奖赏之和
- 采样多条轨迹，每个状态-动作对的累积奖赏采样取平均，即得**状态-动作值函数估计**

● 策略改进：换入当前最优动作

一条轨迹：

$$\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$$

□ 蒙特卡罗强化学习可能遇到的问题：轨迹的单一性（确定性策略时）

□ 蒙特卡罗强化学习：采样轨迹，用样本均值近似期望

● 策略评估：蒙特卡罗法

- 从起始状态出发，执行某策略进行采样
- 对轨迹中出现的每对状态-动作，记录其后的奖赏之和
- 采样多条轨迹，每个状态-动作对的累积奖赏采样取平均，即得状态-动作值函数估计

● 策略改进：换入当前最优动作

一条轨迹：

$$\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$$

□ 蒙特卡罗强化学习可能遇到的问题：轨迹的单一性

$$\pi^\epsilon(x) = \begin{cases} \pi(x), & \text{以概率 } 1 - \epsilon; \\ A \text{ 中以均匀概率选取的动作,} & \text{以概率 } \epsilon. \end{cases}$$

□ 解决问题的办法

● ϵ -贪心法

- 同策略：被评估与被改进的是同一个策略
- 异策略：被评估与被改进的不是同一个策略 (用重要性采样技术)



- 同策略蒙特卡罗强化学习算法
- 最终产生的是 ϵ -贪心策略

输入：环境 E ;
 动作空间 A ;
 起始状态 x_0 ;
 策略执行步数 T .

过程:

- 1: $Q(x, a) = 0$, $\text{count}(x, a) = 0$, $\pi(x, a) = \frac{1}{|A(x)|}$;
- 2: **for** $s = 1, 2, \dots$ **do**
- 3: 在 E 中执行策略 π 产生轨迹
 $< x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T >$;
- 4: **for** $t = 0, 1, \dots, T-1$ **do**
- 5: $R = \frac{1}{T-t} \sum_{i=t+1}^T r_i$;
- 6: $Q(x_t, a_t) = \frac{Q(x_t, a_t) \times \text{count}(x_t, a_t) + R}{\text{count}(x_t, a_t) + 1}$;
- 7: $\text{count}(x_t, a_t) = \text{count}(x_t, a_t) + 1$
- 8: **end for**
- 9: 对所有已见状态 x :

$$\pi(x, a) = \begin{cases} \arg \max_{a'} Q(x, a'), & \text{以概率 } 1 - \epsilon; \\ \text{以均匀概率从 } A \text{ 中选取动作,} & \text{以概率 } \epsilon. \end{cases}$$
- 10: **end for**

输出：策略 π

图 16.10 同策略蒙特卡罗强化学习算法



□ 异策略蒙特卡罗
强化学习算法
(p385-386)

□ 评估时用 ϵ 贪心,
改进时用原始策
略

输入: 环境 E ;
动作空间 A ;
起始状态 x_0 ;
策略执行步数 T .

过程:

```

1:  $Q(x, a) = 0, \text{count}(x, a) = 0, \pi(x, a) = \frac{1}{|A(x)|}$ ;
2: for  $s = 1, 2, \dots$  do
3:   在  $E$  中执行  $\pi$  的  $\epsilon$ -贪心策略产生轨迹
       $\langle x_0, a_0, r_1, x_1, a_1, r_2, \dots, x_{T-1}, a_{T-1}, r_T, x_T \rangle$ ;
4:    $p_i = \begin{cases} 1 - \epsilon + \epsilon/|A|, & a_i = \pi(x); \\ \epsilon/|A|, & a_i \neq \pi(x), \end{cases}$ 
5:   for  $t = 0, 1, \dots, T-1$  do
6:      $R = \frac{1}{T-t} \sum_{i=t+1}^T (r_i \times \prod_{j=i}^{T-1} \frac{1}{p_j})$ ;
7:      $Q(x_t, a_t) = \frac{Q(x_t, a_t) \times \text{count}(x_t, a_t) + R}{\text{count}(x_t, a_t) + 1}$ ;
8:      $\text{count}(x_t, a_t) = \text{count}(x_t, a_t) + 1$ 
9:   end for
10:   $\pi(x) = \arg \max_{a'} Q(x, a')$ 
11: end for

```

输出: 策略 π

图 16.11 异策略蒙特卡罗强化学习算法



□ 蒙特卡罗强化学习的缺点：**低效**

- 求平均时以“批处理式”进行，在一个完整的采样轨迹完成后才对状态-动作值函数进行更新
- 没有充分利用强化学习任务的MDP结构



- 蒙特卡罗强化学习的缺点：低效
 - 求平均时以“批处理式”进行，在一个完整的采样轨迹完成后才对状态-动作值函数进行更新
 - 没有充分利用强化学习任务的MDP结构

- 克服缺点的办法：时序差分 (temporal difference, TD) 学习



□ 蒙特卡罗强化学习的缺点：低效

- 求平均时以“批处理式”进行，在一个完整的采样轨迹完成后才对状态-动作值函数进行更新
- 没有充分利用强化学习任务的MDP结构

□ 克服缺点的办法：结合动态规划与蒙特卡罗方法---时序差分 (temporal difference, TD) 学习

□ 时序差分学习

- 增量式地进行状态-动作值函数更新
- ϵ -贪心法
 - 同策略：Sarsa算法
 - 异策略：Q-学习 (Q-learning)

$$Q_t^\pi(x, a) = \frac{1}{t} \sum_{i=1}^t r_i \quad \longrightarrow \quad Q_{t+1}^\pi(x, a) = Q_t^\pi(x, a) + \frac{1}{t+1} (r_{t+1} - Q_t^\pi(x, a))$$

□ Sarsa算法

输入：环境 E ;
动作空间 A ;
起始状态 x_0 ;
奖赏折扣 γ ;
更新步长 α .

过程:

- 1: $Q(x, a) = 0, \pi(x, a) = \frac{1}{|A(x)|}$;
- 2: $x = x_0, a = \pi(x)$;
- 3: **for** $t = 1, 2, \dots$ **do**
- 4: $r, x' =$ 在 E 中执行动作 a 产生的奖赏与转移的状态;
- 5: $a' = \pi^\epsilon(x')$;
- 6: $Q(x, a) = Q(x, a) + \alpha(r + \gamma Q(x', a') - Q(x, a))$;
- 7: $\pi(x) = \arg \max_{a''} Q(x, a'')$;
- 8: $x = x', a = a'$
- 9: **end for**

输出：策略 π

图 16.12 Sarsa 算法



□ Q-学习算法

输入：环境 E ;
动作空间 A ;
起始状态 x_0 ;
奖赏折扣 γ ;
更新步长 α .

过程:

- 1: $Q(x, a) = 0, \pi(x, a) = \frac{1}{|A(x)|}$;
- 2: $x = x_0$;
- 3: **for** $t = 1, 2, \dots$ **do**
- 4: $r, x' =$ 在 E 中执行动作 $\pi^\epsilon(x)$ 产生的奖赏与转移的状态;
- 5: $a' = \pi(x')$;
- 6: $Q(x, a) = Q(x, a) + \alpha(r + \gamma Q(x', a') - Q(x, a))$;
- 7: $\pi(x) = \arg \max_{a''} Q(x, a'')$;
- 8: $x = x', a = a'$
- 9: **end for**

输出：策略 π

图 16.13 Q-学习算法



武汉大学
WUHAN UNIVERSITY

05 值函数近似

Value Function Approximation



□ 问题：前面都假定状态空间是离散(有限)的，若状态空间是**连续**(无限)的，该怎么办？



- 问题：前面都假定状态空间是离散(有限)的，若状态空间是连续(无限)的，该怎么办？

- 连续状态空间所面临的困难
 - 值函数不再是关于状态的“表格值函数” (tabular value function)



- 问题：前面都假定状态空间是离散(有限)的，若状态空间是连续(无限)的，该怎么办？

- 连续状态空间所面临的困难
 - 值函数不再是关于状态的“表格值函数” (tabular value function)
 - 值函数可表示为一个数组，输入*i*对应的函数值就是数组元素*i*的值
 - 更改一个状态上的值不会改变其他状态上的值

- 解决困难的办法：**值函数近似**
 - 为简便起见，假定状态空间 $X = \mathbb{R}^n$
 - 为简便起见，首先考虑**线性近似**
 - 假定行为空间有限



- 值函数近似

- 将值函数表达为状态的线性函数

$$V_{\theta}(x) = \theta^{\top} x$$

参数向量

状态向量

- 用最小二乘误差来度量**学到的**值函数与**真实的**值函数 V^{π} 之间的近似程度

$$\varepsilon_{\theta} = \mathbb{E}_{x \sim \pi} \left[(V^{\pi}(x) - V_{\theta}(x))^2 \right].$$

- 用**梯度下降法**更新参数向量，求解优化问题（西瓜书p389式16.34-16.36）



□ 状态-动作值函数的线性近似

$$Q_{\theta}(x, a) = \theta^{\top}(x, a) \quad \rightarrow \quad a = (0, \dots, 1, \dots, 0)$$



□ 状态-动作值函数的线性近似

$$Q_{\theta}(x, a) = \theta^{\top}(x, a) \quad \rightarrow \quad a = (0, \dots, 1, \dots, 0)$$

- 使用线性值函数进行近似替代，可以得到近似Sarsa算法与近似Q-学习算法
- 非线性值函数近似（替代p389式16.32）
 - 核方法



武汉大学
WUHAN UNIVERSITY


06 模仿学习

Imitation Learning




- 强化学习任务中多步决策的**搜索空间巨大**（例如**离散状态和离散动作空间的策略空间大小为 $|A|^{|X|}$** ），基于累积奖赏来学习很多步之前的合适决策非常困难

- 强化学习任务中多步决策的搜索空间巨大，基于累积奖赏来学习很多步之前的合适决策非常困难
- 缓解方法：直接模仿人类专家的状态-动作对来学习策略
 - 相当于告诉机器在什么状态下应该选择什么动作
 - 引入了监督信息来学习策略



- 强化学习任务中多步决策的搜索空间巨大，基于累积奖赏来学习很多步之前的合适决策非常困难
- 缓解方法：直接模仿人类专家的状态-动作对来学习策略
 - 相当于告诉机器在什么状态下应该选择什么动作
 - 引入了监督信息来学习策略



- 直接模仿学习



- 直接模仿学习

人类专家决策轨迹数据：

$$\{\tau_1, \tau_2, \dots, \tau_m\},$$

$$\tau_i = \langle s_1^i, a_1^i, s_2^i, a_2^i, \dots, s_{n_i+1}^i \rangle$$

- 直接模仿学习

- 利用专家的决策轨迹，**构造数据集** D ：状态作为特征，动作作为标记
- 利用数据集 D ，使用分类/回归算法即可**学得策略**
- 将学得策略作为**初始策略**
- 基于环境反馈改进策略（强化学习），从而获得更好的策略

人类专家决策轨迹数据：

$$\{\tau_1, \tau_2, \dots, \tau_m\},$$

$$\tau_i = \langle s_1^i, a_1^i, s_2^i, a_2^i, \dots, s_{n_i+1}^i \rangle$$

构造出的“有标记”数据集：

$$D = \{(s_1, a_1), (s_2, a_2), \dots, (s_{\sum_{i=1}^m n_i}, a_{\sum_{i=1}^m n_i})\}$$



- 强化学习任务中，设计合理的符合应用场景的**奖赏函数**往往相当困难



- 强化学习任务中，设计合理的符合应用场景的奖赏函数往往相当困难
- 缓解方法：从人类专家提供的范例数据中**反推**出奖赏函数



- 强化学习任务中，设计合理的符合应用场景的奖赏函数往往相当困难
- 缓解方法：从人类专家提供的范例数据中反推出奖赏函数
- 逆强化学习 (inverse reinforcement learning)
 - 基本思想：寻找某种奖赏函数使得范例数据是最优的，然后即可使用这个奖赏函数来训练策略
 - 假设奖赏函数表达为状态的**线性函数**，可得到如下逆强化学习算法



• 迭代式逆强化学习算法

输入：环境 E ;

状态空间 X ;

动作空间 A ;

范例轨迹数据集 $D = \{\tau_1, \tau_2, \dots, \tau_m\}$.

过程:

1: $\bar{\mathbf{x}}^* =$ 从范例轨迹中算出状态加权和的均值向量;

2: $\pi =$ 随机策略;

3: **for** $t = 1, 2, \dots$ **do**

4: $\bar{\mathbf{x}}_t^\pi =$ 从 π 的采样轨迹算出状态加权和的均值向量;

5: 求解 $\mathbf{w}^* = \arg \max_{\mathbf{w}} \min_{i=1}^t \mathbf{w}^\top (\bar{\mathbf{x}}^* - \bar{\mathbf{x}}_i^\pi)$ s.t. $\|\mathbf{w}\| \leq 1$;

6: $\pi =$ 在环境 $\langle X, A, R(\mathbf{x}) = \mathbf{w}^{*\top} \mathbf{x} \rangle$ 中求解最优策略;

7: **end for**

输出：奖赏函数 $R(\mathbf{x}) = \mathbf{w}^{*\top} \mathbf{x}$ 与策略 π

图 16.15 迭代式逆强化学习算法



武汉大学
WUHAN UNIVERSITY

07 基于人类反馈的强化学习

Reinforcement learning based on human feedback




通过**有监督微调**，大语言模型已经初步具备了遵循人类指令，并完成各类型任务的能力。然而有监督微调**需要大量指令和所对应的标准回复**，获取大量高质量的回复需要耗费大量的人力和时间成本。由于有监督微调通常采用交叉熵损失做为损失函数，目标是调整参数使得模型输出与标准答案完全相同，不能从整体上对模型输出质量进行判断。因此，模型不能适应自然语言**多样性**，也不能解决微小变化的**敏感性**问题。

强化学习则将模型输出文本作为一个**整体**进行考虑，其优化目标是使得模型生成高质量回复。此外，强化学习方法还不依赖于人工编写的高质量回复。模型根据指令生成回复，奖励模型针对所生成的回复给出质量判断。模型也可以生成多个答案，奖励模型对输出文本质量进行排序。模型通过生成回复并接收反馈进行学习。强化学习方法**更适合生成式任务**，也是大语言模型构建中必不可少的关键步骤。

强化学习 (Reinforcement Learning, RL) 研究的是智能体与环境交互的问题，其目标是使智能体在复杂且不确定的环境中最大化奖励。强化学习基本框架如图6.1 所示，主要由两部分组成：**智能体**和**环境**。

在强化学习过程中，智能体与环境不断交互。智能体在环境中获取某个状态后，会根据该状态输出一个**动作**，也称为**决策 (Decision)**。动作会在环境中执行，环境会根据智能体采取的动作，给出下一个状态及当前动作带来的奖励。。





在现实生活中，经常会遇到需要通过探索和试错来学习的情境。

例如，孩子学会骑自行车的过程或是教机器狗如何玩飞盘。机器狗一开始对如何抓飞盘一无所知，但每当它成功抓住飞盘时，都可以给予它一定的奖励。

这种通过与环境交互，根据反馈来学习最佳行为的过程正是强化学习的核心思想。通过机器狗学习抓飞盘的例子，可以引出一些强化学习中的基本概念。

(1) 智能体与环境：在机器狗学习抓飞盘的场景中，机器狗就是一个**智能体 (Agent)**，它做出**决策 (Decision)** 并执行动作。它所在的场景，包括飞盘的飞行轨迹和速度，以及其他可能的因素，则构成了**环境 (Environment)**。环境会根据智能体的行为给予反馈，通常以奖励的形式。



(2) 状态、行为与奖励：每次机器狗尝试抓飞盘，它都在评估当前的**状态 (State)**，这可能包括飞盘的位置、速度等。基于这些信息，它会采取某种**动作 (Action)**，如跳跃、奔跑或待在原地。根据机器狗所执行的动作，环境随后会给出一个**奖励 (Reward)**，这可以是正面的（成功抓住飞盘）或负面的（错过了飞盘）。

(3) 策略与价值：在尝试各种行为的过程中，机器狗其实是在学习一个**策略 (Policy)**。策略可以视为一套**指导其在特定状态下如何行动的规则**。与此同时，智能体还试图估计**价值 (Value) 函数**，也就是预测在未来采取某一行为所能带来的奖励。



总体来说，强化学习的目标就是让智能体通过与环境互动，学习到一个策略，使其在将来能够获得奖励**最大化**。这使得强化学习不总是关注短期奖励，而是在短期奖励与远期奖励之间找到平衡。

智能体与环境的不断交互过程中，会获得很多观测 o_i 。针对每一个观测，智能体会采取一个动作 a_i ，也会得到一个奖励 r_i 。可以定义历史 H_t 是观测、动作、奖励的序列：

$$H_t = o_1, a_1, r_1, \dots, o_t, a_t, r_t$$

由于智能体在采取当前动作时会依赖它之前得到的历史，因此可以把环境整体状态 S_t 看作关于历史的**函数**：

$$S_t = f(H_t)$$



当智能体能够观察到环境的所有状态时，称环境是**完全可观测的 (Fully Observed)**，这时观测 o_t 等于 S_t 。当智能体只能看到部分观测时，称环境是**部分可观测的 (Partially Observed)**，这时观测是对状态的部分描述。整个状态空间使用 S 表示。

在给定的环境中，有效动作的集合经常被称为**动作空间 (Action Space)**，使用 A 表示。例如围棋 (Go) 这样的环境具有**离散动作空间 (Discrete Action Space)**，智能体的动作数量在这个空间中是有限的。智能体在围棋中的动作空间只有361 个交叉点，而在物理世界中则通常是**连续动作空间 (Continuous Action Space)**。在连续动作空间中，动作通常是实值的向量。例如，在平面中，机器人可以向任意角度进行移动，其动作空间为连续动作空间。



策略是智能体的动作模型，决定了智能体的动作。策略也可以用函数表示，该函数将输入的状态变成动作。策略可分为两种：**随机性策略**和**确定性策略**。

随机性策略 (Stochastic Policy) 用 π 函数表示，即 $\pi(a|s) = p(a_t = a | s_{t'} = s)$ 输入一个状态 s ，输出一个概率，表示智能体所有动作的概率。利用这个概率分布进行采样，就可以得到智能体将采取的动作。

确定性策略 (Deterministic Policy) 是智能体最有可能直接采取的动作，即

$$a^* = \arg \max_a \pi(a|s)$$



价值函数的值是对**未来奖励**的预测，可以用它来评估**状态的好坏**。

价值函数可以只根据当前的状态 s 决定，使用 $V_{\pi}(s)$ 表示。

也可以根据当前状态 s 及动作 a ，使用 $Q_{\pi}(s, a)$ 表示。

$V_{\pi}(s)$ 和 $Q_{\pi}(s, a)$ 的具体定义如下：

$$V_{\pi}(s) = \mathbb{E}_{\pi}[G_t | s_t = s] = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s \right], s \in S$$

$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t | s_t = s, a_t = a] = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a \right]$$

其中， γ 为折扣因子（Discount Factor），针对短期奖励和远期奖励进行折中；期望 E 的下标为 π 函数，其值反映在使用策略 π 时所能获得的奖励值。



根据智能体所学习的组件的不同，可以把智能体归类为基于价值的智能体、基于策略的智能体和演员-评论员智能体。

- 基于价值的智能体 (Value-based Agent) 显式地学习价值函数，隐式地学习策略。其策略是从所学到的价值函数推算得到的。
- 基于策略的智能体 (Policy-based Agent) 则直接学习策略函数。策略函数的输入为一个状态，输出为对应动作的概率。基于策略的智能体并不学习价值函数，价值函数隐式地表达在策略函数中。
- 演员-评论员智能体 (Actor-critic Agent) 则是把基于价值的智能体和基于策略的智能体结合起来，既学习策略函数又学习价值函数，通过两者的交互得到最佳的动作。



随着ChatGPT、Claude 等大模型的成功，强化学习在自然语言处理领域获得了越来越多的注意力。在深度学习中，有监督学习和强化学习不同，可以用[旅行方式](#)进行更直观的对比，有监督学习和强化学习可以看作两种不同的旅行方式，每种旅行都有自己独特的风景、规则和探索方式。

- [旅行前的准备：数据来源](#)

监督学习：这如同旅行者拿着一本旅行指南书，其中明确标注了各个景点、餐厅和交通方式。在这里，数据来源就好比这本书，提供了清晰的**问题和答案对**。

强化学习：旅行者进入了一个陌生的城市，手上没有地图，没有指南。所知道的只是他们的**初衷**，例如找到城市中的一家餐厅或博物馆。这座未知的城市，正是强化学习中的数据来源，充满了探索的机会。



- 路途中的指引：反馈机制

监督学习：在这座城市里，每当旅行者迷路或犹豫时，都会有人告诉他们是否走对了路。这就好比每次旅行者提供一个答案，监督学习都会告诉他们是否正确。

强化学习：在另一座城市，没有人会直接告诉旅行者如何走。只会告诉他们结果是好还是坏。例如，走进了一家餐厅，吃完饭后才知道这家餐厅是否合适。需要通过多次尝试，逐渐学习和调整策略。

- 旅行的终点：目的地

监督学习：在这座城市旅行的目的非常明确，掌握所有的答案，就像参观完旅行指南上提及的所有景点。

强化学习：在未知的城市，目标是学习如何在其中有效地行动，寻找最佳的路径，无论是寻找食物、住宿还是娱乐。



与有监督学习相比，强化学习能够给大语言模型带来哪些好处呢？

针对这个问题，2023 年4月OpenAI 联合创始人John Schulman（约翰·舒尔曼）在Berkeley EECS 会议上所做的报告“Reinforcement Learning from Human Feedback: Progress and Challenges”，分享了OpenAI 在人类反馈的强化学习方面的进展，分析了监督学习和强化学习各自存在的挑战。基于上述报告及相关讨论，强化学习在大语言模型上的重要作用可以概括为以下几个方面。



(1) 强化学习相较于有监督学习更有可能考虑**整体**影响。

有监督学习针对单个词元进行反馈，其目标是要求模型针对给定的输入给出确切的答案。而强化学习是针对整个输出文本进行反馈，并不针对特定的词元。

反馈粒度的不同，使**强化学习更适合大语言模型**，既可以**兼顾表达多样性**，又可以增强对微小变化的敏感性。自然语言十分灵活，可以用多种不同的方式表达相同的语义。而有监督学习很难支持上述学习方式。**强化学习则允许模型给出不同的多样性表达**。

另外，有监督微调通常采用交叉熵损失作为损失函数，由于总和规则，**造成这种损失对个别词元变化不敏感**。如果改变个别的词元，只会对整体损失产生小的影响。但是，一个否定词可以完全改变文本的整体含义。强化学习则可以通过奖励函数同时兼顾多样性和微小变化敏感性两个方面。



(2) 强化学习更容易解决幻觉问题。

用户在大语言模型上主要有三类输入：（a）文本型（Text-Grounded），用户输入相关文本和问题，让模型基于所提供的文本生成答案（例如，“本文中提到的人名和地名有哪些”）；（b）求知型（Knowledge-Seeking），用户仅提出问题，模型根据内在知识提供真实回答（例如，“流感的常见原因是什么”）；（c）创造型（Creative），用户提供问题或说明，让模型进行创造性输出（例如，“写一个关于.....的故事”）。有监督学习算法非常容易使得求知型查询产生幻觉。在模型并不包含或者知道答案的情况下，有监督训练仍然会促使模型给出答案。而使用强化学习方法，则可以通过定制奖励函数，将正确答案赋予非常高的分数，将放弃回答的答案赋予中低分数，将不正确的答案赋予非常高的负分，使得模型学会依赖内部知识选择放弃回答，从而在一定程度上缓解模型的幻觉问题。



(3) 强化学习可以更好地解决多轮对话**奖励累积**问题。

多轮对话能力是大语言模型重要的基础能力之一。多轮对话是否达成最终目标，需要考虑多次交互过程的整体情况，因此很难使用有监督学习的方法构建。而使用强化学习方法，可以通过构建奖励函数，根据整个对话的背景及连贯性对当前模型输出的优劣进行判断。



在进行有监督微调后，大语言模型具备了遵循指令和多轮对话，以及初步与用户进行对话的能力。然而，由于庞大的参数量和训练语料，**大语言模型的复杂性往往难以理解和预测**。当这些模型被部署时，可能会产生严重的后果，尤其是当模型变得日渐强大、应用更加广泛，并且频繁地与用户进行互动时。


研究者追求将人工智能**与人类价值观进行对齐**，文献[24] 提出大语言模型输出的结果应该满足**帮助性（Helpfulness）、真实性（Honesty）及无害性（Harmless）的3H 原则**。由于上述3H 原则体现出了人类偏好，因此**基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）**很自然地被引入了通用对话模型的训练流程。



基于人类反馈的强化学习主要分为**奖励模型训练**和**近端策略优化**两个步骤。

奖励模型通过由人类反馈标注的偏好数据来学习人类的偏好，判断模型回复的有用性，以及保证内容的无害性。奖励模型模拟了人类的偏好信息，能够不断地为模型的训练提供奖励信号。在获得奖励模型后，需要借助强化学习对语言模型继续进行微调。

OpenAI 在大多数任务中使用的强化学习算法都是**近端策略优化（Proximal Policy Optimization, PPO）算法**。近端策略优化可以根据奖励模型获得的反馈优化模型，通过不断的迭代，让模型探索 and 发现更符合人类偏好的回复策略。

图 6.2 近端策略优化算法的实施流程^[164]



近端策略优化涉及以下四个模型：

- (1) 策略模型 (Policy Model) , 生成模型回复。
- (2) 奖励模型 (Reward Model) , 输出奖励分数来评估回复质量的好坏。
- (3) 评论模型 (Critic Model) , 预测回复的好坏, 可以在训练过程中实时调整模型, 选择对未来累积收益最大的行为。
- (4) 参考模型 (Reference Model) , 提供了一个SFT 模型的备份, 使模型不会出现过于极端的变化。



近端策略优化算法的**实施流程**如下：

- (1) 环境采样：策略模型基于给定输入生成一系列的回复，奖励模型则对这些回复进行打分获得奖励。
- (2) 优势估计：利用评论模型预测生成回复的未来累积奖励，并借助广义优势估计 (Generalized Advantage Estimation, GAE) 算法估计优势函数，有助于更准确地评估每次行动的好处。
- (3) 优化调整：使用优势函数来优化和调整策略模型，同时利用参考模型确保更新的策略不会有太大的变化，从而维持模型的稳定性。



- 强化学习：多步决策过程
- 有模型学习
 - 基于动态规划的寻优
- 如何处理环境中的未知因素
 - 蒙特卡罗强化学习
 - 时序差分学习
- 如何处理连续状态空间
 - 值函数近似
- 如何提速强化学习过程
 - 直接模仿学习
 - 逆强化学习



□ Reinforcement Learning: An Introduction

- By Richard S. Sutton and Andrew G. Barto
- <http://webdocs.cs.ualberta.ca/~sutton/book/the-book.html>

□ Statistical Reinforcement Learning: Modern Machine Learning Approaches

- By Masashi Sugiyama
- <https://www.crcpress.com/Statistical-Reinforcement-Learning-Modern-Machine-Learning-Approaches/Sugiyama/9781439856895>



武漢大學
WUHAN UNIVERSITY

End of This Part

课后阅读西瓜书第16章